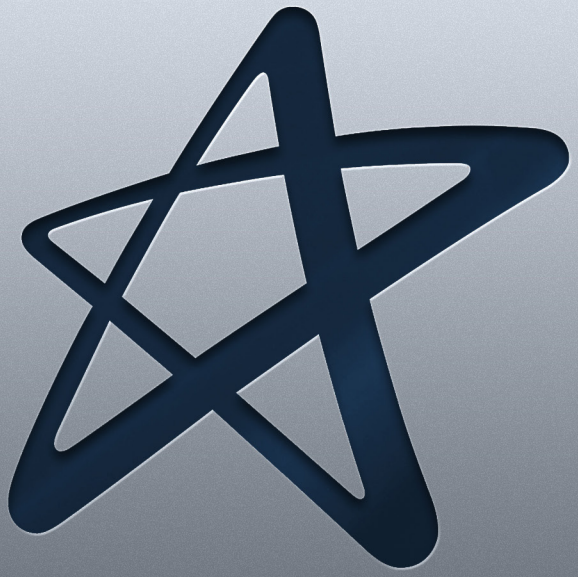
Ciência de Dados e Aprendizagem de Máquina



Cruzeiro do Sul Virtual
Educação a distância

Introdução à Análise de Dados

Responsável pelo Conteúdo:
Prof. Dr. Luciano Rossi

Revisão Textual:
Esp. Maria Thereza Carvalho Rodriguez Guisande

UNIDADE Introdução à Análise de Dados

- Sobre os Dados;
- Análise de Dados;
- Fundamentos da linguagem *R*.



OBJETIVOS DE APRENDIZADO

- Motivar o estudo da ciência de dados, explicitando sua importância e suas possibilidades;
- Apresentar os fundamentos da estatística descritiva e da linguagem de programação *R*.

Orientações de estudo

Para que o conteúdo desta Disciplina seja bem aproveitado e haja maior aplicabilidade na sua formação acadêmica e atuação profissional, siga algumas recomendações básicas:



Assim:

- ✓ Organize seus estudos de maneira que passem a fazer parte da sua rotina. Por exemplo, você poderá determinar um dia e horário fixos como seu "momento do estudo";
- ✓ Procure se alimentar e se hidratar quando for estudar; lembre-se de que uma alimentação saudável pode proporcionar melhor aproveitamento do estudo;
- ✓ No material de cada Unidade, há leituras indicadas e, entre elas, artigos científicos, livros, vídeos e *sites* para aprofundar os conhecimentos adquiridos ao longo da Unidade. Além disso, você também encontrará sugestões de conteúdo extra no item **Material Complementar**, que ampliarão sua interpretação e auxiliarão no pleno entendimento dos temas abordados;
- ✓ Após o contato com o conteúdo proposto, participe dos debates mediados em fóruns de discussão, pois irão auxiliar a verificar o quanto você absorveu de conhecimento, além de propiciar o contato com seus colegas e tutores, o que se apresenta como rico espaço de troca de ideias e de aprendizagem.

Sobre os Dados

No decorrer da história, o poder das pessoas e das organizações foi definido de diferentes formas. Houve uma época, por exemplo, em que o poder era sinônimo de posse de terras produtivas, ou seja, aqueles que possuíam grandes extensões de terras cultiváveis detinham o poder. Nesse contexto, o poder estava associado à capacidade de produção de alimentos. Em outro momento, após a revolução industrial, o poder esteve nas mãos daqueles que detinham os meios de produção em massa, ou seja, grandes indústrias detinham o poder a partir da produção de bens de consumo em larga escala.

Apesar de ainda ser possível considerar os grandes produtores agrícolas e as grandes indústrias como atores detentores de poder, hoje há um novo objeto de desejo para quem o ambiciona: os dados. A exploração dos dados possibilita o acesso a novos conhecimentos que podem, por exemplo, otimizar a produção agrícola ou identificar públicos específicos para novos produtos ou serviços.

O protagonismo dos dados, no contexto contemporâneo, é resultado das práticas atuais no ambiente digital. O uso intensivo de aparelhos, como os *smartphones*, e a conectividade propiciada pela *Internet* são as principais razões para a grande produção de dados. Outro fator importante é a crescente capacidade de processamento de dados. Considere uma analogia para ilustrar esse crescimento: há cerca de 50 anos, uma viagem entre as cidades de Lisboa e do Porto levava, aproximadamente, seis horas. Se os meios de transporte evoluíssem no mesmo ritmo que os processadores, hoje, essa mesma rota levaria por volta de 0,02 segundos.

O crescimento exponencial do volume de dados produzidos diariamente fez surgir um novo conceito, o *Big Data*. As características do *Big Data* podem ser sumarizadas pelas descrições fornecidas pelos quatro vês do *Big Data*, os quais se referem a: Volume, Velocidade, Variedade e Veracidade (LIMA *et al.*, 2018). Cada "V" descreve uma característica em particular, as quais são detalhadas a seguir.

- **Volume:** a prática da utilização de redes sociais, o uso massivo e intensivo dos *smartphones*, o comércio digital, a computação em nuvem e o desenvolvimento da *internet* das coisas (IoT) têm contribuído, de maneira importante, para a produção em larga escala de dados. Esse fenômeno parece ter vindo para ficar e a tendência é que a massa de dados, incrementada todos os dias, cresça exponencialmente e indefinidamente;
- **Velocidade:** a informação, que é possível de ser extraída de conjuntos de dados complexos, tem uma importância relativa em relação ao tempo em que ela é obtida. O objetivo é que se possa realizar o processo de extração de informação em tempo real, ou algo próximo disso;
- **Variedade:** podemos ter dados estruturados (tabelas e arquivos XML) e não estruturados (imagens e *e-mails*). Porém, a grande maioria dos dados são não estruturados, o que introduz maior dificuldade no processamento deles. Além disso, os dados são de fontes distintas, que, comumente, não se relacionam entre elas;
- **Veracidade:** os dados devem refletir a realidade do momento de sua obtenção. Dados antigos não serão capazes de traduzir a realidade daquele contexto no qual estão inseridos. Além disso, nenhum processo é capaz de gerar bons resultados com dados ruins.

Importância

O conceito de *data science,* ou ciência de dados, refere-se, naturalmente, à aplicação de processos de análise de dados. Nesse sentido, *data science* combina conceitos de estatística, *machine learning* (aprendizagem de máquina), *data mining* (mineração de dados) e tecnologias de banco de dados. Apesar de estar muito presente nos últimos anos, a ciência de dados deriva de outras denominações que surgiram há décadas.

Você Sabia?

O termo "mineração de dados" é uma alusão ao processo de extração de minerais preciosos, que ocorre a partir da exploração de uma base de dados (mina), com a aplicação de algoritmos (ferramentas), resultando na obtenção de conhecimento (minerais valiosos).

São exemplos de denominações referentes à análise de dados que precederam a ciência de dados:

- *Decision Support Systems* (1970);
- *Executive Information Systems* (1980);
- *Online Analytical Processing* (1990);
- *Business Inteligence* (2000);
- *Data Science* (2010).

A principal evolução, no que se refere aos conceitos em suas respectivas épocas, está na abrangência dos dados considerados. Inicialmente, os dados estavam restritos a um departamento de uma empresa ou a algum contexto bastante específico. Nos dias atuais, os dados estão disseminados em diferentes contextos. Pode-se, por exemplo, encontrar dados sobre a percepção de consumidores sobre um determinado produto nas redes sociais. Esse tipo de dado é importante para que a empresa que comercializa o produto possa definir estratégias de aprimoramento dos processos de fabricação, comercialização e publicidade de seus produtos.

Com a popularização da área de análise de dados, diferentes nomenclaturas são amplamente utilizadas, como: *Business Inteligence*, *Analytics*, *Big Data*, *Data Mining*, *Machine Learning*, entre outros. Você consegue especificar quais são as principais diferenças entre essas nomenclaturas?

Considere, por exemplo, que seja possível verificar quais produtos são adquiridos conjuntamente em um supermercado. Imagine que se verifique que cervejas e fraldas descartáveis são produtos que frequentemente aparecem em uma mesma compra. Essa informação é importante para o supermercado, pois pode ser utilizada como base para a exposição dos produtos nas prateleiras. Nesse caso específico, expor cervejas e fraldas próximos uns dos outros pode ser uma estratégia que alavancará as vendas desses produtos. Esse tipo de aplicação é denominada "extração de regras de vendas".

Em outro cenário, um grande avanço tecnológico na área do entretenimento são os serviços de *streaming*. Esse tipo de serviço oferece aos usuários acesso a determinados conteúdos, como músicas ou filmes, via *Internet*. Um grande desafio nesse tipo de negócio é fazer com que os usuários se motivem a consumir cada vez mais conteúdo, de modo a permanecer como cliente o maior tempo possível. A estratégia utilizada por empresas que atuam nesse ramo é baseada na caracterização dos usuários, ou seja, conhecer as preferências de seus clientes e utilizar esse conhecimento para recomendar novos conteúdos que tenham potencial para agradá-los. Esse tipo de abordagem é denominada "recomendação de conteúdo" e pode ser aplicada em uma grande variedade de contextos que utilizam os próprios dados dos clientes para uma recomendação mais assertiva.

As redes sociais, no mesmo sentido, impactam de forma importante os processos de negócio no mundo analógico. Empresas mantêm contas nas redes sociais para possibilitar um canal de comunicação direto com o consumidor e, desse modo, avaliar a aceitação de seus produtos e serviços. Nesse contexto, um desafio importante é a avaliação de um grande volume de mensagens que são postadas nas redes sociais, de modo que se possa verificar se estão falando bem ou mal de uma determinada empresa ou marca. Essa tarefa é muito difícil de ser realizada por pessoas, visto que o tempo necessário para verificar o conteúdo de milhares de mensagens acaba por inviabilizar a tarefa. Assim, a abordagem denominada "mineração de sentimentos" possibilita a realização desse tipo de tarefa de maneira automática. Cada mensagem é classificada como positiva, negativa ou neutra, sem que haja a necessidade de classificação manual das mensagens.

São muitos os exemplos de aplicação para a ciência de dados, como também são muitas as áreas que podem ser impactadas por suas descobertas. As técnicas consideradas pela ciência de dados são efetivas em aplicações que vão desde a indústria até a área da saúde, passando por praticamente todas as áreas possíveis de serem enumeradas. Do mesmo modo, os resultados destas aplicações produzem impacto na assertividade, na velocidade e nos custos dos processos impactados.

Nesta disciplina, serão consideradas as principais tarefas de mineração de dados. Essas tarefas são, originalmente, derivas da área de aprendizagem de máquina e possibilitam uma grande variedade de aplicações importantes que utilizam dados como principal insumo. A seguir, vamos analisar os diferentes tipos de dados.

Tipologia

Os dados podem se apresentar de dois tipos principais, de acordo com sua disposição. A identificação do tipo de dado é importante para definir qual tarefa de mineração de dados é mais adequada. Nesse contexto, os dados podem ser estruturados ou não estruturados.

Os dados estruturados são os preferidos pelos sistemas computacionais. Esse tipo de dado é comumente apresentado como uma representação tabular, em que as linhas armazenam um determinado evento e as colunas se referem aos atributos que compõem o evento. Veja, na Tabela 1, um exemplo de conjunto de dados estruturados.

Tabela 1 – Exemplo de conjunto de dados estruturados

ID	Nome	Idade	Peso	Altura	Tabagista	Sedentário	Hipertenso
01	João	49	89,0	1,73	SIM	NÃO	NÃO
02	Maria	18	52,1	1,60	NÃO	NÃO	SIM
...	...	...	...	...	...	...	...
n	Ana	27	48,8	1,53	SIM	SIM	NÃO

Considerando a Tabela 1, a primeira coluna (ID) se refere ao identificador de cada observação ou objeto (linha). Além desse atributo, o exemplar apresenta seis atributos descritivos (nome, idade, peso, altura, tabagista e sedentário) e um atributo de rótulo (hipertenso). Os atributos descritivos apresentam as propriedades do objeto que será analisado, já o atributo de rótulo, ou simplesmente rótulo, define a classe na qual o objeto está inserido.

No caso do exemplo do Tabela 1, note que os objetos se referem a indivíduos em um contexto de saúde. Os atributos descritivos são as características de cada indivíduo e o rótulo define se o indivíduo é ou não hipertenso. Desse modo, poderíamos, por exemplo, estar interessados em descobrir uma correlação entre as características dos pacientes e o fato de eles serem, ou não, hipertensos.

Cada atributo de um objeto é associado a um valor. Os valores dos atributos podem ser de dois tipos: categórico ou numérico. Os valores categóricos, também chamados de qualitativos, são aqueles que definem uma categoria e podem ser classificados como: binário, nominal ou ordinal.

Um atributo binário é aquele que assume somente dois valores, por exemplo, “0” ou “1”, “fechado” ou “aberto”, “ligado” ou “desligado” etc. Um atributo nominal tem seus valores como símbolos ou rótulos distintos, por exemplo, o atributo “estado civil” pode assumir os valores “solteiro”, “casado”, “separado”, “divorciado” ou “viúvo”. Note que não existe uma escala entre esses valores, ou seja, nenhum deles é mais valioso que os demais. Por fim, atributos ordinais são aqueles que possibilitam a ordenação das categorias, por exemplo, o atributo “nível de escolaridade” pode assumir os valores “fundamental”, “médio”, “graduação”, “especialização”, “mestrado” ou “doutorado”. Nesse caso, há uma escala que pode ser considerada para a ordenação dos valores.

Os valores numéricos, também chamados de quantitativos, podem ser de três tipos: contínuos, discretos ou razão. Um atributo contínuo é aquele cujo valor é resultado de uma medição, por exemplo, o peso de uma pessoa. Um atributo discreto é aquele cujo valor é resultado de contagem, por exemplo, o número de filhos que uma pessoa tem. Um atributo tipo “razão” é aquele que o método de medida define o ponto zero. A Figura 1 apresenta a hierarquia dos atributos.

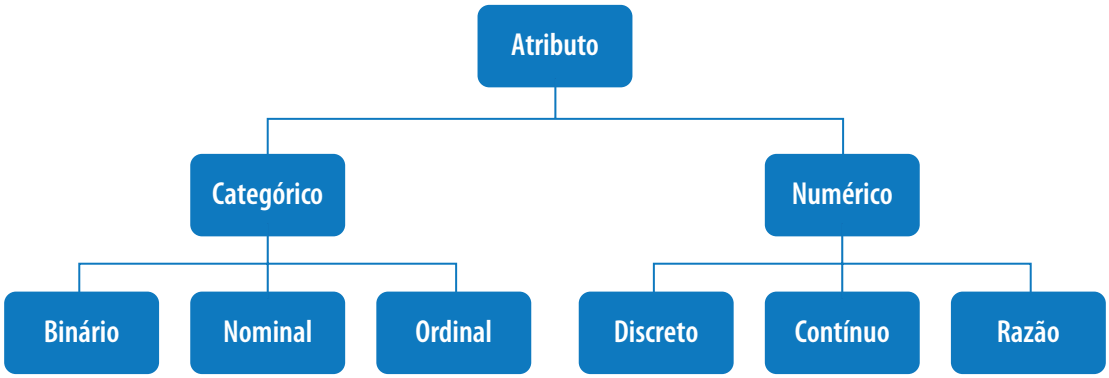


Figura 1 – Hierarquia dos atributos
Fonte: Adaptada de CASTRO; FERRARI, 2016

Apesar de os dados estruturados serem facilmente processados em um computador, somente uma pequena parte dos dados correspondem a essa categoria. A grande maioria dos dados existentes são classificados como não estruturados. Os dados não estruturados, como o próprio nome indica, são aqueles que não apresentam uma estrutura evidente. São exemplos de dados não estruturados: um texto, uma imagem, um som, além de outros tantos possíveis.

Dados não estruturados são de fácil interpretação por seres humanos. Uma criança pode, facilmente, identificar uma imagem de um leão. Por outro lado, um computador não realiza esse tipo de associação facilmente. Assim, o processamento de dados não estruturados requer algum tipo de estruturação prévia para que o processamento seja possibilitado.

Além da classificação dos dados, é importante discutir sobre a qualidade desses dados. Não existe processo de análise de dados que seja robusto o suficiente para produzir bons resultados a partir de dados de má qualidade. Os problemas referentes à qualidade dos dados também podem ser tipificados. Veja, na Figura 2, os principais tipos de problemas que podem ser observados.

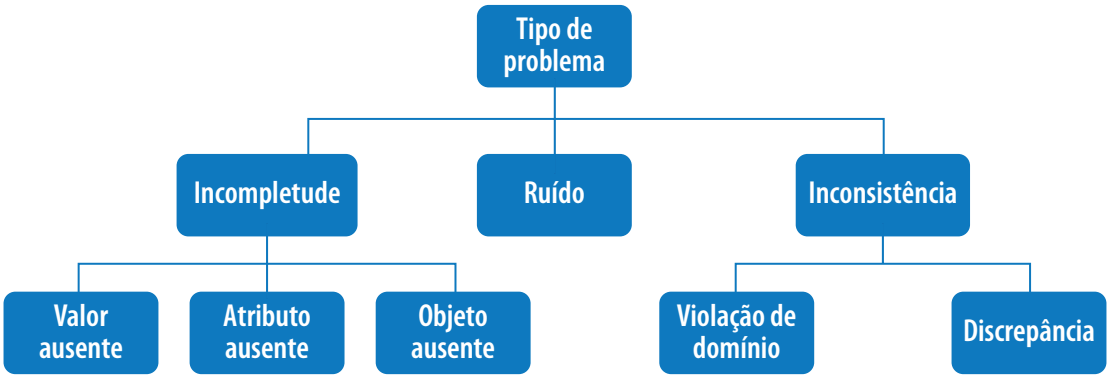


Figura 2 – Principais tipos de problemas com dados
Fonte: Adaptada de CASTRO; FERRARI, 2016

O primeiro tipo de problema com os dados é a incompletude. Nesse caso, estamos nos referindo à ausência de algum elemento no conjunto de dados. Essa ausência pode ser observada em diferentes níveis. Pode ocorrer a ausência de todo o objeto, de um atributo específico ou de apenas um valor. Independentemente do tipo de ausência, é preciso definir uma política de tratamento para cada caso. Assim, os dados devem ser tratados antes da sua utilização por qualquer tarefa de mineração.

Valores ruidosos são aqueles que sofreram alguma modificação quando comparados aos valores originais. Podem ser derivados de erros de medição ou são valores que não se enquadram no padrão observado para a maioria dos atributos do conjunto.

O problema de inconsistência dos valores se refere à discrepância entre valores de um mesmo atributo ou de atributos equivalentes. Suponha, por exemplo, que uma determinada análise considere dois conjuntos de dados provenientes de fontes diferentes. Em ambos os conjuntos, há um atributo que se refere a uma data. No primeiro conjunto a data é grafada com o mês em formato numérico. Já para o segundo conjunto, considerou-se o mês descrito por extenso. Veja que temos que normalizar a forma como as datas serão grafadas antes de iniciar qualquer tipo de análise. Outras fontes de inconsistência podem ser relacionadas a conflitos de unidades, representações ou escalas.

Independentemente do tipo de problema que os dados apresentem, o processo de descoberta de conhecimento considera uma etapa exclusiva para o tratamento prévio dos dados. Essa etapa é denominada de pré-processamento e será discutida mais na frente.

Análise de Dados

O processo de análise de dados é precedido de uma série de etapas fundamentais. Conforme descrito anteriormente, o pré-processamento dos dados garante a qualidade dos resultados. Processos analíticos robustos não garantem bons resultados quando são inseridos dados sem qualidade. Além disso, todo resultado obtido em uma análise de dados é baseado em conceitos estatísticos.

Um analista de dados, ou qualquer outra denominação correlata, é um profissional multidisciplinar, ou seja, ele tem conhecimentos sobre diferentes áreas. Dentre os conhecimentos principais, podemos destacar a programação de computadores e uma certa fluência em estatística. Nesta seção, vamos apresentar os conceitos fundamentais em estatística descritiva (BECKER, 2015) que vão ser úteis para a realização de análises mais eficientes.

Estatística Descritiva

A estatística descritiva é importante para a realização da etapa de pós-processamento, que é dedicada à análise dos resultados obtidos. Nesse contexto, apresentaremos os principais conceitos da estatística descritiva, de modo que a interpretação dos resultados obtidos, a partir da realização das tarefas de mineração de dados, possam ser corretamente avaliados.

- **População:** conjunto de objetos que compartilham características comuns sobre as quais se pretende desenvolver algum estudo. Suponha, por exemplo, que se queira prever o resultado da eleição para prefeito de uma determinada cidade. Nesse exemplo, a população que será estudada são os moradores da cidade que estejam aptos a votar nesse pleito. A população pode ser pequena ou grande. No caso de ser pequena, pode-se considerar todos os objetos do conjunto na análise. Para o caso de a população ser grande, é preciso se definir uma amostra que viabilize a análise;

- **Amostra:** subconjunto da população, cujo objetivo é representar a população. A definição de uma amostra deve considerar técnicas específicas para garantir a representação da população. Considerando o exemplo anterior, um instituto de pesquisa deve definir quais eleitores serão questionados sobre a intenção de voto. Nesse caso, deve-se considerar a representatividade proporcional de acordo com localização, escolaridade, renda, dentre outras características possíveis;
- **Variável:** equivalente ao atributo no contexto da mineração de dados. São referentes às características associadas aos objetos. Podem ser quantitativas ou qualitativas, conforme descrito anteriormente (veja Figura 1);
- **Medidas de posição:** também conhecidas como medidas de tendência central, são utilizadas para determinar a localização de um conjunto de valores por meio de um valor que represente os demais:
  - » **Média:** é obtida a partir da soma de um conjunto de valores dividida pelo número de observações;
  - » **Mediana:** valor que separa a distribuição de valores ao meio;
  - » **Moda:** valor mais frequente em um conjunto de valores.
- **Medidas de dispersão:** são utilizadas para determinar a variação de um conjunto de valores.
  - » **Amplitude:** é a diferença entre o maior e o menor valor em um conjunto de dados;
  - » **Variância:** é a média dos quadrados das diferenças entre cada valor do conjunto e a média desse conjunto;
  - » **Desvio padrão:** é a raiz quadrada da variância.

Considere o Tabela 2 que representa a quantidade de vendas de itens em um restaurante em um mês.

Tabela 2 – Vendas de um restaurante

Item	A	B	C	D	E	F	G	H	I
Qtd	29	30	32	65	65	65	25	25	90

Fonte: Adaptada de SILVA; PERES; BOSCARIOLI, 2017

Considere, também, a fórmula para o cálculo da média. Assim, a média das vendas do restaurante no período considerado é:

$$média(Qtd) = \frac{1}{n}\sum_{i=1}^{n} v_i = \frac{1}{9}(29+30+32+65+65+65+25+25+90) = 47,3 \quad \text{(Eq. 1)}$$

Para se obter a mediana dos valores apresentados no Tabela 2, é preciso que se tenha esses valores previamente ordenados. O Tabela 3 apresenta o resultado dessa ordenação.

Tabela 3 – Vendas de um restaurante com os valores ordenados

Item	G	H	A	B	C	D	E	F	I
Qtd	25	25	29	30	32	65	65	65	90

Fonte: Adaptada de SILVA; PERES; BOSCARIOLI, 2017

A fórmula para a identificação da mediana considera o número de elementos contabilizados e é descrita a seguir:

$$mediana\left(Qtd\right)=\begin{cases} v_i \; se\, n\, é\, impar, i=\dfrac{n+1}{2} \\ \dfrac{1}{2}\left(v_i+v_{i+1}\right) se\, n\, é\, par, i=\dfrac{n}{2} \end{cases} \qquad \text{(Eq. 2)}$$

Como o número de valores considerado (i) é ímpar, temos: $i=(9+1)/2=5$, assim a mediana é $v_5=32$. Para esse mesmo exemplo, a moda é igual a 65, que é o valor que mais se repete no conjunto de valores.

Para o cálculo da variância dos valores do exemplo, vamos considerar a seguinte fórmula:

$$\sigma^2\left(Qtd\right)=\frac{1}{n}\sum_{i=1}^{n}\left(v_i-media\left(Qtd\right)\right)^2 \qquad \text{(Eq. 3)}$$

Sua aplicação deve ser feita em cada um dos valores, de acordo com o que mostra o Tabela 4.

Tabela 4 – Cálculo da variância para os valores do exemplo do restaurante

	Qtd	v_i – média(Qtd)	$(V_i$ – média(Qtd))^2
v_1	25	-22,33	498,78
v_2	25	-22,33	498,78
v_3	29	-18,33	336,11
v_4	30	-17,33	300,44
v_5	32	-15,33	235,11
v_6	65	17,67	312,11
v_7	65	17,67	312,11
v_8	65	17,67	312,11
v_9	90	42,67	1820,44
	$\sum v=426$		$\sum\left(v_i-média\left(Qtd\right)\right)^2=4626$

Fonte: Adaptada de SILVA; PERES; BOSCARIOLI, 2017

Com base no Tabela 4, a variância do conjunto de valores é $\sigma^2\left(Qtd\right)=\dfrac{4626}{9}=513,99$, enquanto o desvio padrão é $\sigma\left(Qtd\right)=\sqrt{513,99}=22,67$.

Pré-processamento

A utilização dos algoritmos que implementam as tarefas de mineração de dados deve ser realizada após a preparação dos dados que serão analisados. A etapa de preparação dos dados é denominada pré-processamento. Na Figura 3, são apresentadas as etapas que precedem a aplicação dos algoritmos. Tudo se inicia com a definição do problema que se pretende resolver. Após a definição do problema, a próxima etapa é a seleção dos dados brutos que serão utilizados para a resolução do problema.

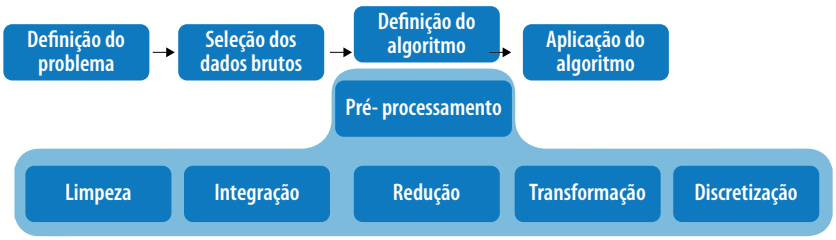


Figura 3 – Etapas do processo de preparação da base de dados
Fonte: Adaptada de CASTRO; FERRARI, 2016

Nesse ponto, é possível a definição do algoritmo que será aplicado e, em função do algoritmo, pode-se estabelecer a estrutura mais adequada para o conjunto de dados. Além disso, os possíveis problemas existentes no conjunto de dados devem ser identificados e corrigidos antes da aplicação do algoritmo.

A limpeza dos dados tem por objetivo tratar a ausência de valores e os valores ruidosos. Comumente, a ausência de valores pode ser resolvida a partir da remoção de todo o objeto que apresenta algum valor ausente. Outra solução possível é o preenchimento manual ou automático desses valores.

Os valores ruidosos são aqueles que surgem de modificações dos valores reais no conjunto de dados. Essas modificações podem ser resultado de erros de medidas ou de *outliers*. Os *outliers* são valores que apresentam um comportamento discrepante dos demais valores do conjunto de dados. A correção dos valores ruidosos pode ser feita a partir de duas abordagens: a primeira considera a inspeção e a correção manual desses valores; e a segunda abordagem é feita por meio da identificação e limpeza automáticas, com a utilização de algoritmos específicos para esse fim.

A etapa de integração dos dados tem por objetivo corrigir problemas decorrentes do uso de conjuntos de dados provenientes de fontes distintas. A utilização de diferentes fontes de dados pode ocasionar problemas de valores inconsistentes ou redundantes.

Um valor inconsistente é aquele que é discrepante em relação ao domínio. Uma data, por exemplo, pode ser grafada de diferentes formas a depender do conjunto de dados. Assim, é preciso padronizar esses valores para que sejam expressos da mesma maneira. A correção desse tipo de problema passa pela remoção do objeto com valor inconsistente, pela correção manual desse valor ou, ainda, por uma correção automática, a partir da análise do esquema dos dados.

Valores redundantes podem ser resultado da utilização de diferentes nomenclaturas para um mesmo atributo em fontes de dados distintas; da prática de armazenamento

de atributos que são obtidos a partir de outros atributos; ou pela inserção de exemplares repetidos por conta de erros de aquisição. A solução para os valores redundantes é obtida a partir da redução dos dados, seja pela eliminação de objetos ou de atributos. As principais técnicas para redução de dados são:

- Agregações em cubos OLAP;
- Análises de correlação;
- Aplicação de medidas de ganho de informação;
- Métodos de invólucro (*wrapper*);
- Análise de componentes principais; ou
- Análise de fator.

A etapa de transformação dos dados se refere ao processo de padronizar ou de normalizar a apresentação dos dados. A padronização dos dados é o processo que resolve as diferenças relativas à unidade ou à escala. Os casos mais comuns de padronização são: a capitalização que padroniza os dados para caixa alta ou baixa (maiúsculas ou minúsculas); a substituição de caracteres especiais que não sejam padrões em diferentes idiomas; a padronização de formatos para valores, por exemplo, datas, números de documentos, entre outros, visando uma representação uniforme; e a conversão de unidades de medidas.

A normalização é o processo de transformação dos dados com o objetivo de torná-los mais adequados aos algoritmos que serão utilizados. São exemplos de tipos de normalização: *Min-Max*, *Escore-Z*, escalonamento decimal e *range* interquartil.

Finalmente, a etapa de "discretização" se refere ao processo de divisão de domínio em intervalos, com o objetivo de atender às especificações de determinados algoritmos e reduzir a números de valores para facilitar o processo de mineração.

Fundamentos da Linguagem *R*

Para cada tarefa que será estudada nesta disciplina, as implementações dos algoritmos de mineração de dados serão feitas por meio da linguagem de programação *R*. A linguagem *R* é voltada para aplicações que envolvem estatística e visualização de resultados em forma de gráficos, estando disponível para sistemas operacionais *Linux*, *macOS* e *Windows*. Além disso, ela conta com um IDE chamado *R-Studio*, que pode ser instalado ou utilizado via *web*.



Um *IDE* (*Integrated Development Environment* ou Ambiente de Desenvolvimento Integrado) facilita o desenvolvimento de aplicações por meio da disponibilização de um conjunto de ferramentas úteis para esse fim. A linguagem de programação R conta com o *R STUDIO* como IDE. *Take control of your R code*. Disponível em: https://bit.ly/30C5ha7

Os programas em linguagem *R* podem ser criados e executados em linha de comando ou com a utilização do *R-Studio*. Os exemplos que serão apresentados nesta disciplina serão demonstrados a partir do *R-Studio*. Veja, na Figura 4, a visão geral do *R-Studio*.

O ambiente do *R-Studio* é dividido em quatro quadrantes principais. No primeiro quadrante, temos o "**editor**", que é o local onde os códigos são escritos. O quadrante "**console**" é o local onde os códigos são executados e as saídas são apresentadas. O quadrante identificado como "*output*" (na Figura 4) permite visualizar o sistema de arquivos (aba *files*), os gráficos resultantes da execução do código (aba *plots*), os pacotes instalados e disponíveis para instalação (aba *packages*), o *link* para ajuda (aba *help*) e uma aba de visualização (*viewer*). O último quadrante (canto superior direito da Figura 4) apresenta a aba *environment,* que é um painel com todos os objetos criados na sessão.

O *R-Studio* disponibiliza os seguintes tipos de dados primitivos: *character* (cadeia de caracteres), *complex* (números complexos), *numeric* (números reais), *integer* (números inteiros) e *logical* (valor lógicos).

Os arranjos (vetores) em R são objetos atômicos homogêneos. Se colocarmos dados de tipos diferentes em um mesmo vetor, eles serão convertidos para o mesmo tipo, de acordo com as seguintes precedências: *character* → *complex* → *numeric* → *integer* → *logical*. Criar um vetor com diferentes tipos de dados e verificar o tipo resultante do vetor, por exemplo, pode ser feito da seguinte forma:

```
> vetor <- c(1,"a",TRUE,3.2)

> class(vetor)

[1] "character"
```

Veja que o exemplo combina quatro tipos diferentes de dados ("*integer*", "*character*", "*logical*" e "*numeric*") atribuídos ao vetor [`vetor <- c(1,"a",TRUE,3.2)`]. Desse modo, ao se verificar qual é o tipo do vetor [`class(vetor)`], nota-se que ele assumiu o tipo "`character`", de acordo com os níveis de precedência considerados.

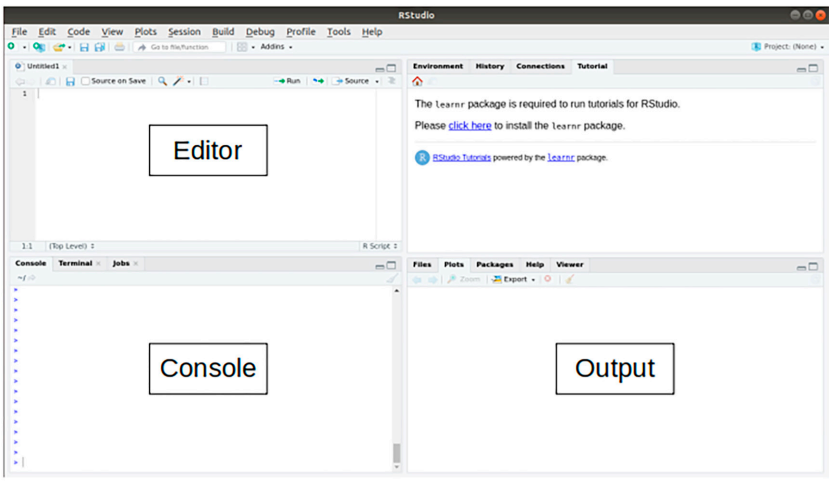


Figura 4 – Visão geral do *R-Studio*
Fonte: Reprodução

Podemos forçar os tipos de dados de forma explícita. Veja, no exemplo abaixo, que criamos um vetor identificado por `x`, com valores numéricos inteiros de zero até quatro. O tipo ou classe desse vetor é "`integer`". A partir da utilização da função `as.*` combinada com o nome da classe que se pretende forçar, podemos obter um objeto de uma outra classe.

```
> x <- 0:4

> class(x)

[1] "integer"

> as.numeric(x)

[1] 0 1 2 3 4

> as.logical(x)

[1] FALSE  TRUE  TRUE  TRUE  TRUE

> as.character(x)

[1] "0" "1" "2" "3" "4"
```

Note que, quando forçamos o vetor `x` para a classe `logical`, os valores diferentes de zero foram transformados para `TRUE`.

As listas em *R* são coleções de objetos que não precisam, necessariamente, pertencer à mesma classe, ou seja, uma lista é um objeto heterogêneo. Veja, no exemplo abaixo, como criar uma lista.

```
> y <- list(1L:4L,"a", c("a","b"), TRUE)

> y

[[1]]

[1] 1 2 3 4


[[2]]

[1] "a"


[[3]]

[1] "a" "b"


[[4]]

[1] TRUE
```

A lista `y` foi criada a partir da utilização da função `list()`. Os elementos que compõem a lista `y` são de classes diferentes. O primeiro elemento da lista, indicado pela notação `[[1]]`, é um arranjo de números inteiros de um até quatro. Note que o `L` que acompanha o número indica a classe integer. Os demais elementos da lista `y` são das classes `character`, `character` e `logical`, respectivamente.

Para a criação de matrizes (arranjos bidimensionais) em *R*, utilizamos a função `matrix()`. Essa função permite que sejam especificados tanto os valores que serão populados na matriz quanto suas dimensões. No exemplo abaixo, criamos uma matriz com duas linhas e três colunas, populada com valores de um até seis. A função `dim()` retorna à dimensão da matriz.

```
> m <- matrix(1:6, nrow = 2, ncol = 3)

> m

     [,1] [,2] [,3]

[1,]    1    3    5

[2,]    2    4    6

> dim(m)

[1] 2 3
```

Nas Unidades posteriores serão apresentadas outras funções *R* de acordo com a necessidade da aplicação. Essas funções iniciais são úteis para estabelecer um primeiro contato com a linguagem. À medida que as implementações das tarefas de mineração de dados forem estudadas, apresentaremos as funções correspondentes.



Visite a Galeria de Gráficos *R* e veja mais sobre as potencialidades da linguagem *R*, principalmente na visualização gráfica de dados. Disponível em: https://bit.ly/3BSBlyD

Material Complementar

Indicações para saber mais sobre os assuntos abordados nesta Unidade:

Vídeos

10 *Cases* de Sucesso de *Data Science* na Indústria
https://youtu.be/JkjZXe4gVCo

Estatísticas Descritivas no *R* – Tabelas
https://youtu.be/jZvQ4N0nuDY

***R* (Linguagem de Programação para *Data Science*) – Dicionário do Programador**
https://youtu.be/x4S9rlJHqxU

Tutorial *R* | Representação e Tipos de Pré Processamento de Dados
https://youtu.be/T19_Egp8nkE

Referências

BECKER, J. L. **Estatística básica:** transformando dados em informação. 1. ed. Porto Alegre: Bookman, 2015. (*e-book*)

CASTRO, L. N. de; FERRARI, D. G. **Introdução à mineração de dados:** conceitos básicos, algoritmos e aplicações. 1. ed. São Paulo: Saraiva Uni, 2016. (*e-book*)

LIMA, M. de F. W. do P. **Introdução a *Big Data* e *Internet* das Coisas**. 1. ed. Porto Alegre: SAGAH, 2018.

SILVA, L. A. da; PERES, S. M.; BOSCARIOLI, C. **Introdução à mineração de dados:** com aplicações em R. 1. ed. Rio de Janeiro: Elsevier Brasil, 2017.


Cruzeiro do Sul
Educacional