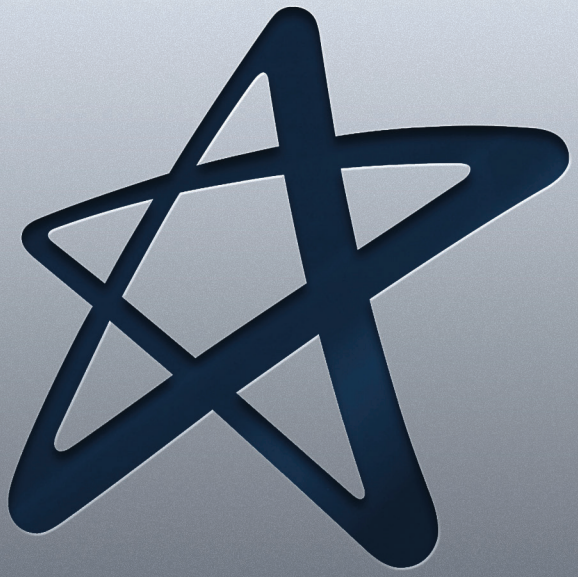
Ciência de Dados e Aprendizagem de Máquina



Cruzeiro do Sul Virtual
Educação a distância

Análise Preditiva – Parte II

Responsável pelo Conteúdo:
Prof. Dr. Luciano Rossi

Revisão Textual:
Prof. Me. Claudio Brites

UNIDADE Análise Preditiva – Parte II

- Conceito de Regressão;
- Regressão Linear;
- Regressão não Linear;
- Modelos Preditivos.



OBJETIVO DE APRENDIZADO

- Analisar as principais características da tarefa de regressão, por meio da definição de alguns de seus principais algoritmos com a respectiva aplicação prática.

Orientações de estudo

Para que o conteúdo desta Disciplina seja bem aproveitado e haja maior aplicabilidade na sua formação acadêmica e atuação profissional, siga algumas recomendações básicas:



Assim:

- ✓ Organize seus estudos de maneira que passem a fazer parte da sua rotina. Por exemplo, você poderá determinar um dia e horário fixos como seu "momento do estudo";
- ✓ Procure se alimentar e se hidratar quando for estudar; lembre-se de que uma alimentação saudável pode proporcionar melhor aproveitamento do estudo;
- ✓ No material de cada Unidade, há leituras indicadas e, entre elas, artigos científicos, livros, vídeos e *sites* para aprofundar os conhecimentos adquiridos ao longo da Unidade. Além disso, você também encontrará sugestões de conteúdo extra no item **Material Complementar**, que ampliarão sua interpretação e auxiliarão no pleno entendimento dos temas abordados;
- ✓ Após o contato com o conteúdo proposto, participe dos debates mediados em fóruns de discussão, pois irão auxiliar a verificar o quanto você absorveu de conhecimento, além de propiciar o contato com seus colegas e tutores, o que se apresenta como rico espaço de troca de ideias e de aprendizagem.

Conceito de Regressão

A tarefa de classificação tem por objetivo predizer um rótulo para um objeto não rotulado. Trata-se, como vimos anteriormente, de uma tarefa preditiva, na qual o rótulo é do tipo categórico. O processo de predição de um rótulo categórico tem como base um conjunto de dados rotulados. Assim, a partir da utilização de algum algoritmo preditivo, busca-se identificar um padrão que possa ser utilizado para a predição de rótulos categóricos para objetos não rotulados.

Do ponto de vista formal, dizemos que o processo que descreve a tarefa de classificação produz um modelo f que é considerado para a predição de um rótulo y a um objeto não rotulado $\vec{x}$, ou seja, $f(\vec{x}) = y$. Nesse contexto, o padrão encontrado nos dados rotulados é utilizado para a obtenção de um rótulo, a partir dos atributos descritivos do objeto não rotulado.

Um ponto de destaque no processo de classificação é que ele somente pode ser considerado quando o rótulo que se busca é categórico. Existem muitas aplicações para a tarefa de predição, nas quais a informação que buscamos não é uma categoria, mas sim um valor discreto ou contínuo. Nesses casos, a predição dos valores (rótulos) é feita a partir da tarefa de regressão.

Veja um exemplo de dados categóricos no vídeo a seguir.
Disponível em: https://youtu.be/dunCa_Z3pbw

A tarefa de regressão consiste em encontrar uma função preditiva, baseada nos atributos descritivos dos objetos no conjunto de treinamento, que possa retornar um valor para objetos não rotulados. Por exemplo, a partir de um conjunto de dados que descreve imóveis (casas ou assemelhados), no qual contamos com atributos descritivos como número de quartos, número de banheiros, área total construída, área do terreno, dentre outros possíveis, e o valor de mercado correspondente, queremos predizer o valor de outros imóveis que não possuem essa informação.

Para aprender mais ou recordar, sobre funções, seus tipos e características principais, assista ao vídeo a seguir. Disponível em: https://youtu.be/xpv-SWbDUr8

Nesta Unidade, serão analisados os modelos de regressão linear e não linear. Fundamentalmente, a diferença entre esses dois tipos de modelo está na função preditora, que pode ser uma função afim (linear) ou exponencial (não linear).

Nas próximas seções, exploraremos os conceitos e aplicações, na linguagem de programação R, dos dois tipos de modelos. Além disso, discutiremos sobre algumas características importantes que devem ser consideradas quando trabalhamos com modelos preditivos. Essas características abrangem estratégias de desenvolvimento e medidas de avaliação dos modelos.

Regressão Linear

Definições

A regressão linear é um tipo de análise estatística, na qual consideram-se duas variáveis: uma dependente, que pode ser o rótulo (y) que buscamos, e uma independente ou preditora, que, no nosso contexto, será representada por um conjunto de atributos descritivos ($\vec{x}$). Nesse contexto, o processo de regressão linear consiste em obter o valor de y (variável dependente) a partir de uma combinação linear de $\vec{x}$ (variáveis preditoras). Quando temos uma única variável preditora, o modelo de predição pode ser definido pela seguinte equação:

$$y = a + bx$$

em que y é a variável dependente, x é a variável preditora, a e b são coeficientes de regressão. Os coeficientes de regressão são responsáveis por indicar a interceptação do eixo y e a inclinação da reta, respectivamente.

A função resultante tem por objetivo fazer com que a reta se ajuste aos pontos que representam os objetos rotulados. Esse ajuste se dá quando a distância entre os pontos e a reta é a menor possível e é obtida por meio da escolha dos valores para os coeficientes de regressão.

A Figura 1 apresenta um diagrama que ilustra o processo de regressão. Nessa figura, os objetos de dados são distribuídos no espaço bidimensional a partir dos valores de suas respectivas variáveis (dependente e descritiva). Os coeficientes de regressão são definidos de modo que a soma dos erros entre os objetos e a reta seja mínima. Desse modo, a reta representa o padrão capturado a partir da distribuição dos objetos rotulados. Assim, dado o valor de uma variável descritiva, a função mapeia o valor da variável dependente para um objeto não rotulado.

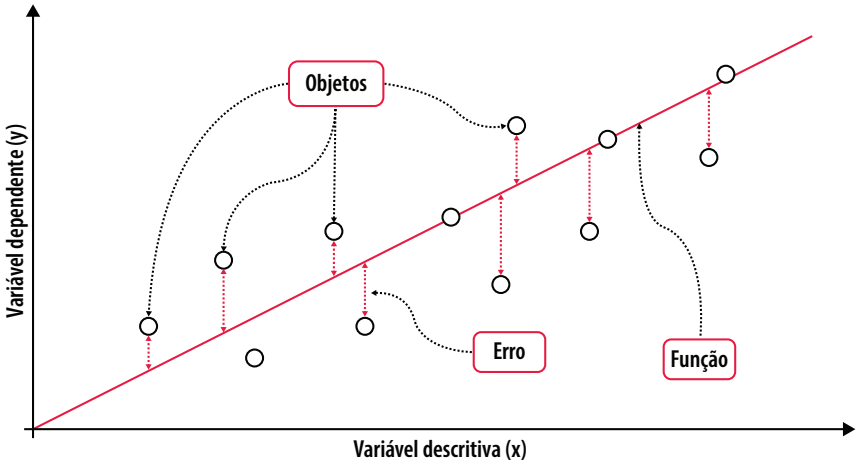


Figura 1 – Exemplo ilustrativo de ajustamento da reta aos objetos de dados no espaço bidimensional

Seja um conjunto de dados de treinamento descrito por $X_{tr} = \{(\vec{x}_i, y_i)\}$, com $i = [1,\ldots,n]$, o processo de estimação dos coeficientes de regressão é descrito da seguinte forma:

$$b = \frac{\sum_{i=1}^{n}(x_i - \mu)(y_i - \mu_y)}{\sum_{i=1}^{n}(x_i - \mu_x)^2}$$

$$a = \mu_y - b\mu_x$$

Em que μ_x é a média dos valores da variável descritiva x e μ_y é a média dos valores da variável dependente y. O algoritmo que descreve as etapas para a modelagem de regressão linear, usando o método dos mínimos quadrados, é descrito a seguir.



Aprenda mais sobre o método dos Mínimos Quadrados na videoaula disponível a partir do vídeo a seguir. Disponível em: https://youtu.be/zll0we-qfKM

Algoritmo 1: Modelagem de Regressão Linear

Entrada:

X_{tr}: conjunto de treinamento.

Saída:

a e b: coeficientes de regressão.

Etapas:

1. Calcular μ_x e μ_y;
2. Inicializar dois somadores, $s1, s2 = 0$;
3. Para cada $i \in X_{tr}$ faça:
   $s1 = s1 + (x_i - \mu_x)(y_i - \mu_y)$;
   $s2 = s2 + (x_i - \mu_x)$;
4. Fazer $b = s1 / s2$;
5. Fazer $a = \mu_y - b\mu_x$.

Fonte: Adaptado de DA SILVA *et al.*, 2017

Para ilustrar a implementação do algoritmo de regressão linear, considere os dados apresentados na Tabela 1. Suponha que o dono de um restaurante quer aumentar suas vendas de refeições, por meio da divulgação de anúncios na rádio local. Essa estratégia foi realizada por um intervalo de dez meses consecutivos, durante os quais o dono do restaurante registrou o número de anúncios vinculados na rádio e o respectivo total de refeições vendidas no mês.

Tabela 1 – Conjunto de dados de exemplo para o algoritmo de regressão linear

	ID	x_{i1}	y_i
	Período	Anúncios	Vendas
$\vec{x}_1$	1	30	430
$\vec{x}_2$	2	21	335
$\vec{x}_3$	3	38	520
$\vec{x}_4$	4	42	490
$\vec{x}_5$	5	37	470
$\vec{x}_6$	6	20	210
$\vec{x}_7$	7	8	195
$\vec{x}_8$	8	17	270
$\vec{x}_9$	9	35	400
$\vec{x}_{10}$	10	25	480

Fonte: Adaptado de DA SILVA *et al.*, 2017

Aplicações com a Linguagem *R*

Os dados apresentados na Tabela 1, representados no formato de um arquivo CSV serão considerados para a realização de um experimento envolvendo a obtenção de uma função linear e sua aplicação para a obtenção de um rótulo (número de vendas y_i) para um novo registro. Para isso, os dados foram importados para o *RStudio*. A Figura 2 ilustra essa importação.

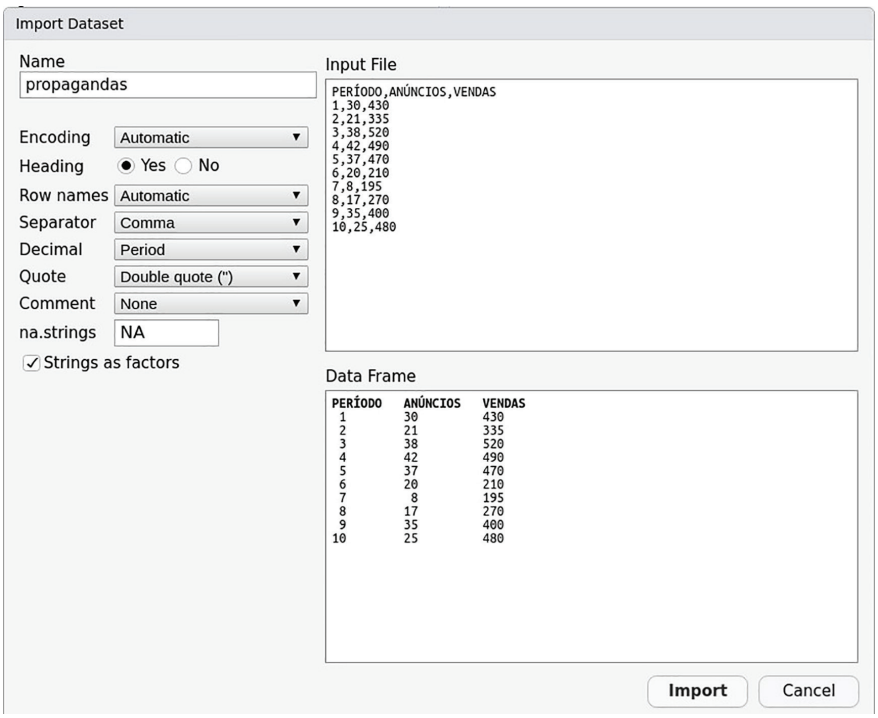


Figura 2 – Resultado da importação de um arquivo CSV (*Input File*) para o *RStudio*, transformando os dados em um *Data Frame*

Fonte: Reprodução

Apesar de, nesse exemplo, estarmos interessados em demonstrar a utilização do algoritmo de regressão linear, é importante uma observação mais atenta ao conjunto de dados para verificar qual tipo de regressão é a mais indicada a partir da distribuição dos dados no espaço bidimensional. Assim, utilizaremos a função `plot()`, que foi apresentada anteriormente, para que possamos visualizar a distribuição dos dados.

Para aprender mais sobre a função plot() leia a documentação disponibilizada no *link* a seguir. Disponível em: https://bit.ly/3tz4FNn

A criação do gráfico de dispersão no *RStudio*, considerando o identificador '`propagandas`' para o objeto de dados importado, pode ser feito da seguinte forma:

```
plot(propagandas[1:12,2:3])
```

De modo que sejam selecionadas as linhas de 1 até 12 e as colunas 2 e 3 para a plotagem do diagrama, o qual é apresentado na Figura 3.

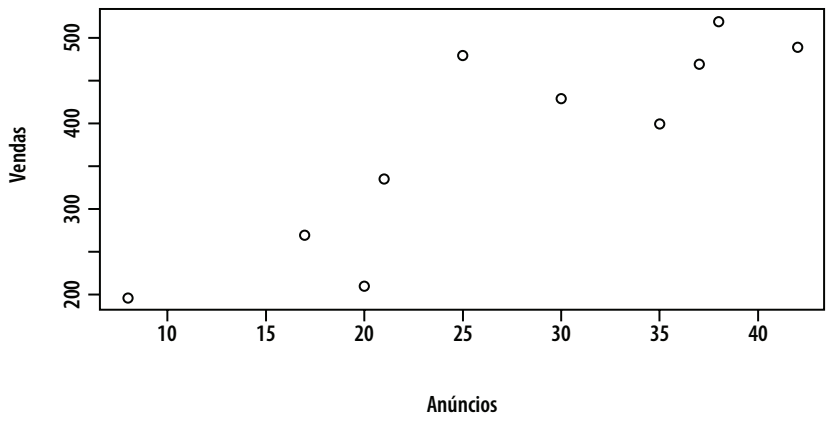


Figura 3 – Diagrama de dispersão, a partir da utilização da função plot()
Fonte: Reprodução

A função `lm()` implementa o algoritmo de regressão linear e é nativa do *R*, ou seja, não há a necessidade de importá-la. A função `lm()` recebe os seguintes parâmetros:

```
lm(fórmula, dados)
```

Sendo que:

- **Fórmula** é a descrição dos atributos (descritivos e rótulo) para a geração do modelo;
- **Dados** é o conjunto de treinamento.

O primeiro passo para a utilização da função `lm()` é a separação dos dados referentes às variáveis independente e dependente em dois objetos distintos. Nesse exemplo, vamos nomear os objetos com *x* e *y* que contêm os dados dos atributos descritivos e os rótulos, respectivamente. No *RStudio*, a criação dos objetos e a separação dos dados pode ser feita da seguinte forma:

- *x* ← `propagandas$ANÚNCIOS`;
- *y* ← `propagandas$VENDAS`.

Para a obtenção do modelo de regressão linear, consideraremos o uso da função `lm()`, de acordo com o seguinte exemplo:

```
modelo ← lm(y~x,propagandas)
```

Veja que é possível visualizar os coeficientes do modelo a partir da chamada ao modelo, considerando seu identificador. Essa chamada e o respectivo resultado são descritos a seguir.

```
> modelo

Call:
lm(formula = y ~ x, data = propagandas)

Coefficients:
(Intercept)            x
    117.38         9.62
```

O modelo apresentado pelo *RStudio* apresenta os valores dos coeficientes que compõem a equação da reta, a qual é utilizada para a predição de rótulos para objetos não rotulados.

Suponha que se queira saber qual será a previsão de vendas para um mês em que se realizaram 50 anúncios. Veja que não há, na base de dados, um mês com esse número de anúncios, porém podemos considerar o modelo obtido para a predição do volume de vendas nesse mês.

Anteriormente, discutimos sobre a utilização da função `predict()` para a predição a partir de um modelo previamente obtido. Nesse sentido, utilizaremos a mesma função para predizer o volume de vendas de um mês no qual foram realizados 50 anúncios. Se você tiver alguma dúvida a respeito da utilização da função `predict()`, sugiro que consulte o material didático antecedente.

O primeiro passo para a predição do novo rótulo é a criação de um objeto que possua o(s) valor(es) da(s) variável(eis) independente(s). Essa criação pode ser feita da seguinte forma:

```
teste ← data.frame(x=50)
```

O próximo passo consiste em realizar a predição a partir da função predict(), conforme descrito a seguir:

```
y_est ← predict(modelo,teste)
```

Veja que `y_est` é o objeto que contém o rótulo para o exemplar *teste*, cujo valor do atributo descritivo é igual a 50. A função `predict()` utiliza o modelo criado anteriormente para a obtenção do novo rótulo que, para esse exemplo, será igual a 598,37. Ou seja, de acordo com o padrão observado no conjunto de dados de treinamento, se o proprietário do restaurante realizar 50 anúncios em um determinado mês, a expectativa é que se obtenha a venda de 598 produtos.

Regressão não Linear

Definições

Existem casos em que as relações entre as variáveis dependente e independentes não podem ser representadas, de forma precisa, por uma função linear, ou seja, uma reta não é suficiente para capturar o padrão de relação entre as variáveis. Assim, consideram-se outros tipos de funções, não lineares, para a representação das relações.

A decisão sobre a utilização de regressão linear ou não linear pode ser tomada a partir da observação da distribuição dos dados. A visualização dos dados permite que se tenha uma intuição sobre o padrão das relações entre as variáveis e, assim, identificar um tipo de função que descreva melhor essas relações.

As principais funções não lineares que podemos considerar são exponencial, logarítmica e de potência. Uma característica importante dessas funções é que elas podem ser reduzidas a uma função linear por meio do ajuste de seus parâmetros.

Aplicações com a Linguagem *R*

Para ilustrar a aplicação da regressão não linear, consideraremos o mesmo exemplo anterior e, consequentemente, a mesma função `lm()`. Os passos iniciais são os mesmos, ou seja, a importação do conjunto de dados (arquivo CSV) e a separação dos objetos:

```
> x ← propagandas$ANÚNCIOS;
```

```
> y ← propagandas$VENDAS.
```

Neste exemplo, estamos considerando que o nosso modelo de regressão não linear se baseia na obtenção de uma função exponencial, cuja forma geral é descrita a seguir:

$$y = a \times e^{bx}$$

Podemos realizar ajustes para linearizar a função exponencial, a partir da aplicação do logaritmo em cada lado da equação, o que resulta na seguinte equação linear:

$$\ln y = \ln a + bx$$

Desse modo, consideramos a função `lm()`, da mesma forma que foi considerada para a regressão linear, com os parâmetros ajustados:

```
> modelo ← lm(log(y)~x,propagandas),
```

Esse modelo descreve os seguintes valores para os coeficientes ajustados:

```
> modelo

Call:
lm(formula = log(y) ~ x, data = propagandas)

Coefficients:
(Intercept)            x
     5.0973       0.0289
```

A utilização do modelo obtido também segue de forma similar ao exemplo anterior. A diferença aqui é referente à utilização da função exponencial (exp()) em ambos os coeficientes no momento da predição. No exemplo abaixo, o exemplar foi constituído com o valor de sua variável descritiva igual a 50, o que resultou em 697,4, que é a quantidade de vendas previstas a partir do modelo.

```
> exemplar <- data.frame(x=50)
> y_est <- exp(5.0973) * exp(0.029*exemplar)
> y_est
         x
1 697.3588
```

Modelos Preditivos

Estratégias de Desenvolvimento

No exemplo anterior, vimos que a visualização dos dados é importante para a decisão de qual estratégia de regressão será considerada. A visualização dos dados é importante, também, para identificar suas principais características e tendências. Essa exploração inicial busca realizar a descrição de algumas características importantes do conjunto de dados. Comumente, utilizam-se as medidas de posição e de dispersão como elementos caracterizadores dos dados.

As medidas de posição buscam representar a tendência de concentração dos dados. As principais medidas de posição são a média, a mediana, a moda, os percentis e os quatis. Por outro lado, as medidas de dispersão são aquelas que medem o grau de variação dos dados. As principais medidas de dispersão são a amplitude, a variância, o desvio padrão, conforme discutido em unidades anteriores.

Um experimento interessante, que ilustra como a estatística descritiva pode não descrever, isoladamente, as características de um conjunto de dados, é o chamado Quarteto de Anscombe. Trata-se de quatro conjuntos de dados, que foram construídos por Francis Anscombe, em 1973, que ilustram a importância da visualização dos dados antes de qualquer tipo de análise.

As estatísticas descritivas dos conjuntos de Anscombe são, praticamente, idênticas, no entanto, a observação da distribuição desses dados, no plano cartesiano, mostra uma distinção importante.

As quatro bases de dados (B1, B2, B3, B4), do Quarteto de Anscombe, são simples e contam com onze objetos (pontos de dados) e dois atributos (*X* e *Y*). A Tabela abaixo apresenta os resultados da média e da variância para esses conjuntos.

Tabela 2 – Medidas descritivas para os dados denominados de Quarteto de Anscombe

	B1	B2	B3	B4
Média (X)	9,000	9,000	9,000	9,000
Média (Y)	7,501	7,501	7,500	7,501

	B1	B2	B3	B4
Variância (X)	11,000	11,000	11,000	11,000
Variância (Y)	4,127	4,128	4,123	4,123

Fonte: Adaptada de ANSCOMBE, 1973

As medidas descritivas das bases de dados de Anscombe são muito similares e, em uma análise descuidada, poderiam levar a conclusões imprecisas. Além disso, a reta de regressão linear, para todas as bases, é $Y = 3,00 + 0,500X$, corroborando a similaridade dos conjuntos de dados.

O objetivo de Anscombe, ao propor os quatro conjuntos de dados, era ilustrar a importância da visualização dos dados, de forma gráfica, como parte da análise descritiva para conjuntos de dados e, também, mostrar que a utilização dos elementos básicos da análise descritiva é insuficiente para representar, com precisão, o comportamento de dados do mundo real. A Figura 4 apresenta os dados pertinentes ao Quarteto de Anscombe, distribuídos no plano cartesiano. Veja que as distribuições são muito distintas entre si, contrariando o que as medidas de análise descritiva básica demonstraram com seus resultados.

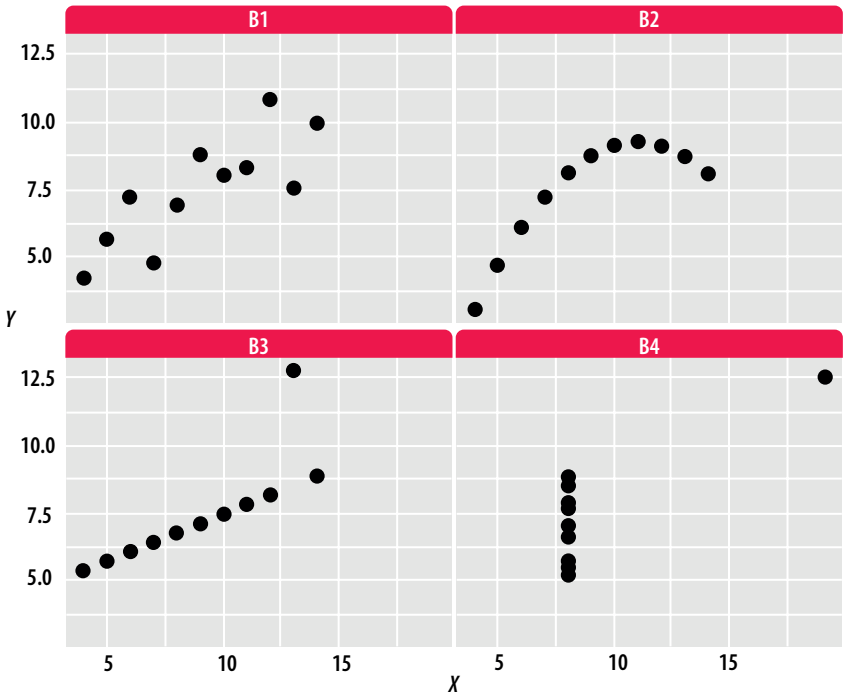


Figura 4 – Distribuição dos dados do Quarteto de Anscombe

A observação dos dados, na Figura 4, nos mostra o quão distintos são os conjuntos de dados. Veja que o objetivo aqui não é atribuir às medidas de posição e de dispersão qualquer tipo de crítica quanto à importância de sua utilização, mas sim considerar outras formas adicionais de análise descritiva, como a visualização dos dados, de modo a enriquecer a análise.

A avaliação da qualidade (assertividade) do modelo obtido não deve ser feita considerando os dados utilizados na etapa de treinamento. É sempre importante que o modelo seja testado com objetos que ele não conhece, ou seja, novos exemplares. Esse cuidado é importante pois podemos estar sujeitos a modelos muito ou pouco ajustados, que são fenômenos conhecidos como *overfitting* e *underfitting*, respectivamente.

O ajustamento da curva aos dados é uma questão importante que deve ser observada. Veja o exemplo na Figura 5a, ela apresenta um modelo com um ajuste ideal aos dados. Por outro lado, um ajuste extremo da curva da função aos dados também representa um problema. Veja o exemplo na Figura 5b, ela está perfeitamente ajustada a cada ponto de dado. Dessa forma, a predição de um valor desconhecido será comprometida, visto que a curva não captura a tendência dos dados. Esse fenômeno de muito ajuste da curva aos dados é chamado de *overfitting*.

Note que, nos exemplos apresentado na Figura 5, há diferenças quanto aos erros de generalização. Um modelo muito ajustado aos dados de treinamento tende a rotular novos exemplares com um erro de generalização maior. Para lidar com esse tipo de problema, podemos utilizar diferentes estratégias, como descrito a seguir.

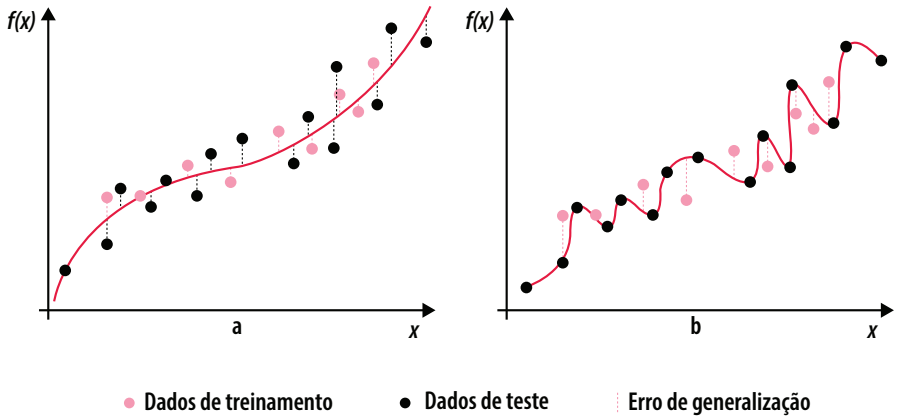


Figura 5 – Exemplos de modelos preditivos: com *overfitting* (b) e sem *overfitting* (a)
Fonte: Adaptada de DA SILVA *et al.*, 2017

Medidas de Avaliação

As tarefas preditivas são consideradas para prever um rótulo de acordo com um conjunto de características. Quando temos uma predição discreta, na qual estamos interessados em uma ou mais classes, dizemos que a tarefa é de classificação. Por outro lado, quando a predição é contínua, e estamos interessados em predizer um determinado valor, dizemos que a predição é denominada estimação.

O processo de predição apresenta duas etapas principais. Na primeira etapa, denominada treinamento, utilizamos uma parte dos dados de um conjunto (a maior parte deles) para gerar um modelo preditor que seja capaz de inferir uma classe ou um valor a partir das características dos dados. A segunda etapa, denominada teste, consiste em aplicar o modelo obtido à parte não utilizada dos dados. O objetivo aqui é verificar a capacidade de generalização do modelo, no sentido de predizer a classe ou o valor de dados que não foram utilizados para a obtenção do preditor.

O processo de predição, de classes ou valores, considera quatro etapas principais. A primeira etapa é a etapa de pré-processamento, que consiste em preparar a base de dados. A segunda etapa é a separação do conjunto de dados entre conjunto de treinamento e conjunto de teste. Como mencionado anteriormente, a maior parte dos dados será utilizada como conjunto de treinamento e a parte restante será o conjunto de teste.

Para o caso em que todos os dados possuem rótulo, utiliza-se algum método de seleção dos dados para treinamento do modelo. Caso haja parte dos dados não rotulados, os dados que possuem rótulo devem ser utilizados para o treinamento e a outra parte será rotulada pelo modelo.

Veja que, para os casos anteriores, utilizar um conjunto de dados rotulados como conjunto de teste nos permite estimar a eficiência do modelo, por meio da comparação entre os rótulos que são resultado da predição e os rótulos originais. Por outro lado, o uso de um conjunto não rotulado como conjunto de teste não permite que a acurácia do modelo seja verificada, havendo, assim, a necessidade de se utilizar outro método para a verificação do modelo.

As etapas de treinamento e teste consistem em realizar o ajuste dos parâmetros do modelo, os quais vão variar de acordo com o tipo de técnica escolhida, de modo a melhorar a sua capacidade preditiva.

Finalmente, a avaliação da saída é a última etapa. O processo de predição é baseado em estimativas e, consequentemente, pode apresentar algum grau de imprecisão. O desempenho de um classificador depende de sua flexibilidade e da qualidade do treinamento. Nesse sentido, a utilização de medidas de avaliação de desempenho, em geral, tem por objetivo medir a taxa de acerto dos classificadores.

Os problemas de classificação binária, ou seja, aqueles que fazem a inferência entre duas classes podem ser avaliados por meio de medidas específicas que consideram a relação entre a classe alvo, que descreve a classe esperada e é denominada de classe positiva, e a classe negativa. Nesse sentido, podemos ter como resultado: verdadeiro positivo, verdadeiro negativo, falso positivo e falso negativo.

No verdadeiro positivo (VP), um objeto da classe positiva é classificado como pertencente à classe positiva. Por outro lado, para o verdadeiro negativo (VN), um objeto da classe negativa é classificado como tal. Já o falso positivo (FP) ocorre quando um objeto da classe negativa é classificado como pertencente à classe positiva. Finalmente, um falso negativo (FN) ocorre quando um objeto da classe positiva é classificado como negativo. Essa forma de avaliação de desempenho pode ser aplicada facilmente com a utilização de uma matriz de confusão. Veja a Tabela 3, que descreve a estrutura desse tipo de matriz.

Os valores contabilizados para cada caso, descritos anteriormente, são tabulados nas respectivas células na matriz de confusão. Nesse sentido, é possível extrair duas importantes taxas, baseadas nos valores contabilizados, são elas a taxa de verdadeiros positivos (TVP) e a taxa de falsos positivos (TFP).

Tabela 3 – Matriz de confusão para um problema de classificação binária

		Classe predita	
		Positiva	**Negativa**
Classe original	**Positiva**	VP	FN
	Negativa	FP	VN

Fonte: Adaptada de CASTRO *et al.*, 2016

A taxa de verdadeiros positivos descreve a porcentagem de objetos positivos que foram classificados como tal, ou seja, o modelo classificou corretamente os objetos contabilizados nesse caso. O cálculo da TVP é intuitivo e segue de acordo com a seguinte fórmula:

$$TVP = \frac{VP}{VP + FN}$$

A taxa de falsos positivos corresponde à porcentagem de objetos negativos que foram classificados como positivos, nesse caso, o classificador falhou em atribuir a classe correta aos objetos analisados. O cálculo da TFP é feito da seguinte forma:

$$TFP = \frac{FP}{FP + VN}$$

Outra taxa importante para a verificação da acurácia dos classificadores binários é a taxa global de sucesso, ou simplesmente acurácia (ACC). A ACC é o quociente da soma dos verdadeiros positivos e verdadeiros negativos pela soma dos verdadeiros positivos, falsos positivos, verdadeiros negativos e falsos negativos. Em outras palavras, a ACC é a quantidade de acertos dividida pelo total de possibilidades e pode ser representada da seguinte maneira:

$$ACC = \frac{VP + VN}{VP + FP + VN + FN}$$

De modo oposto ao que representa a ACC, a taxa de erro de um classificador descreve o percentual de classificações erradas que foram realizadas por ele, nesse sentido, o cálculo da taxa de erro (E) é feito da seguinte forma:

$$E = 1 - ACC$$

Material Complementar

Indicações para saber mais sobre os assuntos abordados nesta Unidade:

Vídeos

Coeficiente de Correlação Linear
https://youtu.be/ayAxTRN4aVg

Regressão Linear Simples
https://youtu.be/qft6BI7KUwg

Tipos de Funções
https://youtu.be/6-Lw05u0skM

Regressão não Linear no *R*
https://youtu.be/DYoLq7UH-SA

Referências

ANSCOMBE, F. J. *Graphs in statistical analysis*. ***The american statistician***, v. 27, n. 1, p. 17-21, 1973.

BECKER, J. L. **Estatística básica:** transformando dados em informação. Porto Alegre Bookman 2015. (*e-book*)

CASTRO, L. N.; FERRARI, D. G. **Introdução à mineração de dados:** conceitos básicos, algoritmos e aplicações. São Paulo: Saraiva, 2016.

SILVA, L. A.; PERES, S. M.; BOSCARIOLI, C. **Introdução à mineração de dados:** com aplicações em R. Elsevier Brasil, 2017.

LIMA, M. F. W. P. **Introdução a *Big Data* e *Internet* das Coisas**. Porto Alegre: SAGAH, 2018.

LORENA, A. C.; FARIA, F. A. **Representação do Conhecimento – Lidando com incerteza**. Notas de aula. UNIFESP (São Paulo), 2015.

ROSSI, L. **Técnicas para converter dados em conhecimento**. São Paulo: Universidade Cruzeiro do Sul, 2021.


Cruzeiro do Sul
Educacional