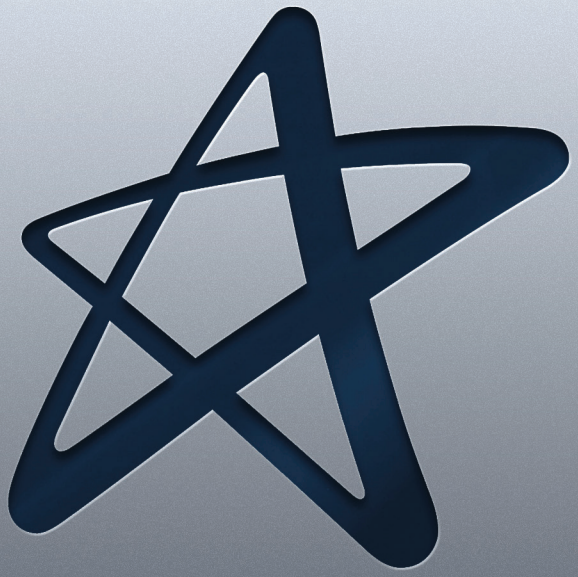
Ciência de Dados e Aprendizagem de Máquina



Cruzeiro do Sul Virtual
Educação a distância

Análise Descritiva

Responsável pelo Conteúdo:
Prof. Dr. Luciano Rossi

Revisão Textual:
Prof. Me. Claudio Brites

UNIDADE Análise Descritiva

- Conceito de Agrupamento;
- Agrupamento Hierárquico;
- Agrupamento por Partição;
- Agrupamento por Densidade.



OBJETIVO DE APRENDIZADO

- Analisar as principais características da tarefa de agrupamento, por meio da definição de alguns de seus principais algoritmos com a respectiva aplicação prática.

Orientações de estudo

Para que o conteúdo desta Disciplina seja bem aproveitado e haja maior aplicabilidade na sua formação acadêmica e atuação profissional, siga algumas recomendações básicas:



Assim:

- ✓ Organize seus estudos de maneira que passem a fazer parte da sua rotina. Por exemplo, você poderá determinar um dia e horário fixos como seu "momento do estudo";
- ✓ Procure se alimentar e se hidratar quando for estudar; lembre-se de que uma alimentação saudável pode proporcionar melhor aproveitamento do estudo;
- ✓ No material de cada Unidade, há leituras indicadas e, entre elas, artigos científicos, livros, vídeos e *sites* para aprofundar os conhecimentos adquiridos ao longo da Unidade. Além disso, você também encontrará sugestões de conteúdo extra no item **Material Complementar**, que ampliarão sua interpretação e auxiliarão no pleno entendimento dos temas abordados;
- ✓ Após o contato com o conteúdo proposto, participe dos debates mediados em fóruns de discussão, pois irão auxiliar a verificar o quanto você absorveu de conhecimento, além de propiciar o contato com seus colegas e tutores, o que se apresenta como rico espaço de troca de ideias e de aprendizagem.

Conceito de Agrupamento

A tarefa de agrupamento é considerada uma tarefa descritiva, cujo objetivo é a descoberta de relações entre os objetos pertinentes a um conjunto de dados. Uma diferença importante, se compararmos as tarefas de classificação e de agrupamento, é a ausência de rótulo (atributo de classe) nos objetos considerados para a tarefa de classificação. Assim, os objetos no conjunto de dados não apresentam pertinência a nenhuma categoria explícita, ficando a cargo da tarefa de agrupamento a reunião dos objetos que são similares em grupos com a maior homogeneidade possível.

A similaridade entre os objetos é verificada por meio de seus atributos descritivos. Os valores dos atributos são utilizados para calcular a distância existente entre os objetos. Assim, medidas de distância, ou similaridade, têm papel fundamental na identificação de agrupamentos. A Figura 1 apresenta um exemplo de distância entre dois objetos no espaço bidimensional.

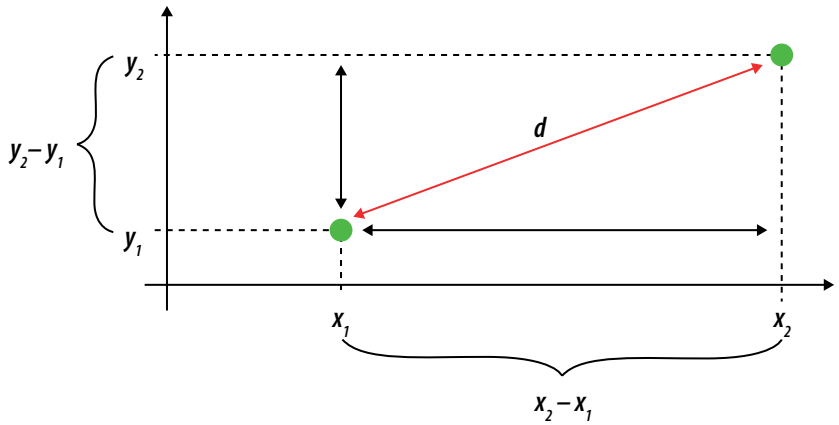


Figura 1 – Diagrama ilustrativo do cálculo da distância Euclidiana

Suponha dois objetos, identificados como 1 e 2, com dois atributos descritivos, identificados pelas variáveis x e y. A distância Euclidiana é uma medida que pode ser utilizada para a verificação de similaridade entre os objetos, sendo definida da seguinte forma:

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)}$$

Em que: d é o valor calculado para a distância entre os objetos 1 e 2, a coordenada (x_1, y_1) é composta pelos valores dos atributos descritivos para o objeto 1 e a coordenada (x_2, y_2) é composta pelos valores dos atributos descritivos para o objeto 2. Assim, quanto maior o valor de d, tanto maior é a distância entre os objetos.

Para conhecer mais sobre o conceito de agrupamento, leia o artigo "**Algoritmos de agrupamento e o seu significado na aprendizagem de máquinas**".
Disponível em: https://bit.ly/3gckSlg

O objetivo da tarefa de agrupamento é a obtenção de uma estrutura de grupos em que a similaridade intragrupos seja maximizada e a similaridade intergrupos seja minimizada. Na Figura 2A, os agrupamentos obtidos apresentam alta similaridade entre os objetos nos grupos e baixa similaridade entre os grupos, característica que é considerada ideal. Por outro lado, na Figura 2B, a similaridade entre os objetos nos grupos é baixa, enquanto a similaridade entre os grupos é alta, característica indesejável como resultado da tarefa de agrupamento.

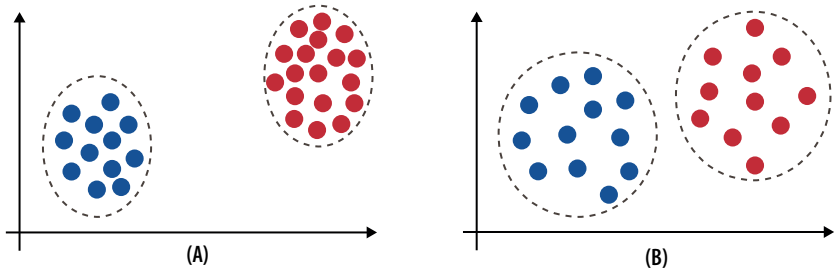


Figura 2

Exemplos de agrupamento com alta similaridade intragrupos e baixa similaridade intergrupos. (A) e de agrupamento com baixa similaridade intragrupos e alta similaridade intergrupos (B) O exemplo (A) descreve uma condição ideal.

Para a tarefa de agrupamento, o modelo de grupos gerado é uma solução. Nessa solução, os grupos agregam objetos que são similares entre si, constituindo categorias de semântica ignorada, ou seja, não se sabe qual(is) característica(s) agregam os objetos nos grupos. Uma análise posterior, em cada grupo obtido, pode desvendar as características dos grupos, possibilitando melhor explicação a respeito da composição dos grupos e facilitando a aplicação do modelo.

A partir da obtenção do modelo de grupos, pode-se utilizar esse conhecimento para a caracterização de novos objetos, identificando o grupo ao qual eles pertencem, em função de seus atributos descritos, como é feito na tarefa de classificação.

A tarefa de detecção de agrupamentos considera um conjunto de etapas que descrevem esse processo. A primeira etapa é a seleção de atributos, na qual consideramos o contexto da análise para identificar os melhores atributos. Outras características a serem observadas aqui são a quantidade de informação que será codificada pelos atributos e a redundância entre eles, a qual deve ser a menor possível.

A segunda etapa consiste na escolha da medida de similaridade que será utilizada. Essas medidas têm por objetivo quantificar o quão similar ou dissimilar dois objetos são, de acordo com suas características (atributos). O ideal é que haja um equilíbrio na contribuição dos atributos no cálculo da medida. Outro ponto a ser considerado é a utilização de algum processo de normalização dos dados, de modo que não haja um atributo mais dominante que outro.

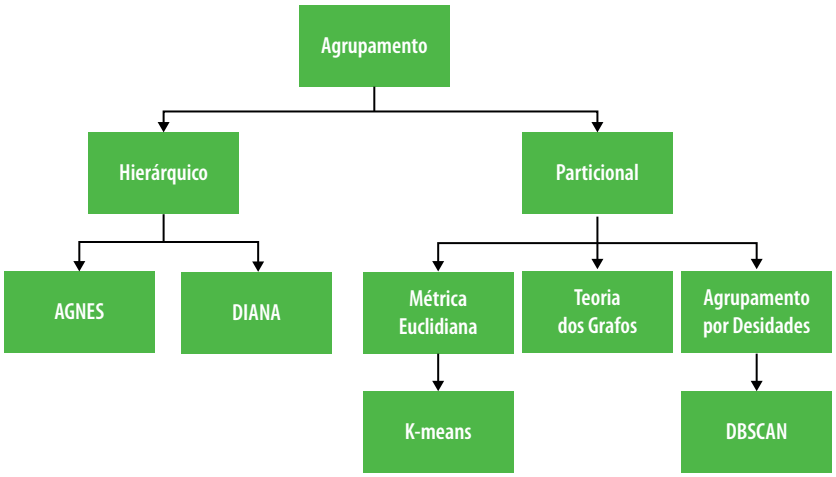


Figura 3 – Taxonomia para a tarefa de agrupamento

O terceiro passo é a definição do critério de agrupamento. Aqui será definida a sensibilidade do agrupamento de acordo com o tipo de grupo que se espera. Assim, podemos ter grupos do tipo compacto, alongado ou esféricos, dentre outros tipos possíveis. Essa definição juntamente com a definição da medida de similaridade serão a base para a escolha do algoritmo de agrupamento, que constitui o quarto passo.

Os quinto e sexto passos são, respectivamente, a validação dos resultados, que avalia por meio de testes a correção do que foi obtido, e a interpretação dos resultados, a qual é feita, em geral, em conjunto com outras técnicas.

A Figura 3 descreve a taxonomia de técnicas de detecção de agrupamentos. Essa categorização é baseada nas descrições realizadas pelos professores Moscato e Von Zuben (Unicamp) em suas notas de aula sobre análise de dados em bioinformática. Essa taxonomia é útil para nortear as decisões a respeito das técnicas que devem ser adotadas e a posterior seleção do melhor algoritmo que atenda aos objetivos pretendidos.

Nas seções posteriores, serão discutidos os principais tipos de agrupamento, considerando um exemplo de algoritmo para cada tipo e uma aplicação prática na linguagem de programação *R*.

Agrupamento Hierárquico

Definições

O agrupamento hierárquico consiste na divisão hierárquica dos objetos em grupos. Há duas abordagens principais para esse tipo de agrupamento. A primeira abordagem considera uma estratégia divisiva (*top-down*) e pode ser implementada pelo método *DIANA* (***Di****visive* ***Ana****lysis*). A segunda abordagem considera uma estratégia aglomerativa (*botton-up*) e pode ser implementada pelo método *AGNES* (***A*** ***G****lomerative* ***Nes****ting*).

Ambas as abordagens objetivam a obtenção de uma árvore, ou mais especificamente um dendrograma, na qual os níveis representam uma organização dos dados em grupos. Veja, na Figura 4, uma ilustração das duas abordagens de agrupamento hierárquico.

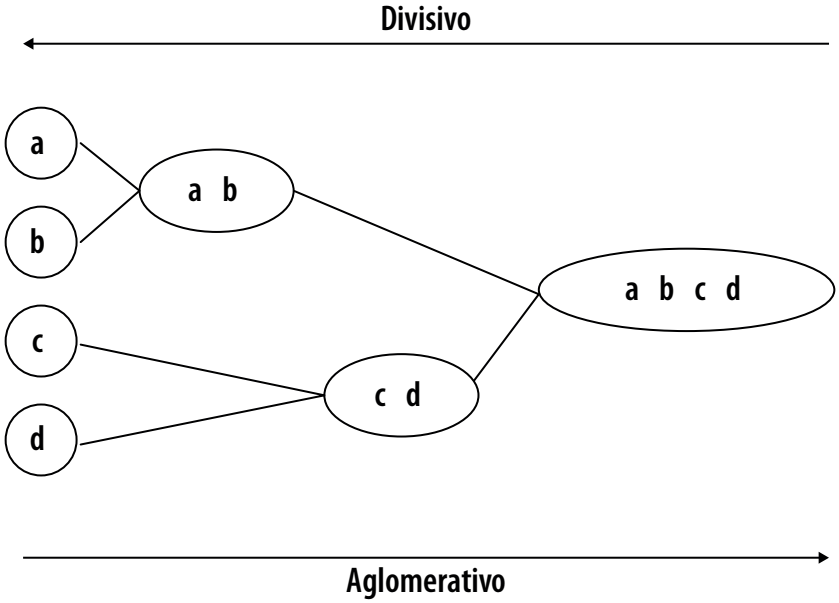


Figura 4 – Exemplo ilustrativo das abordagens divisiva e aglomerativa para a tarefa de agrupamento hierárquico
Fonte: Adaptada de SILVA, *et al.*, 2017

Para ilustrar o funcionamento da tarefa de agrupamento hierárquico, consideraremos a abordagem AGNES. O algoritmo que apresenta os passos para a implementação dessa abordagem é descrito a seguir.

Algoritmo 1: Agrupamento hierárquico aglomerativo – método AGNES
Entrada:
$\mathbf{X}_{tr}$: conjunto de treinamento
dist: medida de distância
Abordagem para o cálculo de distância entre grupos
Saída:
$\mathbf{D}$: dendrograma representando o modelo de agrupamento.
Etapas:
1. Calcular a matriz de similaridade (MS);
2. Alocar cada objeto $\vec{\mathbf{x}}_i \in \mathbf{X}_{tr}$ em grupos distintos;
3. Enquanto houver possibilidade de aglomerar grupos:
   Verifique as distâncias entre todos os pares de grupos;
   Aglomere o par de grupos mais similar.

Fonte: Adaptado de SILVA, *et al.*, 2017

O algoritmo descrito anteriormente será aplicado a um conjunto de dados que descreve o perfil de clientes de um restaurante. Nesse conjunto, temos, além de um identificador

(ID) para cada cliente, a média de visitas que o cliente fez ao restaurante (**Frequência**), o valor médio consumido em um mês pelo cliente (**Consumo**) e a forma de pagamento, sendo que o código "1" descreve o pagamento com cartão de crédito e o código "2" o pagamento com cartão de débito.

Para saber mais sobre o agrupamento hierárquico leia o artigo "**Agrupamento Hierárquico: Como agrupar dados usando esse algoritmo?**". Disponível em: https://bit.ly/34a5Hq7

O objetivo é identificar grupos de clientes similares, de acordo com os atributos descritivos. A Tabela 1 e 2 apresenta esse conjunto de dados em duas configurações; primeiro, em (Tabela 1), o conjunto de dados original e, em (Tabela 2), o conjunto de dados normalizado. Note que a frequência e o consumo foram normalizados para o intervalo [0,1], sendo os valores absolutos normalizados para fatores proporcionais no intervalo considerado. O atributo pagamento foi padronizado para valores binários (0 ou 1).

Tabela 1 – Conjunto de Dados Considerado para Experimentação com a Linguagem de Programação *R*. Corresponde ao Conjunto Original

	ID	Frequência	Consumo	Pagamento
1	Cli1	3	120,5	1
2	Cli2	3	130,0	1
3	Cli3	4	150,8	1
4	Cli4	2	75,6	2
5	Cli5	3	88,5	2
6	Cli6	1	58,8	2

Fonte: Adaptada de SILVA, et al., 2017

Tabela 2 – Conjunto de Dados Considerado para Experimentação com a Linguagem de Programação *R*. Conjunto Normalizado

	ID	FREQnorm	CONSnorm	PAGcod
1	Cli1	0,67	0,67	0
2	Cli2	0,67	0,77	0
3	Cli3	1,00	1,00	0
4	Cli4	0,33	0,18	1
5	Cli5	0,67	0,32	1
6	Cli6	0,00	0,00	1

Fonte: Adaptada de SILVA, et al., 2017

Aplicações com a Linguagem *R*

O agrupamento aglomerativo é realizado em duas etapas principais. Primeiro é calculada a matriz de similaridade. Para essa tarefa podemos utilizar a função `dist()` disponível a partir do pacote `stats` da linguagem *R*. A função `dist()` pode ser considerada da seguinte forma:

```
ms <- dist(dados1_norm, method = "manhattan")
```

sendo `ms` o objeto que representa a matriz resultante, dados1_norm os dados normalizados e `method` a medida de distância que será utilizada. O método pode ser: "*euclidean*", "*maximum*", "*manhattan*", "*canberra*", "*binary*" ou "*minkowski*".

O segundo passo consiste na construção da hierarquia a partir da utilização da função `hclust()`, da seguinte forma:

```
agrupamento <- hclust(ms, method = "single")
```

sendo agrupamento a hierarquia resultante, `ms` a matriz de similaridade e `method` a abordagem utilizada para calcular a distância, que pode ser:

- ***single:*** menor distância;
- ***complete:*** maior distância;
- ***average:*** distância média.

Para visualizar a hierarquia de agrupamentos, que é representada por um dendrograma, podemos utilizar a função `plot()` da seguinte forma:

```
plot(agrupamento, main = "Agrupamento Hierarquico Aglomerativo", xlab = "Clientes", ylab = "Distância")
```

sendo agrupamento a hierarquia obtida e `main`, `xlab` e `ylab` correspondentes ao título do gráfico, rótulo do eixo horizontal e rótulo do eixo vertical, respectivamente.

O resultado da análise de agrupamento pelo método aglomerativo, considerando as etapas descritas, é apresentado na Figura 5.



Figura 5 – Agrupamento Hierárquico Aglomerativo. Dendrograma resultante da análise de agrupamento aglomerativo para o conjunto de dados das Tabelas 1 e 2
Fonte: Adaptada de SILVA, 2017

A estrutura, em forma de árvore, apresentada na Figura 5 é denominada dendrograma. Os números na parte inferior do dendrograma representam os objetos do conjunto de dados. Note que os objetos são interligados por meio de um segmento de reta vertical. O eixo vertical representa os valores de distância entre os objetos. Uma projeção a partir de um valor de distância interceptará alguns segmentos de reta que conectam os objetos, definindo o número de grupos e sua respectiva composição.

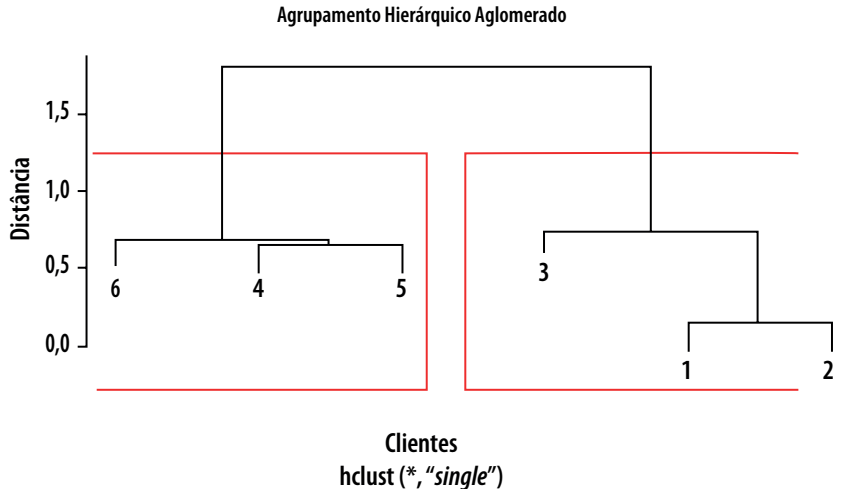


Figura 6 – Dendrograma resultante da análise de agrupamento aglomerativo para o conjunto de dados das Tabelas 1 e 2 com o destaque para a formação de dois grupos
Fonte: Adaptada de da SILVA *et al.*, 2017

A visualização dos grupos, a partir do *RStudio*, pode ser feita por meio da função `rect.hcluster()`. Essa função recebe, como parâmetros de entrada, um objeto que representa o modelo de grupos, um valor (*k*) que define o número de grupos desejado e uma cor para as bordas do agrupamento. Veja um exemplo do uso da função

```
rect.hcluster(): rect.hclust(agrupamento, k = 2, border = "red").
```

Essa chamada da função retornará o seguinte modelo com dois grupos. O primeiro contendo os objetos 6, 4 e 5 e o segundo com os objetos 3, 1 e 2, conforme apresentado na Figura 6.

Agrupamento por Partição

Definições

O agrupamento por partições tem por objetivo encontrar partições no conjunto de dados de forma que se tenha *k* grupos de objetos similares ao final do processo. A similaridade entre os objetos é considerada por meio de alguma medida de distância.

O algoritmo mais utilizado para essa tarefa de mineração de dados é o algoritmo *k*-médias ou *k-means*. O processo associado ao *k*-médias parte da definição, de forma aleatória, de *k* centroides que representam os grupos que se pretende obter. Os objetos do conjunto de dados são associados ao centroide mais próximo. Após essa etapa, os centroides são recalculados e o processo se repete, até que não haja movimentação dos centroides entre uma iteração e outra.

Seja $X_{tr} = \{x_1, x_2, \ldots, x_n\}$ o conjunto dos dados que serão agrupados em um dos k grupos $C_1, C_2, \ldots, C_k$, com $k < n$. Considere ainda μ_i como a média dos objetos no grupo C_i e d como uma medida de distância. O objeto x_p pertence ao grupo C_i se

$d\left(x_p, \mu_i\right)$ for menor que todas as $k-1$ distâncias entre x_p e μ_j, com $j=1,2,\ldots,k$ e $i \neq j$. Nesse contexto, o algoritmo *k*-médias descreve o seguinte:

Algoritmo 2: Agrupamento Particional – *k*-média

Entrada:

- X_{tr}: conjunto de treinamento;
- k: número de partições ou grupos a serem identificados;
- dist: medida de distância.

Saída:

Um vetor de grupos C_i com $i=1\ldots k$

Etapas:

1. Sugerir k centros iniciais $\grave{\imath}_1, \grave{\imath}_2, \ldots, \grave{\imath}_k$;
2. Enquanto as médias se alterarem faça:
   Para $i=1$ até n faça:
   Inserir x_i no grupo C_i com média $\grave{\imath}_i$ mais semelhante;
   Para $i=1$ até k faça:
   Substituir $\grave{\imath}_i$ pela média dos objetos em C_i.

Fonte: Adaptada de SILVA *et al.*, 2017

O algoritmo *k*-médias assume valores iniciais aleatórios para cada uma das *k* médias que serão consideradas. Em seguida, os objetos serão distribuídos entre os grupos que são representados pelas médias, considerando o grupo cuja média seja mais similar ao objeto. Após a distribuição de todos os objetos, a média entre eles é calculada para cada grupo e ela substituirá o valor anterior. Feito isso, todos os objetos serão novamente distribuídos, considerando a nova média de cada grupo. Quando o valor calculado da média for igual ao valor anterior, o algoritmo finaliza.

Conheça a biblioteca ***"sklearn.cluster.KMeans"***, que implementa o algoritmo *k*-médias. Disponível em: https://bit.ly/3HjF0Th

A Figura 7 apresenta um exemplo da execução do algoritmo *k*-médias. O primeiro passo é a seleção de *k* objetos, de forma aleatória, os quais representarão os centroides iniciais. No caso desse exemplo, o objetivo é obter $k=3$ grupos. A Figura 7B apresenta os objetos selecionados como centroides iniciais. Nessa etapa, os centroides são objetos selecionados aleatoriamente, porém, nos passos seguintes, os centroides podem ser um ponto no espaço que não representa, necessariamente, um objeto. Veja que os grupos são destacados nas cores azul, verde e vermelha.

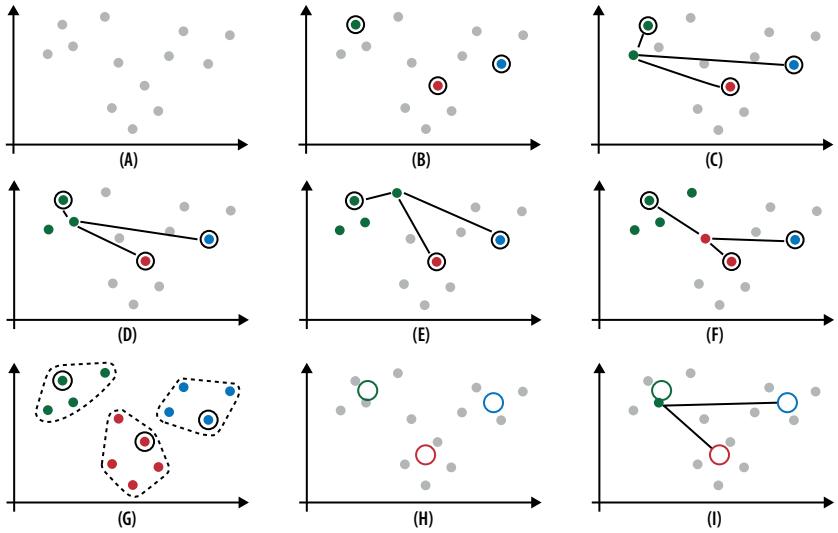


Figura 7 – Exemplo de agrupamento por partição pelo algoritmo *k*-médias
Fonte: Adaptada de FARIA, 2015

Após a definição dos centroides, cada objeto será associado ao centroide mais próximo. Veja que, na Figura 7C, o objeto selecionado está mais próximo do centroide verde, assim, ele é associado a esse grupo. Os dois próximos objetos selecionados, nas Figuras 7D e 7E, também têm uma distância menor em relação ao centroide verde, ao qual eles serão associados. O objeto selecionado, na Figura 7F, é mais próximo ao centroide vermelho, ao qual ele será associado.

O processo descrito será repetido para todos os objetos pertinentes ao conjunto. Ao final dessa etapa, teremos a formação dos grupos, a partir da associação aos centroides. Veja na Figura 7G o estado final após a finalização dessa etapa.

Aplicações com a Linguagem *R*

Para aplicarmos o algoritmo *k*-médias, utilizando o *RStudio*, vamos considerar um conjunto de dados no qual os objetos representam a experiência de um cliente em uma visita a um restaurante. O conjunto de dados consiste nos seguintes atributos:

- **ID:** um identificador exclusivo para o atendimento;
- **Tempo:** tempo de espera pela refeição;
- **Qualidade:** nota atribuída pelo cliente à refeição.

O objetivo da aplicação do algoritmo k-médias é identificar o perfil dos atendimentos. A Tabela 3 apresenta o nosso conjunto de dados já normalizado.

Tabela 3 – Conjunto de Dados Considerado para Experimentação com a Linguagem de Programação *R*

	ID	Tempo	Qualidade
1	Atend1	0,0	0,57
2	Atend2	0,5	0,43
3	Atend3	1,0	0,00
4	Atend4	0,5	0,86

	ID	Tempo	Qualidade
5	Atend5	1,0	1,00
6	Atend6	1,0	0,57

Fonte: Adaptada de da SILVA *et al.*, 2017

O algoritmo *k-means* pode ser aplicado por meio da função `kmeans()` disponibilizada pelo *RStudio*. Essa função recebe, como parâmetros de entrada, o conjunto de dados normalizado e estruturado na forma de um `data-frame`, um número que determina o número de grupos que serão obtidos e um número máximo de iterações. Veja que é possível que o algoritmo entre em *looping* em determinadas condições, desse modo, o parâmetro referente ao número máximo de iterações garante que o algoritmo irá finalizar, em qualquer situação.

A utilização da função `kmeans()` pode ser feita de acordo com o seguinte exemplo:

```
grupos <- kmeans(dados, 2, iter.max = 5).
```

O objeto grupos contém o modelo de agrupamento, o qual pode ter seus parâmetros consultados a partir da chamada ao próprio objeto. O nosso exemplo de modelo de agrupamento tem os parâmetros descritos na Figura 8.

Name	Type	Value
grupos	list [9] (S3: kmeans)	List of length 9
cluster	integer [6]	1 1 2 1 2 2
centers	double [2 x 2]	0.333 1.000 0.620 0.523
totss	double [1]	1.446817
withinss	double [2]	0.263 0.503
tot.withinss	double [1]	0.7661333
betweenss	double [1]	0.6806833
size	integer [2]	3 3
iter	integer [1]	1
ifault	integer [1]	0

Figura 8 – Parâmetros do modelo de agrupamento resultante da aplicação do algoritmo *k*-média ao conjunto de dados da Tabela 3
Fonte: Adaptada de SILVA, *et al.*, 2017

Dentre as informações descritas para o modelo de agrupamento, podemos destacar a pertinência dos objetos a cada grupo (primeiro parâmetro da Figura 8), o centroide de cada grupo, representado por um par de valores que definem uma coordenada no espaço bidimensional (segundo parâmetro), o número de objetos em cada grupo (sétimo parâmetro), dentre outros.

Uma forma mais visual de se verificar o resultado da aplicação do algoritmo *k*-médias é a partir de uma representação gráfica. Nesse sentido, podemos considerar a função `plot()` para visualizar a distribuição dos objetos no espaço e colorir os objetos de acordo com o grupo ao qual pertencem. A função `plot()` é considerada juntamente com os parâmetros descritos a seguir:

```
plot(dados, col = grupos$cluster+1, main="K-Means result with 2 clusters",
pch=20, cex=2),
```

em que `dados` é o modelo de grupos obtido, `col = grupos$cluster+1` é a identificação de qual atributo do modelo será utilizado para colorir os objetos, `main` é o título do gráfico, `pch` é referente ao símbolo que representa o objeto e `cex` é o tamanho do símbolo. Assim, a representação gráfica resultante é apresentada na Figura 9, na qual os pontos vermelhos e verdes definem a pertinência do objeto ao respectivo grupo.

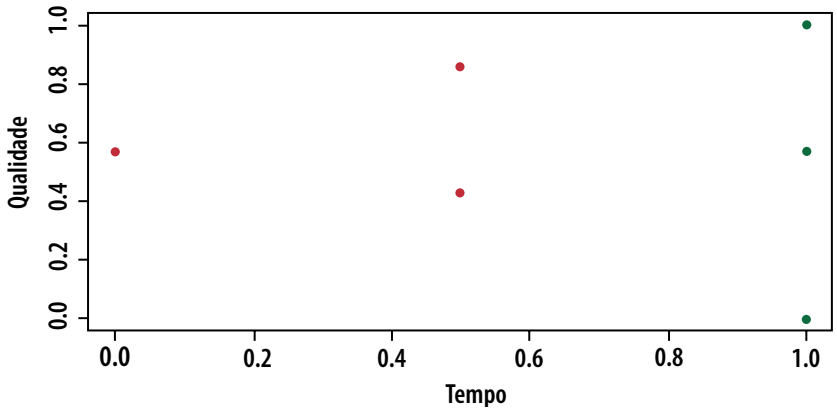


Figura 9 – Representação gráfica do agrupamento dos objetos resultante da aplicação do algoritmo *k*-média ao conjunto de dados da Tabela 3
Fonte: Adaptada de SILVA *et al.*, 2017

Agrupamento por Densidade

Definições

O agrupamento por densidade é especialmente útil para a aplicação em conjuntos de dados que contenham muitos objetos. Um dos principais algoritmos utilizados é chamado *DBSCAN* (*Density Based Spatial Clustering of Applications with Noise*). Esse algoritmo orienta o processo de formação dos grupos a partir da densidade de objetos na vizinhança de um objeto pertinente ao grupo em questão. O algoritmo *DBSCAN* é descrito a seguir.

Nesse sentido, um objeto y é vizinho de um objeto x se y está contido em uma área de tamanho ε em torno de x. Formalmente, a vizinhança de x é definida da seguinte forma:

$$V(x) = \{y | d(x, y) \leq \varepsilon\}, \forall y$$

em que x e y são objetos do conjunto de dados, $d(x, y)$ é a distância entre esses objetos e ε é um limiar arbitrário que limita a área ao redor de x.

Algoritmo 3: Agrupamento por Densidade (DBSCAN)
Entrada:

- X_{tr}: é um conjunto de exemplares não rotulado de treinamento, ou seja, $X_{tr} = \{\vec{x}_i\}, i = 1, \ldots, n;$

- $minEx$: número mínimo de exemplares exigido na verificação da densidade da vizinhança;
- r: raio de vizinhança de um exemplar;
- $dist$: medida de distância entre dois exemplares.

Saída:

G: uma lista com os exemplares agrupados ou indicação de exemplares definidos como ruído pelo algoritmo;

Etapas:

- $G[1 \ldots n] = exemplar_não_agrupado$;
- $id_{grupo} = 0$;
- para todo $\vec{x}_i$ que ainda não pertence a um grupo e não está determinado como ruído faça:

  $lista1 = \{\}$;

  $lista1 = \{\vec{x}_i\}$ e todos os exemplares de X_{tr} na vizinhança de raio r de $\vec{x}_i$, considerando a distância $dist$;

  se $lista1$ indicar menos exemplares na vizinhança de $\vec{x}_i$ que $minEx$

Então:

- $\vec{x}_i$ é considerado ruído e $G[i] = ruído$;
- Senão:
- $id_{grupo} = id_{grupo} + 1$;
- $G[lista1] = id_{grupo}$;
- $lista1 = lista1 - \vec{x}_i$;
- para todo exemplar $\vec{x}_j \in lista1$ faça:

  $lista2 = \{\}$;

  $lista2 = \{\vec{x}_j\}$ e todos os exemplares de X_{tr} na vizinhança de raio r de $\vec{x}_j$, considerando a distância $dist$;

  se $lista2$ contém menos exemplares que $minEx$

Então:

- $lista1 = lista1 - \vec{x}_j$;

Senão:

- $lista1 = lista1 - \vec{x}_j$;
- para todo $\vec{x}_k \in lista2$ que ainda não pertence a um grupo faça:

  se $\vec{x}_k \neq ruído$ então:

  $lista1 = lista1 + \vec{x}_k$;

  $G[k] = id_{grupo}$.

Fonte: Adaptada de SILVA *et al.*, 2017

O DBSCAN define automaticamente o número de grupos que serão formados. Em cada grupo há, pelo menos, um objeto de núcleo que é definido como o objeto que possui um número mínimo de objetos em sua vizinhança. A formação dos grupos é feita a partir do objeto núcleo agregando seus vizinhos. Para cada objeto adicionado,

a respectiva vizinhança também será adicionada. O processo iterativo se encerra quando todos os objetos tiverem sido considerados. Ao final do processo, os objetos que não foram adicionados a nenhum grupo são definidos como ruído.

Tabela 4 – Conjunto de Dados Considerado para Experimentação com a Linguagem de Programação *R*

	Valor Gasto	Num. de. pessoas
1	10.00	10.0
2	6.60	4.0
3	3.40	4.0
4	4.70	4.0
5	5.30	4.0
6	1.00	1.0
7	2.80	2.5
8	2.30	2.5
9	2.90	2.5
10	1.05	1.0
11	3.80	4.0
12	1.90	2.5

Fonte: Adaptada de DA SILVA *et al.*, 2017

Para a aplicação prática do algoritmo DBSCAN, vamos considerar um conjunto de dados referente a Análise de Vendas em um restaurante. Nesse conjunto, cada linha representa um objeto que possui dois atributos; um referente ao valor gasto por mesa no restaurante e outro relativo ao número de pessoas presentes na mesa. A Tabela 4 apresenta esse conjunto de dados, com seus valores previamente normalizados, importados para a manipulação no *RStudio*, na forma de um *Data Frame*.



Para saber mais sobre os algoritmos de agrupamento por densidade, leia a dissertação de mestrado intitulada: "Algoritmos rápidos para estimativas de densidade hierárquicas e suas aplicações em mineração de dados". Disponível em: https://bit.ly/320D3u4

Aplicações com a Linguagem *R*

A linguagem de programação *R* implementa o algoritmo DBSCAN por meio da função `dbscan()`. Essa função é disponibilizada pelo pacote `fpc`. A instalação desse pacote é feita da seguinte forma:

```
install.packages('fpc').
```

A função `dbscan()` considera três parâmetros principais:

- O conjunto de dados (*data frame*) – `analise_de_vendas;`
- A vizinhança acessível de um exemplar – `eps;`

• Parâmetro para a verificação da densidade de vizinhança de um objeto – `MinPts.`

Assim, a criação do modelo de agrupamento é feita como segue:

```
grupos <- dbscan(analise_de_vendas, eps = 1, MinPts = 2).
```

Para a verificação do modelo de agrupamento, obtido por meio dos dados da Tabela 4, podemos consultar a variável `grupos$cluster`, cujo conteúdo é apresentado a seguir:

```
[1] 0 0 1 1 1 2 3 3 3 2 1 3.
```

Nesse experimento, foram identificados três grupos (1, 2 e 3) cujos indicadores são armazenados na variável `grupos$cluster`, os objetos indicados com "0" foram considerados como ruído pelo algoritmo.

Para a visualização dos grupos identificados, podemos considerar a plotagem de um gráfico e a utilização do modelo obtido para a rotulação dos grupos de cada objeto. Assim, considere a utilização da função `plot()` da seguinte forma:

```
plot(grupos, analise_de_vendas),
```

que resultará no gráfico da Figura 10.

O gráfico da Figura 10 apresenta a distribuição dos objetos no espaço bidimensional. Os objetos são representados por triângulos coloridos e por circunferências na cor preta. As cores dos triângulos (verde, azul e vermelho) descrevem os grupos de cada objeto. As circunferências representam os objetos que foram classificados como ruído.

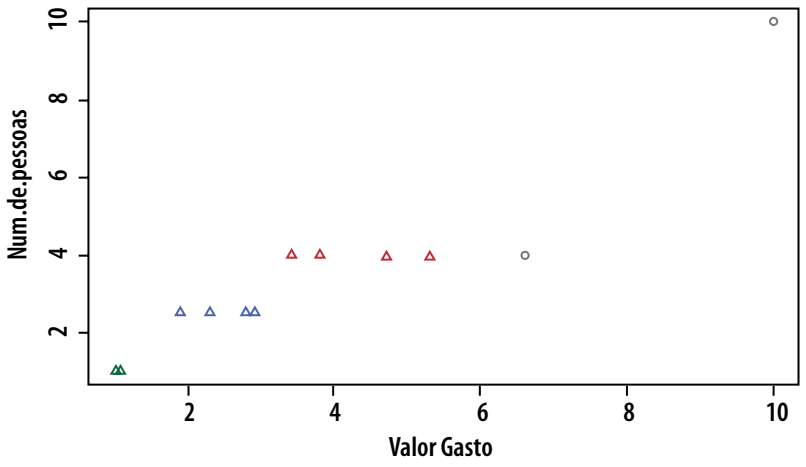


Figura 10 – Agrupamento do conjunto de dados "Análise de Vendas"
Fonte: Adaptada de SILVA *et al.*, 2017

Material Complementar

Indicações para saber mais sobre os assuntos abordados nesta Unidade:

Vídeos

***K-means* com *Python* Parte1/2 Exemplo Visual**
https: https://youtu.be/piDlrtfz58s

Algoritmo *K*-Médias ou *K-Means*
https://youtu.be/_cxSLmrT9zk

Dendrograma/Agrupamento/*Cluster* Explicadinho e Mastigado com Exemplo Bem Prático e Simples
https://youtu.be/dToBP2UL9FI

Análise de Agrupamentos
https://youtu.be/zyLDAnQMnbo

Referências

BECKER, J. L. **Estatística básica**: transformando dados em informação. Porto Alegre Bookman 2015. (*e-book*)

CASTRO, L. N.; FERRARI, D. G. **Introdução à mineração de dados**: conceitos básicos, algoritmos e aplicações. São Paulo: Saraiva, 2016.

DA SILVA, L. A.; PERES, S. M.; BOSCARIOLI, C. **Introdução à mineração de dados**: com aplicações em R. Elsevier Brasil, 2017.

FARIA, F. A. **Aprendizagem não supervisionada – Agrupamento (*Clustering*)**. Notas de aula. UNIFESP (São Paulo), 2015.

LIMA, M. F. W. P. **Introdução a *Big Data* e *Internet* das Coisas**. Porto Alegre: SAGAH, 2018.

LORENA, A. C., FARIA, F. A. **Representação do Conhecimento – Lidando com incerteza**. Notas de aula. UNIFESP (São Paulo). 2015.

ROSSI, L. **Técnicas para converter dados em conhecimento**. São Paulo: Universidade Cruzeiro do Sul, 2021.


Cruzeiro do Sul
Educacional