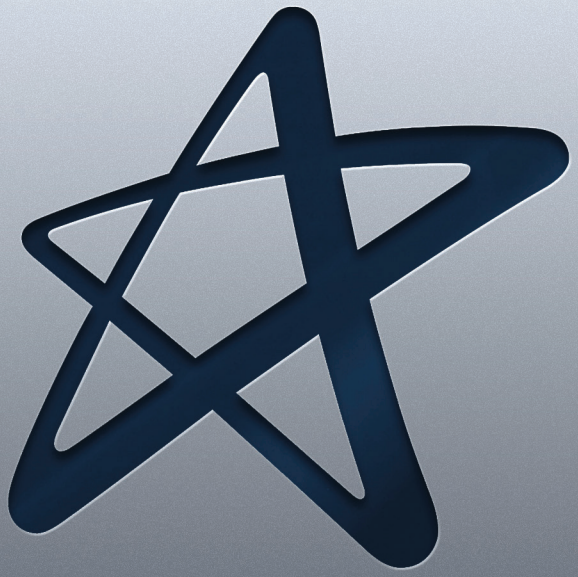
# Mineração de Dados



Cruzeiro do Sul Virtual
Educação a distância

# Material Teórico

## Introdução à Mineração de Dados

**Responsável pelo Conteúdo:**
Prof. Dr. Alberto Messias

**Revisão Textual:**
Prof.ª Dr.ª Luciene Oliveira da Costa Granadeiro

# UNIDADE Introdução à Mineração de Dados

- Relembrando o Processo de Aquisição de Conhecimento;
- *DataWareHouse;*
- *Data Mart;*
- Conceito de *Data Mining;*
- Visão Geral de Algoritmos para Análise de Dados;
- Técnica de Regras de Associação.



## OBJETIVO DE APRENDIZADO

- Relembrar alguns conceitos iniciais quanto ao processo de aquisição de conhecimento, as definições iniciais sobre a mineração de dados, além de dar uma visão geral sobre os algoritmos para análise de dados e, por fim, mencionar as técnicas de regras de associação.

# Orientações de estudo

Para que o conteúdo desta Disciplina seja bem aproveitado e haja maior aplicabilidade na sua formação acadêmica e atuação profissional, siga algumas recomendações básicas:




## Assim:

- ✓ Organize seus estudos de maneira que passem a fazer parte da sua rotina. Por exemplo, você poderá determinar um dia e horário fixos como seu "momento do estudo";
- ✓ Procure se alimentar e se hidratar quando for estudar; lembre-se de que uma alimentação saudável pode proporcionar melhor aproveitamento do estudo;
- ✓ No material de cada Unidade, há leituras indicadas e, entre elas, artigos científicos, livros, vídeos e *sites* para aprofundar os conhecimentos adquiridos ao longo da Unidade. Além disso, você também encontrará sugestões de conteúdo extra no item **Material Complementar**, que ampliarão sua interpretação e auxiliarão no pleno entendimento dos temas abordados;
- ✓ Após o contato com o conteúdo proposto, participe dos debates mediados em fóruns de discussão, pois irão auxiliar a verificar o quanto você absorveu de conhecimento, além de propiciar o contato com seus colegas e tutores, o que se apresenta como rico espaço de troca de ideias e de aprendizagem.

# Relembrando o Processo de Aquisição de Conhecimento

O aproveitamento das informações já existentes e sua transformação em conhecimento criaram o conceito de "mineração de dados", ou aqui chamado de "processo de extração de informação", que é um passo essencial para descoberta do conhecimento.

Um processo muito utilizado para transformar dados em conhecimento é o KDD (*Knowledge Discovery in Databases*), o qual é descrito na Figura 1 de acordo com (SCHEFFER, 2001).

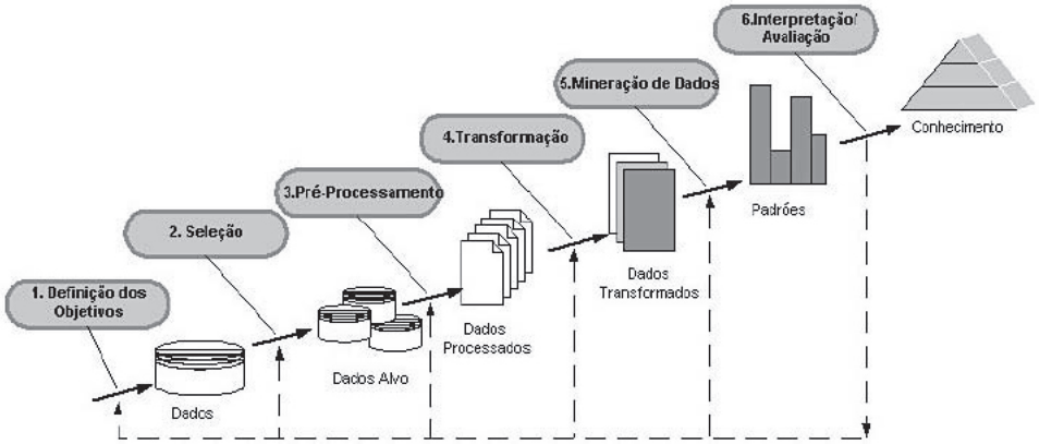



Figura 1 – Processo de KDD ou aquisição de conhecimento
Fonte: SCHEFFER, 2001

Minerar dados é o processo de descobrir informações relevantes como padrões, associações, mudanças, anomalias e estruturas em grandes quantidades de dados armazenados em bancos de dados, depósitos de dados, ou outros depósitos de informação.

O processo de KDD está presente na implementação de projetos de BI, análises de dados e de *Big Data*. Isso significa que as fases descritas desse processo ocorrem nos projetos de BI e também na aplicação das outras tecnologias mencionadas. Vão desde a definição de objetivos do projeto como um todo, passando pela seleção de dados, pré-processamento, que é uma preparação inicial dos dados, à transformação, em que os dados deverão ser uniformizados, para que possa ocorrer a mineração, que é a execução dos algoritmos de análises, e, por fim, à interpretação e visualização das informações geradas.

Diversos conceitos são aplicados ao processo de KDD e que são importantes no contexto de BI e *Big Data*, a própria modelagem de dados, que é diferente da modelagem ER comumente conhecida, o conceito *DataWarehose* e de *Datamining*.

Veja outros conceitos importantes a seguir.

# DataWareHouse

Em uma grande empresa, com grandes bancos de dados ou grandes sistemas para funções separadas, como manufatura, vendas e contabilidade, são necessários recursos e ferramentas especiais para analisar vastas quantidades de dados e extraí-los de múltiplos sistemas. Entre esses recursos, estão o *data warehousing* (armazenamento de dados), o *data mining* (mineração de dados) e ferramentas para acessar bancos de dados internos.

*Data Warehouse* é um conceito de utilização de banco de dados que armazena dados correntes e históricos de potencial interesse para os tomadores de decisão de toda a empresa. Os dados originam-se de muitos sistemas operacionais existentes na organização, o *data warehouse* consolida e padroniza estas informações, de modo que elas possam ser usadas por toda a empresa para análise gerencial e tomada de decisões. A Figura 2 mostra grosso modo como um *data warehouse* funciona.

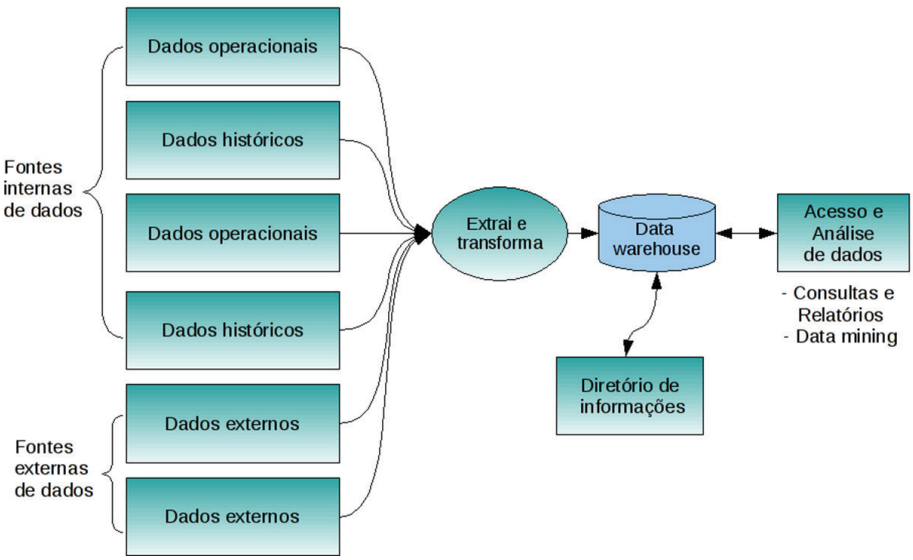



Figura 2 – Componentes de um data warehouse
Fonte: LAUDON, 2008

O processo importante que resgata os dados e os insere no data warehouse é chamado de ETL – *extraction, transformation e loading* –, ou em português extração, transformação e carga.

Uma vez que os dados tenham sido capturados e organizados em data warehouses, eles ficam disponíveis para análises e processamentos posteriores para que outros sistemas resgatem os dados, criem outras áreas de dados e gerem os dashboards e relatórios através do processo chamado OLAP – *online analytical processing*.

# Data Mart

Enquanto o *data warehouse* armazena o conjunto completo de dados da empresa, um data mart tende a ser menor e armazenar os dados de áreas específicas da organização ou associada a uma unidade de negócio, como, por exemplo, *data mart de marketing*, *data mart financeiro*, entre outros.

Inicialmente, deve ser criado o *data warehouse* para que, posteriormente, sejam criados os *data marts* por áreas na organização. Essas bases tendem a ser menores que os *data warehouse* e, consequentemente, seus conceitos e geração de informação processam mais rapidamente.

A Figura 3 ilustra a estrutura e visualização de um *data warehouse*.

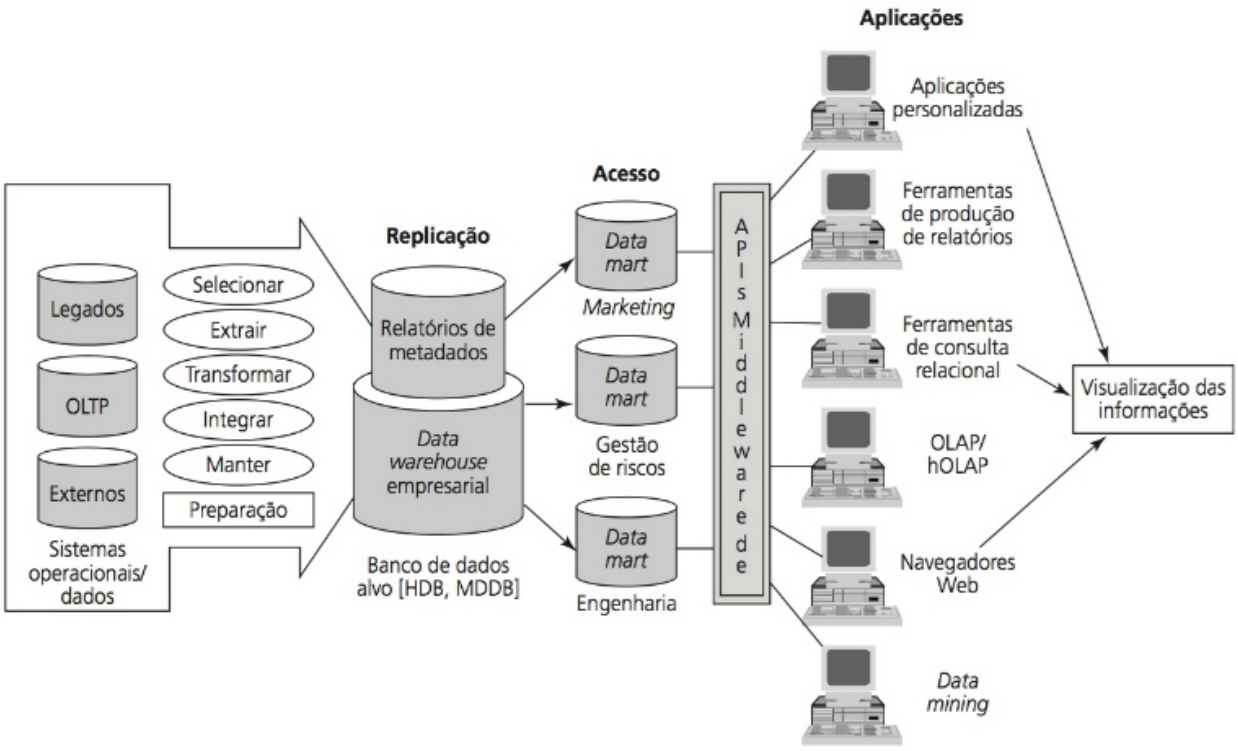



Figura 3: Estrutura de um data warehouse
Fonte: Turban et. Al, 2009

Cabe ressaltar que na literatura há descrições do processo de *data warehouse* que criam inicialmente os datamarts departamentais, e posteriormente fazem a convergência para o *data warehouse*.

Segue a Figura 4 que ilustra a estratégia gradativa de *data marts* (Barbiere, 2001).

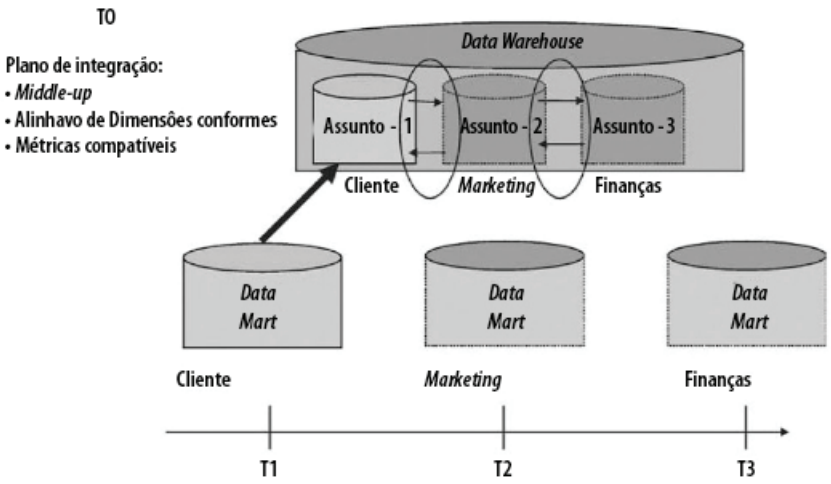



Figura 4 – Estratégia gradativa de data marts
Fonte: Barbieri, 2001

Notem que o processamento desses dados, para a geração de informações, utiliza as técnicas e algoritmos de mineração de dados, que poderão ser executados em ambientes tradicionais de processamento ou ambientes de *Big Data*.

**Importante!**

As técnicas de algoritmos são, grosso modo, as mesmas; o que as diferencia é a implementação, seja em computação tradicional, como ambientes para geração de informações para sistemas de BI, ou com computação distribuída e paralela, utilizando os conceitos de *Big Data*.

# Conceito de *Data Mining*

O *Data mining* fornece percepções dos dados corporativos, descobrindo padrões e relacionamentos ocultos em grandes bancos de dados e inferindo regras a partir deles para prever comportamentos futuros. Esses modelos e regras podem, então, ser utilizados para guiar processos de decisão e prever o efeito dessas decisões (LAUDON, 2008).

A técnica é conhecida também como mineração de dados, onde, minerar dados é o processo de descobrir informações relevantes como padrões, associações, mudanças, anomalias e estruturas, em grandes quantidades de dados armazenados em bancos de dados, depósitos de dados ou outros depósitos de informação. A mineração de dados fornece percepções dos dados, descobrindo padrões e relacionamentos ocultos em grandes bancos de dados e inferindo regras a partir deles, para prever comportamentos futuros (ZAKI; MEIRA, 2014).

A mineração de dados utiliza um conjunto de técnicas estatísticas e de inteligência artificial na transformação de um conjunto de dados em informações úteis como padrões e dados comportamentais.

Na mineração de dados, existem muitas técnicas para identificar padrões, e podem ser dados como exemplos: implementação de redes neurais artificiais, algoritmos para análise e reconhecimento de padrões, algoritmos de agrupamento ou clustering, técnicas de classificação, técnicas de regressão ou detecção de outliers. Essas técnicas ou algoritmos são aplicados no processo de OLAP.

# Visão Geral de Algoritmos para Análise de Dados

Minerar dados é o processo de descobrir informações relevantes como padrões, associações, mudanças, anomalias e estruturas, em grandes quantidades de dados armazenados em bancos de dados, depósitos de dados ou outros depósitos de informação. A mineração de dados fornece percepções dos dados, descobrindo padrões e relacionamentos ocultos em grandes bancos de dados e inferindo regras a partir deles, para prever comportamentos futuros (ZAKI; MEIRA, 2014).

O reconhecimento de padrões é uma disciplina da ciência que tem como objetivo classificar objetos em um número de categorias ou classes, conforme o observado em (THEODORIDIS; KOUTROUMBAS, 2008). Dependendo da aplicação, esses objetos podem ser, por exemplo, imagens, sinais de ondas de rádio, ou qualquer tipo de medida que se deseja classificar.

Observa-se ainda que, com as técnicas de reconhecimento de padrões, pode-se, por exemplo (DOUGHERTY, 2012):

- estimar valores;
- selecionar atributos relevantes para classificação;
- reconhecer pontos fora da curva, chamados de outliers;
- agrupamento de instâncias;
- classificação de instâncias;
- análise de textos.

Essas técnicas ou algoritmos possuem diversas aplicabilidades e em diversos segmentos de mercado. Os algoritmos são aplicados em tecnologias para *Big Data*, mineração de dados e Business Intelligence. Seguem uma tabela que mostra quais tipos de problemas cada uma das técnicas se aplica ou qual problema resolve:

Tabela 1

| Qual problema a técnica endereça | Tipo de técnica |
|---|---|
| Eu desejo agrupar item dadas as suas similaridades.<br>Eu quero encontrar estruturas comuns em um conjunto de dados. | *Clustering* |
| Eu quero encontrar relacionamentos entre ações ou itens. | Regras de associação |
| Eu quero encontrar o relacionamento ou valor específico de uma variável dada uma entrada. | Regressão |
| Eu desejo inserir uma marcação ou categoria a objetos. | Classificação |
| Eu desejo analisar um conjunto de textos ou documentos. | Análise de textos |
| Eu desejo encontrar anomalias no meu conjunto de dados. | Detecção de *outlier* |

Seguem alguns exemplos de aplicabilidade das técnicas (THEODORIDIS; KOUTROUMBAS, 2008):

- **Detecção de *outlier*:** comumente aplicado em análise de operações de compras com cartão de crédito, onde se percebem caso ocorram fraudes;
- **Técnicas de classificação:** classificação de clientes mediante ao perfil de compra e crédito;
- **Técnica de *clustering*:** técnicas de agrupamento podem ser aplicadas para a criação de grupos e separação de indivíduos ou criação de categorias, criação de categorias de documentos, por exemplo, análise de dados de postagens em redes sociais;
- **Estimação de valores:** estimar leituras de sensores quando há falhas na leitura ou falhas na comunicação entre uma aplicação e o sensor;
- **Seleção de atributos:** compreender quais são as características que melhor definem o comportamento de uma espécie;
- **Análise de textos:** aplicação que caracteriza um perfil social dadas as suas postagens em uma rede social de textos.

Seguem alguns exemplos de aplicabilidade de técnicas de reconhecimentos de padrões:

- Reconhecimento de fala;
- Reconhecimento de textos;
- Identificação por impressão digital ou íris;
- Identificação de sequência de DNA;
- Avaliação de risco de crédito;
- Detecção de anomalias em leituras de sensores;
- Busca de água em imagens de satélite retiradas de marte;
- Categorização automática de documentos e filmes.

**Importante!**

Um aspecto importante para qualquer das técnicas é a seleção correta dos atributos, limpeza adequada dos dados, certo conhecimento do domínio de aplicação, percepção de ruídos nos dados e fazer a validação do modelo de análise proposto pela técnica ou execução do algoritmo e saber aplicar a técnica adequada para o tipo de domínio e tipos de dados a serem analisados.

Vamos iniciar por uma das técnicas de mineração de dados:

# Técnica de Regras de Associação

Regras de Associação representam um padrão de relacionamento entre itens de dados no domínio da aplicação, que ocorrem com uma determinada frequência nas bases de dados. Uma regra de associação demonstra a presença de um determinado conjunto que implica na presença de algum outro conjunto distinto de itens. As Regras de Associação podem ser definidas formalmente como: dado um conjunto de itens $I = \{i1, i\ 2,..., i\ m\}$, sendo $D$ um conjunto de transações, enquanto cada transação $T$ é um conjunto de itens tal que $I \supseteq T$, onde cada transação está associada com um identificador único, tal que $T \supseteq X$, $I \supseteq X$. A regra associativa equivale a uma implicação na forma $X\ Y$, enquanto $X$ é o antecedente e $Y$ é o consequente (GILLMEISTER, 2007).

O algoritmo mais conhecido para a criação de regras de associação é o *Apriori*, que foi proposto por Agrawal em (1994) com o objetivo de encontrar regras associativas em grandes e complexas bases de dados. Constitui-se em um dos algoritmos mais difundidos em regras associativas e originou muitos outros, seu grande diferencial está em sua simplicidade.

A abrangência de uma regra constitui-se no número de instâncias que são preditas corretamente, esta característica é chamada de *Suporte*. A precisão da regra associativa é conhecida como **Confiança**, onde se faz uma proporção das instâncias corretamente preditas sobre todas as instâncias analisadas (GILLMEISTER, 2007).

O algoritmo gera todos os conjuntos de itens (chamados de *itemsets* candidatos) e testa qual a relevância daquele conjunto na base de dados. Quando o conjunto não é muito relevante, ele e os outros conjuntos dos quais esses são subconjuntos, são excluídos dos *itemsets* candidatos. A relevância dos conjuntos, deve ser medida através de critérios, ou medidas, que possam identificar quais das possíveis regras de associação são mais interessantes. Para isso, são introduzidas as medidas de interesse.

Considerando uma regra $X \Rightarrow Y$, onde $X$ é o conjunto de itens do antecedente da regra, $Y$ é o conjunto de itens do seu consequente e $X \cup Y$ é o conjunto de todos os itens presentes no antecedente e no consequente, tem-se as seguintes medidas de interesse aplicadas sobre a regra. Considerando $P(X)$ igual ao número de transações contendo os itens de $X$ dividido pelo número total de transações da base de dados.

Seguem algumas definições de termos que serão constantemente utilizados:

- **confiança:** foi introduzida na mineração de dados através do modelo **suporte-confiança**, por *Agrawal*, *Imielinski* e *Srikant* em 1993. Esta medida indica a ocorrência de transações em que todos os itens da regra aparecem, em relação às transações em que os itens do antecedente estão presentes, ou seja:

$$\text{confiança}(X \Rightarrow Y) = \frac{P(X \cup Y)}{P(X)}$$

- **suporte:** O **suporte** de um *itemset* X em I, denotado como *sup*(X), é o número das transações que contém X, dividido pelo número total de transações.

$$\sup(X) = \frac{|\{t_j : X \subseteq t_j\}|}{|I|}$$

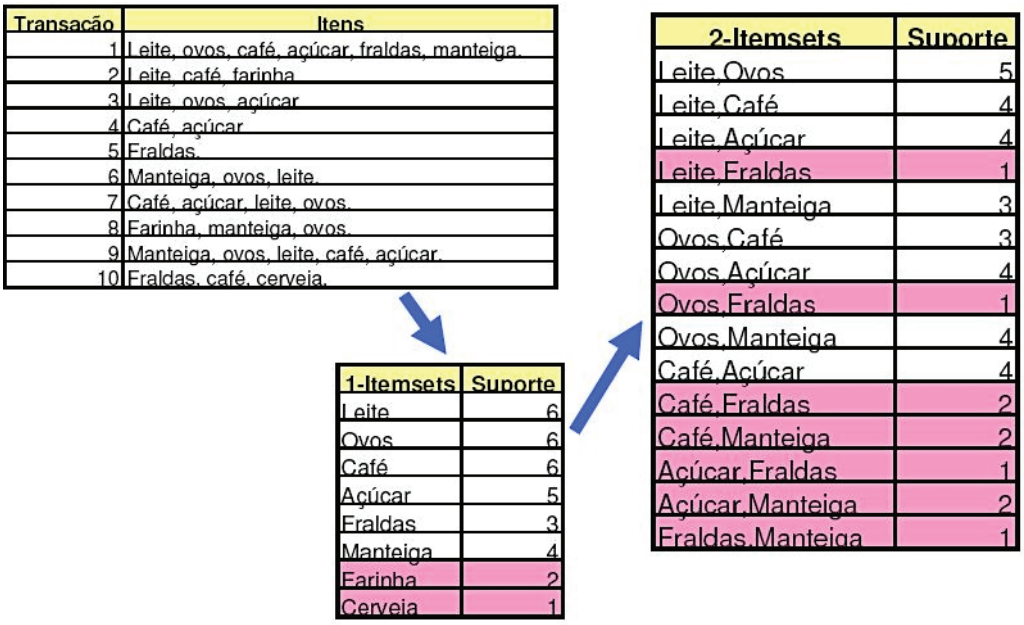
Um *itemset* é **frequente** se o seu **suporte** é maior que o **suporte limiar**, que é uma entrada para o algoritmo *Apriori*, dado como **suporte mínimo** que o *itemset* pode ter para continuar sendo aceito pelo algoritmo.

A partir da escolha de uma medida de interesse, cada regra de associação possível de ser gerada é avaliada e aquelas que não atendem a um valor mínimo definido e passado como parâmetro para o algoritmo serão descartadas.

A parametrização normalmente é feita com um **suporte mínimo** e uma **confiança mínima**.

Inicialmente, o algoritmo *Apriori* faz diversas passagens sobre os dados para selecionar todos os conjuntos de itens frequentes, sendo que, em cada um desses passos, primeiro, ele gera um conjunto de itens candidatos e, então, percorre a base de dados para determinar se os candidatos satisfazem o **suporte mínimo** estabelecido pelo parâmetro.

Segue abaixo um exemplo de criação das regras de associação, com a formação dos itemsets e os valores de suporte:



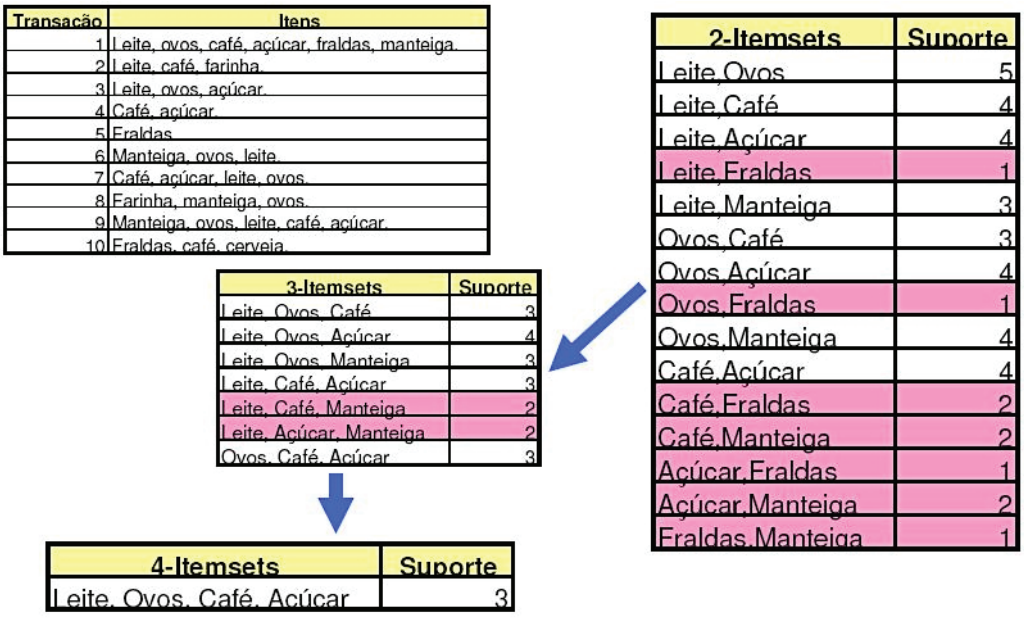
| Transação | Itens |
|---|---|
| 1 | Leite, ovos, café, açúcar, fraldas, manteiga. |
| 2 | Leite, café, farinha. |
| 3 | Leite, ovos, açúcar. |
| 4 | Café, açúcar. |
| 5 | Fraldas. |
| 6 | Manteiga, ovos, leite. |
| 7 | Café, açúcar, leite, ovos. |
| 8 | Farinha, manteiga, ovos. |
| 9 | Manteiga, ovos, leite, café, açúcar. |
| 10 | Fraldas, café, cerveja. |

| 1-Itemsets | Suporte |
|---|---|
| Leite | 6 |
| Ovos | 6 |
| Café | 6 |
| Açúcar | 5 |
| Fraldas | 3 |
| Manteiga | 4 |
| Farinha | 2 |
| Cerveja | 1 |

| 2-Itemsets | Suporte |
|---|---|
| Leite,Ovos | 5 |
| Leite,Café | 4 |
| Leite,Açúcar | 4 |
| Leite,Fraldas | 1 |
| Leite,Manteiga | 3 |
| Ovos,Café | 3 |
| Ovos,Açúcar | 4 |
| Ovos,Fraldas | 1 |
| Ovos,Manteiga | 4 |
| Café,Açúcar | 4 |
| Café,Fraldas | 2 |
| Café,Manteiga | 2 |
| Açúcar,Fraldas | 1 |
| Açúcar,Manteiga | 2 |
| Fraldas,Manteiga | 1 |

Figura 5 – Exemplo de Base de dados com itens

A Figura 5 mostra uma tabela com alguns itens referentes a compras em um supermercado – considerando um **suporte** mínimo de 25%, o algoritmo analisa os itens e verifica os mais frequentes; em seguida, monta outra tabela e despreza os itens que não atendem ao **suporte** mínimo; em seguida, varre a mesma base desprezando os itens menos frequentes, e analisando agora a frequência para 2 *itemsets*; e faz a mesma análise, itens menos frequentes são desprezados.



| Transação | Itens |
|---|---|
| 1 | Leite, ovos, café, açúcar, fraldas, manteiga. |
| 2 | Leite, café, farinha. |
| 3 | Leite, ovos, açúcar. |
| 4 | Café, açúcar. |
| 5 | Fraldas. |
| 6 | Manteiga, ovos, leite. |
| 7 | Café, açúcar, leite, ovos. |
| 8 | Farinha, manteiga, ovos. |
| 9 | Manteiga, ovos, leite, café, açúcar. |
| 10 | Fraldas, café, cerveja. |

| 3-Itemsets | Suporte |
|---|---|
| Leite, Ovos, Café | 3 |
| Leite, Ovos, Açúcar | 4 |
| Leite, Ovos, Manteiga | 3 |
| Leite, Café, Açúcar | 3 |
| Leite, Café, Manteiga | 2 |
| Leite, Açúcar, Manteiga | 2 |
| Ovos, Café, Açúcar | 3 |

| 4-Itemsets | Suporte |
|---|---|
| Leite, Ovos, Café, Açúcar | 3 |

| 2-Itemsets | Suporte |
|---|---|
| Leite,Ovos | 5 |
| Leite,Café | 4 |
| Leite,Açúcar | 4 |
| Leite,Fraldas | 1 |
| Leite,Manteiga | 3 |
| Ovos,Café | 3 |
| Ovos,Açúcar | 4 |
| Ovos,Fraldas | 1 |
| Ovos,Manteiga | 4 |
| Café,Açúcar | 4 |
| Café,Fraldas | 2 |
| Café,Manteiga | 2 |
| Açúcar,Fraldas | 1 |
| Açúcar,Manteiga | 2 |
| Fraldas,Manteiga | 1 |

Figura 6 – Exemplo de Base de dados com itens

Na Figura 6, é feita a mesma iteração com 3 itens e depois com 4 itens, e, assim, satisfazendo ao **suporte** mínimo, temos uma regra de associação simples – "Pessoas que comprar leite normalmente compram Ovos, café e açúcar".

No algoritmo *Apriori*, com os conjuntos frequentes de tamanho 3, geram-se candidatos de tamanho 4, realiza-se a poda e calculam-se os seus valores de *suporte*.

Em seguida, com os conjuntos frequentes de tamanho 4, obtém-se os conjuntos candidatos de tamanho 5, e assim por diante, até que não seja mais possível gerar candidatos $k$ a partir dos conjuntos frequente de tamanho $k - 1$.

Após a conclusão da etapa de obtenção dos conjuntos de itens frequentes na base de dados, devem ser geradas as regras de associação no formato $X \Rightarrow Y$. Essa nova etapa é crítica, tendo em vista que podem ter sido obtidos muitos conjuntos frequentes e, para cada um deles, podem-se obter várias regras através das combinações de seus itens no antecedente e consequente de cada regra.

Tendo em vista que, para um conjunto frequente de tamanho $k$, podem ser geradas $k!$ regras diferentes. O número de regras possíveis pode se tornar muito grande, principalmente quando há muitos conjuntos frequentes de tamanho superior a dois, inviabilizando qualquer análise por parte dos usuários de mineração de dados.

Segue a figura com o pseudocódigo do algoritmo *Apriori* (GILLMEISTER, 2007):

```
L1 = { large 1-itensets };\\L1 será formado por item sets de apenas um elemento

para {k=2; Lk-1 ≠ ∅; k++ } faça
      \\ a partir do grupo de item sets com dois elementos, a geração é feita com  base no grupo
      \\anterior.
 inicio
   Ck = apriori_gen { Lk-1 }; \\neste passo são executadas a geração e a poda
   Para todas as transações t ∈ Base de dados faça \\todas as transações
      \\ serão lidas para a contagem dos candidatos
    inicio
      Ct = subset { Ck , t };
      Para todas transactions c  ∈ Ck faça
          c.count++;
    fim
   Lk = { c ∈ Ck | c.count > minsup };
 fim
resultado = ∪k Lk ;
```

Figura 7 – Algoritmo *Apriori*
Fonte: Adaptado de GILLMEISTER, 2007

No início, $L1$, que é o conjunto com somente um elemento, é gerado. Na sequência, tem-se um laço com $k$ passos; nele, serão desenvolvidas duas tarefas. A primeira é a geração do grupo de itens candidatos $C_k$, através dos itens gerados no passo anterior (conjunto de $L_{k-1}$) e utilizando-se da função *A priori-gen* para isso. A segunda tarefa executada no laço $k$ consiste em outro laço para contagem do **suporte** dos itens do grupo candidato $C_k$, onde cada transação da base de dados é

analisada. Nesse momento, o algoritmo *Apriori* utiliza uma função, estruturada na forma de uma *hash-tree*, onde cada nó folha contém uma lista de itens ou o endereçamento para uma tabela *hash*. Assim é possível encontrar todos os candidatos contidos na transação *t* de forma ágil. Cada candidato *c* terá no final o seu **suporte** calculado e no próximo passo *k*, os itens que não obtiveram o **suporte mínimo** estabelecido são excluídos.

A Função A *priori-gen* apresenta duas finalidades: a primeira consiste em formar a união dos conjuntos frequentes e a segunda consiste em gerar o conjunto de candidatos $C_k$. Assim, os itens do conjunto candidato formado estarão ordenados lexicograficamente, eliminando aqueles que possuírem itens iguais, conforme a Figura 8 (GILLMEISTER, 2007).

```
insert   into Ck
select   p.item1, p.item2,..., p.itemk-1, q.itemk-1
 from    Lk-1 p, Lk-1 q
where    p.item1= q.item1,..., p.itemk-2= q. itemk-2, p.item k-1< q.
item k-1;
para todos itens  c ∈ Ck faça
   para todos (k – 1)subsets s of c faça
      Se (s ∉ Lk-1) então
         delete c from Ck;
```

Figura 8 – Função *Apriori-gen*
Fonte: Adaptado de GILLMEISTER, 2007

O outro objetivo da função *Apriori-gen* é fazer a poda do conjunto de itens candidatos, usando o princípio de que cada subconjunto de um conjunto de itens frequentes também deve ser frequente. Essa regra é utilizada para reduzir o número de candidatos a serem comparados com cada transação na base de dados (GILLMEISTER, 2007). Todos os candidatos gerados que contenham algum subconjunto que não seja frequente serão podados pela função *Apriori-gen*.

O Algoritmo *Apriori* apresenta muitas derivações, que consistem em pequenas alterações, adicionando vantagens em relação ao tempo de execução, alocação de memória e geração de regras mais concisas e mais confiáveis.

As seguintes derivações do algoritmo *Apriori* serão apresentadas:

- *Fast Apriori*;
- *Predictive Apriori*;
- TID *Apriori*;
- *Apriori Hybrid*;
- *Apriori Group*.

Para se aprofundar no assunto, veja o *link* para materiais complementares no qual há dois *links* para o livro de Mineração de Dados.

# Material Complementar

## Indicações para saber mais sobre os assuntos abordados nesta Unidade:

### Sites

***Machine Learning Repository***

Segue a indicação do site com repositório de bases de dados públicas para experimentos para análise de dados:

https://goo.gl/ZR9Tde

***Collections of Datasets***

Segue o link do site do software WEKA que traz inúmeras bases públicas para experimentos para análise de dados:

https://goo.gl/2A7pvX

### Leitura

**Introdução à Mineração de Dados**

Segue a indicação de leitura do Capítulo 1 do Livro presente no *link* Minha Biblioteca, de **Introdução à Mineração de Dados**.

https://goo.gl/4pNkyp

**Algoritmos com Regras de Associação**

Segue a indicação de leitura do Capítulo 7 do Livro presente no *link* Minha Biblioteca, sobre **Algoritmos com Regras de Associação**.

https://goo.gl/UGULWZ

# Referências

CARLOS BARBIERI, ***BI-business intelligence:*** modelagem e tecnologia, Axcel Books, 2001

DOUGHERTY, G. ***Pattern Recognition and Classification:*** *An Introduction*. 2013. ed. [S.l.]: Springer, 2012.

Turban, E.; Sharda, R.; Aronson, J. E.; King, D.; ***Business Intelligence:*** Um enfoque gerencial para a inteligência do negócio, Bookman Editora, 1 de jan de 2009

Gillmeister, P. R. G., Cazella, S. C., **"Uma análise comparativa de algoritmos de regras de associação: minerando dados da indústria automotiva"**, Universidade do Vale do Rio dos Sinos – UNISINOS; Rio Grande do Sul, 2007.

GILLMEISTER, P. R. G.; CAZELLA, S. C. **Uma análise comparativa de algoritmos de regras de associação:** minerando dados da indústria automotiva. Rio Grande do Sul: Universidade do Vale do Rio dos Sinos – UNISINOS, 2007.

Laudon, K. C., Laudon, J. P., **"Sistemas de informação gerenciais"**, 7ª edição, Pearson, 2008.

Scheffer, T., ***"Finding association rules that trade support optimally against confidence"***, *In: PKDD 2001: principles of data mining and knowledge discovery, European conference on principles of data mining and knowledge discovery* N. 5, 20011973, v. 2168, pages. 424-435.

SOUZA, A. M. da C. **Uma nova arquitetura para Internet das Coisas com análise e reconhecimento de padrões e processamento com *Big Data***. 2015. Tese (Doutorado em Sistemas Eletrônicos) - Escola Politécnica, Universidade de São Paulo, São Paulo, 2015. Disponível em: <http://www.teses.usp.br/teses/disponiveis/3/3142/tde-20062016-105809/>. Acesso em: 2017-03-07.

THEODORIDIS, S.; KOUTROUMBAS, K. ***Pattern Recognition***. 4. ed. [S.l.]: Academic Press, 2008.

ZAKI, M. J.; MEIRA, W. J. ***Data Mining and Analysis:*** *Fundamental Concepts and Algorithms*. 1. ed. [S.l.]: *Cambridge University Press*, 2014.


Cruzeiro do Sul
Educacional