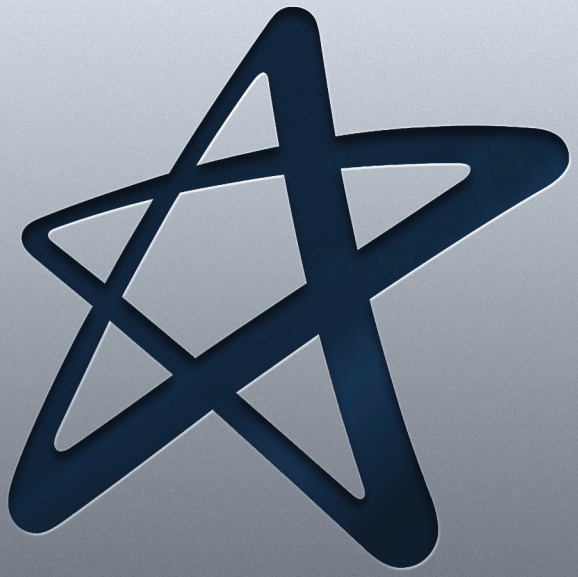
Mineração de Dados



Cruzeiro do Sul Virtual
Educação a distância

Material Teórico

Algoritmos de Detecção de *Outliers* e de *Clustering*

Responsável pelo Conteúdo:
Prof. Dr. Alberto Messias

Revisão Textual:
Prof.ª Dr.ª Luciene Oliveira da Costa Granadeiro

UNIDADE

Algoritmos de Detecção de *Outliers* e de *Clustering*

- Similaridade e Medidas de Distância;
- Técnica de Detecção de *Outlier*;
- Algoritmos de *Clustering*;
- O Algoritmo Kmeans;
- Validação de *Clusters*.



OBJETIVO DE APRENDIZADO

- Introduzir o conceito de similaridade e utilizar a medida de distância euclidiana para aferir a similaridade entre dois objetos, entender o conceito de detecção de *outliers* e compreender a técnica que utiliza os *quartis* para esse fim, logo em seguida, introduzir os algoritmos de *clustering* ou agrupamento, e compreender o funcionamento do algoritmo *kmeans*, bem como uma técnica de validação de *clusters* ou grupos gerados.

Orientações de estudo

Para que o conteúdo desta Disciplina seja bem aproveitado e haja maior aplicabilidade na sua formação acadêmica e atuação profissional, siga algumas recomendações básicas:



Assim:

- ✓ Organize seus estudos de maneira que passem a fazer parte da sua rotina. Por exemplo, você poderá determinar um dia e horário fixos como seu "momento do estudo";
- ✓ Procure se alimentar e se hidratar quando for estudar; lembre-se de que uma alimentação saudável pode proporcionar melhor aproveitamento do estudo;
- ✓ No material de cada Unidade, há leituras indicadas e, entre elas, artigos científicos, livros, vídeos e *sites* para aprofundar os conhecimentos adquiridos ao longo da Unidade. Além disso, você também encontrará sugestões de conteúdo extra no item **Material Complementar**, que ampliarão sua interpretação e auxiliarão no pleno entendimento dos temas abordados;
- ✓ Após o contato com o conteúdo proposto, participe dos debates mediados em fóruns de discussão, pois irão auxiliar a verificar o quanto você absorveu de conhecimento, além de propiciar o contato com seus colegas e tutores, o que se apresenta como rico espaço de troca de ideias e de aprendizagem.

Similaridade e Medidas de Distância

Conforme se observa em Theodoridis e Koutroumbas (2008), uma medida de similaridade ou dissimilaridade é expressa em valor real à similaridade ou à diferença entre dois vetores ou instância. Para se medirem esses valores, podem ser utilizadas medidas de distância entre dois pontos. As medidas de distância comumente utilizadas são: distância euclidiana, distância de Mahalanobis e distância de Manhattan.

A distância de Mahalanobis foi introduzida, em 1936, pelo matemático indiano Prasanta Chandra Mahalanobis. Essa medida se baseia nas correlações entre as variáveis.

A distância de Manhattan é uma forma de geometria que se baseia na soma das diferenças absolutas de todas as coordenadas entre um ponto e outro. Em outras palavras, assemelha-se à distância calculada em um software de GPS, que não trata como uma linha reta entre os dois pontos, mas sim a soma de todas as distâncias entre cada rua ou esquina que se passa. Essa distância tem esse nome tendo em vista a analogia feita ao cálculo da distância que um táxi percorre em Manhattan para ir de um ponto a outro na cidade. Sendo assim, o cálculo da distância entre o ponto P1 com valores (x_1, y_1) e o ponto P2 em (x_2, y_2) é $|x_1 - x_2| + |y_1 - y_2|$.

Vamos nos concentrar na distância euclidiana, que é uma das mais utilizadas. Essa medida de distância mede na verdade o comprimento de uma reta entre dois pontos no espaço euclidiano, o que é a menor distância entre dois pontos quaisquer em um plano.

A figura ilustra uma comparação entre as duas medidas de distância – a euclidiana e a Manhattan.

Notem que a distância euclidiana calcula a reta entre os dois pontos, enquanto a distância de Manhattan é a soma de todas as esquinas e ruas percorridas.

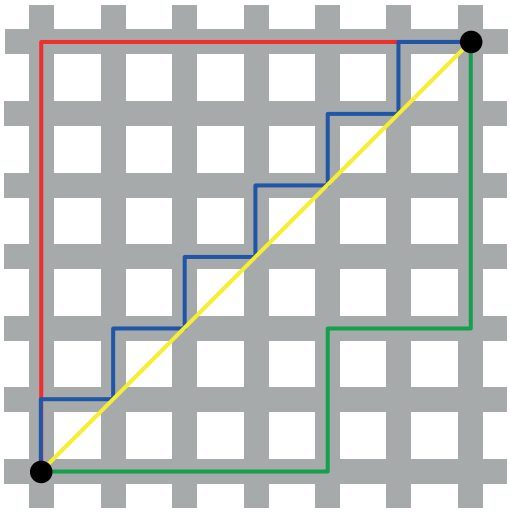


Figura 1 – Comparação entre as distâncias de Manhatan e euclidiana

Sendo assim, o cálculo da distância euclidiana entre o ponto P1 com valores (x_1, y_1) e o ponto P2 em (x_2, y_2) é $\sqrt{((x_1 - x_2)^2 + (y_1 - y_2)^2)}$.

Nesse caso, a distância euclidiana está sendo calculada em um plano de duas dimensões, ou com dois atributos. Porém, ela pode ser calculada para qualquer quantidade de dimensões ou atributos. A equação para o cálculo da distância euclidiana entre os ponto P_i e P_j é:

$$d = \sqrt{\sum_{k=1}^{n} \left(p_{ik} - p_{jk} \right)^2}$$

Onde *n* é o número de atributos ou dimensões, a distância é então raiz quadrada, da soma das diferenças entre os atributos das duas instâncias P_i e P_j elevada ao quadrado.

Segue um exemplo A (3,5,8) e B (1,4,3), a distância euclidiana é:

$$d = \sqrt{(x_b - x_a)^2 + (y_b - y_a)^2 + (z_b - z_a)^2} =$$
$$= \sqrt{(1-3)^2 + (4-5)^2 + (3-8)^2} =$$
$$= \sqrt{(-2)^2 + (-1)^2 + (-5)^2} = \sqrt{4+1+25} =$$
$$= \sqrt{30} \approx 5.477225575051661$$

Técnica de Detecção de *Outlier*

Segundo Zaki e Meira Junior (2014), uma anomalia, ou um *outlier*, ocorre quando uma instância, ou conjunto de instâncias, é diferente do restante do conjunto de dados. A detecção de *outliers* tem importantes aplicações para detecção de fraudes em cartões de crédito, fraudes em sistemas de telecomunicações, detecção de falhas, redes de sensores, detecção de intrusos, detecção de spam em *e-mails*, diagnósticos médicos, ou aplicações em *marketing*.

Há três tipos de técnicas elencadas na literatura para a detecção de *outliers*: técnicas baseadas em distância, baseadas em densidade ou baseadas em estatísticas (ZAKI; MEIRA JUNIOR, 2014). Destaca-se a técnica baseada em distância, na qual uma dada instância é considerada um *outlier*, caso uma fração, onde $p(0 < p < 1)$, de instâncias em uma base de dados estejam fora do raio de uma vizinhança. Caso esse limiar seja muito grande, pontos que deveriam ser considerados *outliers* não serão, e caso esse limiar seja muito pequeno, grande parte dos pontos serão considerados *outlier* erroneamente.

Abordagens mais simples para a detecção de *outliers* utilizam os valores de Quartil no conjunto de dados, que, por sua vez, utiliza a medida de **mediana**. A mediana é o valor que separa a metade menor da metade maior da população ou do conjunto de dados. Ou seja, em uma série de números, por exemplo, {1,1,2,3,5,6,6,7,8,9,10}, o valor central é 6, caso o conjunto de dados tenha a quantidade par de número e não houver um valor central, a média entre os valores do par central será a mediana, por exemplo, {1,2,3,3,5,5,6,7,8,9,10,11}, o par central é {5,6} e a média entre eles é 5,5, portanto, sua mediana.

Uma técnica simples para a detecção de *outliers* é o uso dos valores de mediana e quartis do conjunto de dados. Segue um exemplo prático:

- Dado o conjunto com valores de salários de vendedores em um determinado mês, nesse caso há um vendedor que possui um salário muito dispare do conjunto {1,2,2,3,5,5,6,7,8,9,10,12,40}.
- Calcula-se a mediana do conjunto total: {1,2,2,3,5,5,6,7,8,9,10,12,40}, nesse caso o valor 6 destacado.
- Calcula-se a mediana do conjunto obtido com valores menores ao da primeira mediana, o conjunto obtido é: {1,2,2,3,5,5,6}, nesse caso o valor 3 destacado;
- Calcula-se a mediana do conjunto obtido com valores maiores ao da primeira mediana, o conjunto obtido é: {6,7,8,9,10,12,40}, nesse caso o valor 9 destacado;
- Nesse caso temos os seguintes conjuntos e divisões:

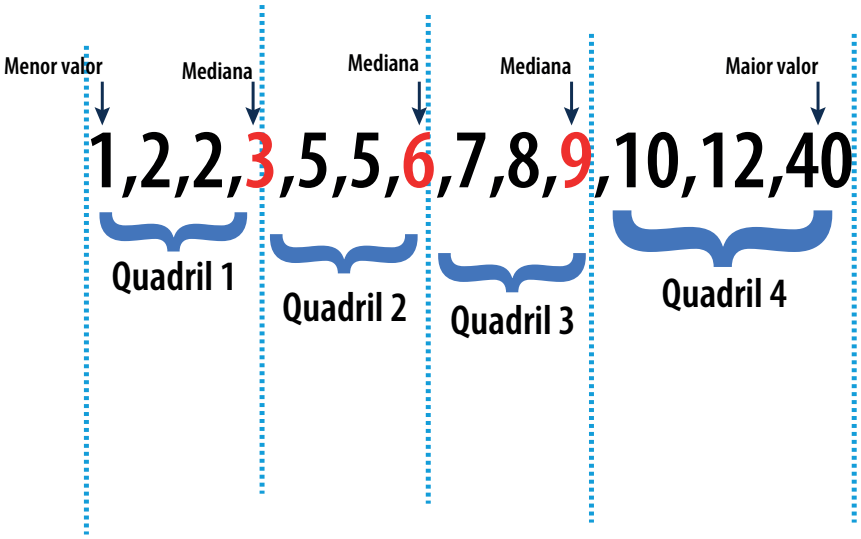


Figura 2 – Exemplo de criação dos conjuntos para análise de *outlier*

- A partir desses valores, calcula-se o valor chamando interquartil (IQR), que é dado pela diferença entre a mediana do quartil 3 e mediana do quartil 1. Observe a figura com o intervalo interquartil:

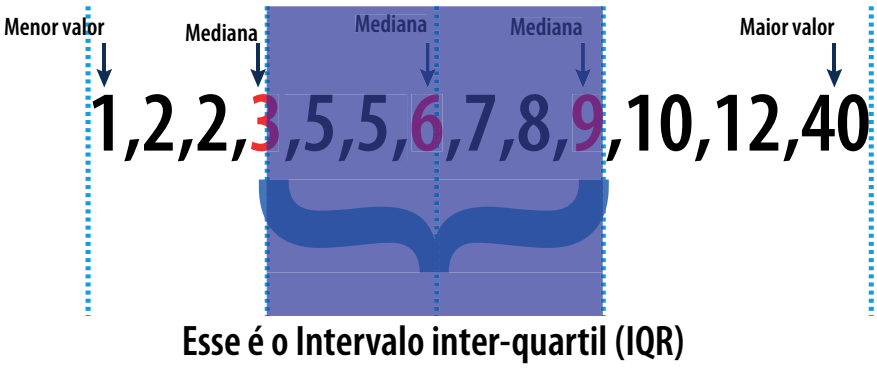


Figura 3

- O tamanho desse IQR é dado por 9 - 3 = 6;
- Para se determinar um valor de *outlier*, multiplica-se esse valor por 1.5, sendo assim, o valor 6*1,5 = 9;
- Sendo assim, um *outlier* é um número cuja diferença com Q1 é menor que 9, ou a diferença com Q3 é maior que 9. Ou seja, qualquer valor menor do que Q1 = 3 – 9 = -6 e qualquer valor maior do que Q3 = 9 + 9 = 18;
- Qualquer valor menor que -6 e maior que 18 deve ser considerado um *outlier*, sendo assim, o valor 40 é um *outlier*.

Existem outras técnicas e algoritmos para detecção de *outlier*, essa é a mais simples.

Algoritmos de *Clustering*

Os algoritmos de *Clustering* são métodos de aprendizado não supervisionados usados para a criação de grupos homogêneos, dado um conjunto de dados com base em sua estrutura interna.

Clustering é um método frequentemente usado para análise exploratória dos dados, onde não há estimativas de quaisquer valores ou agrupamentos. As criações dos grupos ocorrem apenas se encontrando a semelhança entre os dados e agrupando-os em grupos ou *clusters*.

A ideia de semelhanças pode ser explicada com os seguintes exemplos:

Considere questões como:

1. Como faço para agrupar esses documentos por tópico?
2. Como faço para realizar segmentação de clientes para permitir programas de *marketing* direcionados ou especiais.

Note que a definição de "similaridade" é específica para o domínio do problema. Estamos definindo semelhança como esses pontos de dados com a mesma característica como "tópico" ou clientes que podem ser perfilados para uma mesma "faixa etária / renda / gênero" ou um "padrão de compra".

Se tivermos um vetor de medidas de um atributo dos dados, os pontos de dados agrupados em um *cluster* terão valores para a medição próxima uns dos outros dos pontos de dados agrupados em um *cluster* diferente. Em outras palavras, a distância (um inverso de semelhança) entre os pontos dentro de um *cluster* é sempre menor do que a distância entre pontos em um *cluster* diferente. Em um *cluster*, acabamos com um grupo apertado (homogêneo) de pontos de dados que estão distantes dos pontos de dados que acabam em um *cluster* diferente.

Note que a escolha do tipo de medida de distância é importante para a execução dos algoritmos de usam medidas de similaridades. Nesse caso, a principal função de distância que será utilizada é a distância euclidiana.

Segue um exemplo de agrupamento:

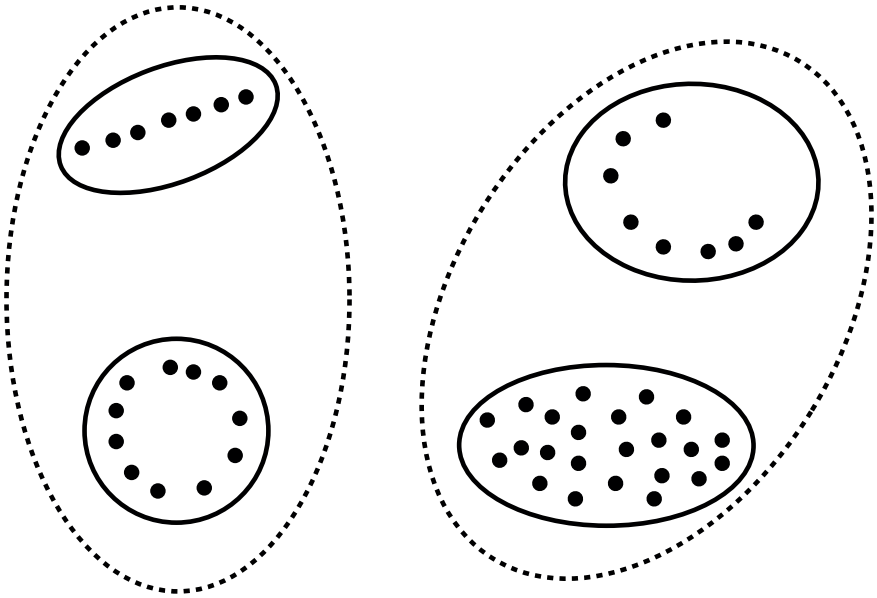


Figura 4 – Exemplo de *clusters*
Fonte: Theodoridis; Koutroumbas, 2008

À esquerda, dois agrupamentos que criam formas e, à direita, agrupamentos com pontos aleatórios, nesse caso usando duas dimensões, ou duas características ou ainda, dois atributos para a classificação.

Na literatura, são encontrados diversos tipos de algoritmos de *clustering*, dentre eles:

- **Métodos de partição:** para os quais são criados os *clusters* e são agregadas as instâncias a cada um dos *clusters* dada a execução dos algoritmos;
- **Métodos de *clusters* hierárquicos:** método que inicia criando-se tuplas, e aumentando o número de participantes do *clusters*, e agrupando as instâncias dada à similaridade, conforme se observa na figura, onde um dendograma é formado pela execução do algoritmo, onde, no eixo vertical, observa-se a escala de similaridade e, no eixo horizontal, as instâncias a serem agrupadas. Notem que a cada nível aumenta no número de participantes do *cluster*, chegando até o nível máximo, que será o número total de instâncias do modelo.

```
<!-- Generator: Adobe Illustrator 22.1.0, SVG Export Plug-In  -->

<svg version="1.1"

        xmlns="http://www.w3.org/2000/svg"
xmlns:xlink="http://www.w3.org/1999/xlink"
xmlns:a="http://ns.adobe.com/AdobeSVGViewerExtensions/3.0/"

        x="0px" y="0px" width="14px" height="14px" viewBox="0 0 14 14"
style="enable-background:new 0 0 14 14;" xml:space="preserve">
```

```
<style type="text/css">

      .st0{fill:#FF0000;}

</style>

<defs>

</defs>

<circle class="st0" cx="7" cy="7" r="7"/>

</svg>v
```

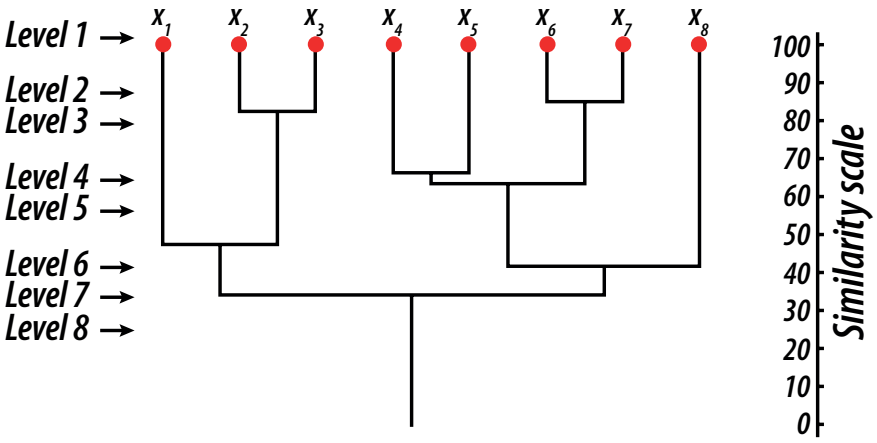


Figura 5 – Dendograma gerado pelo método de *clustering* hierárquico

- **Métodos com base em densidade de objetos:** a ideia principal é continuar o crescimento de um *cluster* à medida em que sua densidade ou quantidade de objetos em sua vizinhança tenha uma proximidade determinada. Esse método permite criar *clusters* de forma arbitrária com regiões densas separadas entre si por dados dispersos, o algoritmo comumente mencionado na literatura é o DBSCAN.

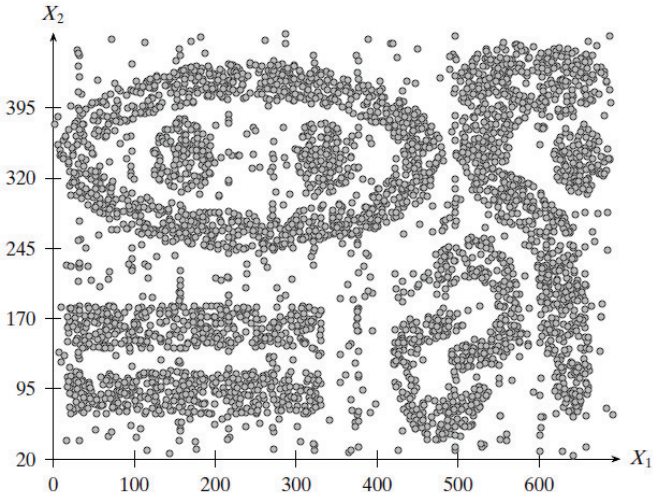


Figura 6 – Exemplo de *clusters* utilizando a técnica de densidade
Fonte: Zaki; Meira Junior, 2014

- **Métodos que utilizam estruturas de grafo:** nesse caso, os vértices são os objetos e suas ligações ou arestas são suas similaridades; ao analisar a estrutura do grafo ou rede gerada, é possível se criar os *clusters*.

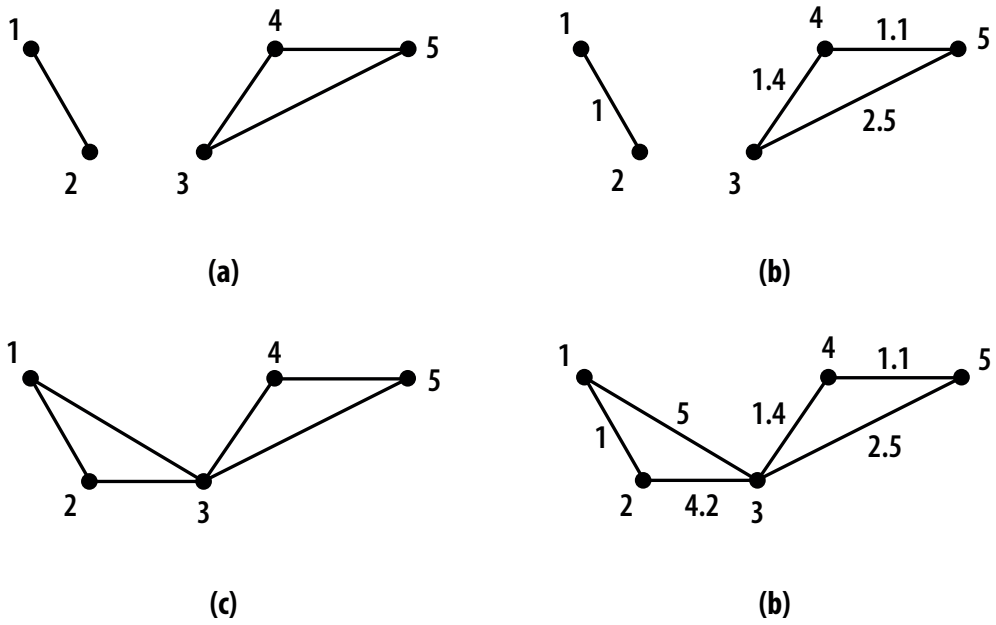


Figura 7 – Exemplo de *clusters* usando a estrutura dos grafos

Observe que os objetos deverão ser representados por seus atributos, por exemplo, idade, peso, sexo, cor de pele e altura, podem ser características ou atributos que poderão representar um indivíduo.

Segue um exemplo de representação de instâncias:

P1 = {34, 71, M, Branca, 1.72}

P1 = {34, 58, F, Branca, 1.65}

O Algoritmo *K-means*

O algoritmo de *clustering k-means* foi proposto incialmente por MacQueen (1967), e utiliza medidas de similaridade entre os objetos.

O algoritmo deve receber como parâmetro a quantidade de grupos ou *clusters* nos quais se deseja agrupar os objetos. O algoritmo escolhe aleatoriamente *N* objetos, que se tornam representantes de cada *cluster*, chamados de centroides. A cada iteração do algoritmo, os outros objetos são alocados nos *clusters*, ou seja, o objeto é colocado no *cluster* do centroide mais próximo. A cada iteração, o algoritmo recalcula o centroide, usando a média das distâncias entre todos os integrantes do *cluster*. Segue a figura que ilustra o funcionamento do algoritmo.

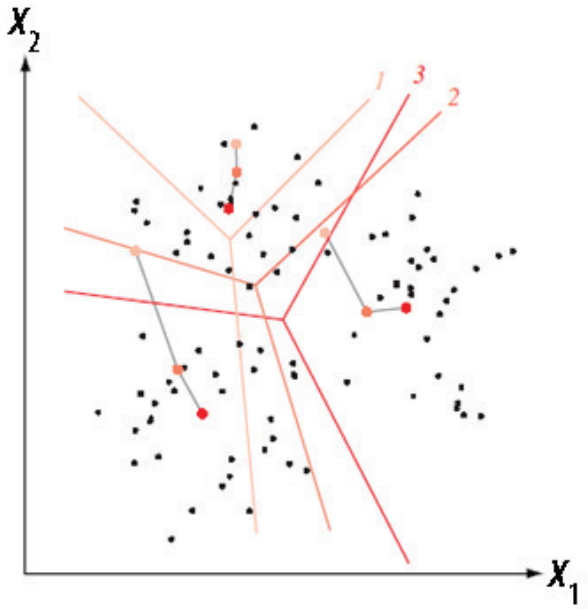


Figura 8 – Representação em duas dimensões de iterações do algoritmo k-means
Fonte: Duda; Hart, 2000

A figura anterior representa em duas dimensões algumas iterações do algoritmo *k-means*, onde inicialmente os centroides definidos aleatoriamente e a cada iteração do algoritmo eles vão convergindo e ficando mais próximos das instâncias de seu *cluster*. Note pela figura que os centroides vão mudando de lugar e suas respectivas formações/divisões entre os grupos também, conforme as linhas marcadas com 1, 2 e 3 se modificam.

Quando não ocorrerem mais variações nos posicionamentos dos centroides, significa que o algoritmo convergiu. A figura ilustra o pseudocódigo do algoritmo (DOUGHERTY, 2012).

```
Input: E = {e_1, e_2, ..., e_n} (set of entities to be clustered)
       k (number of clusters)
       MaxIters (limit of iterations)
Output: C = {c_1, c_2, ..., c_k} (set of cluster centroids)
        L = {l(e) | e = 1, 2, ..., n} (set of cluster labels of E)

foreach c_i ∈ C do
  | c_i ← e_j ∈ E (e.g. random selection)
end
foreach e_i ∈ E do
  | l(e_i) ← argminDistance(e_i, c_j) j ∈ {1...k}
end

changed ← false;
iter ← 0;
repeat
    foreach c_i ∈ C do
      | UpdateCluster(c_i);
    end
    foreach e_i ∈ E do
      | minDist ← argminDistance(e_i, c_j) j ∈ {1...k};
      | if minDist ≠ l(e_i) then
      |   | l(e_i) ← minDist;
      |   | changed ← true;
      | end
    end
    iter + +;
until changed = true and iter ≤ MaxIters ;
```

Figura 9 – Pseudo-código do algoritmo *k-means*
Fonte: DOUGHERTY, 2012

O algoritmo executa da seguinte maneira:

- Escolha *K*, o número de *cluster* que se deseja classificar;
- Aleatoriamente defina os posicionamentos de cada um dos *k* centroides;
- Atribua cada instância ao seu centroide mais próximo;
- Recalcule o valor de cada um dos centroides dada a média de todas as instâncias do *cluster*;
- Repita essa função de atribuir instâncias e recalcular as posições dos centroides até que não ocorram mais variações no posicionamento dos centroides.

Note que o algoritmo *K-means* é relativamente simples, seu tempo de execução vai depender da quantidade de *k*, a escolha dos valores iniciais para os centroides e o critério de parada, que pode ser o número máximo de iterações ou, caso se tenha que de fato, só parar a execução do algoritmo após a paralização completa das posições dos centroides.

Segue mais um exemplo ilustrado do passo a passo que ocorre com a execução do algoritmo para um exemplo hipotético com $k = 3$:

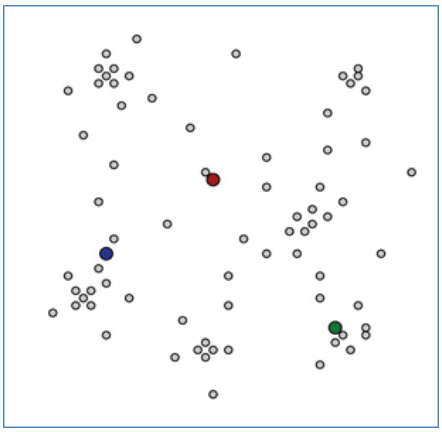


Figura 10

No passo 1, observa-se a escolha inicial dos centroides.

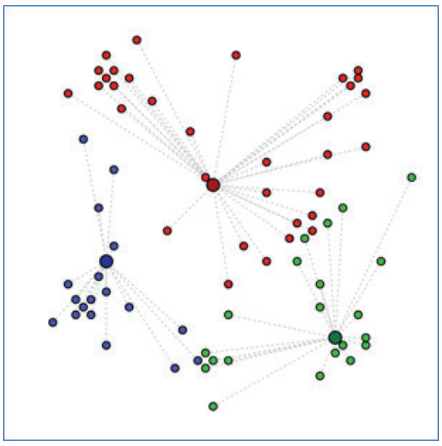


Figura 11

No passo 2, observa-se que o algoritmo calcula a distância de cada instância para os centroides e atribui a dada instância a um *cluster* específico.

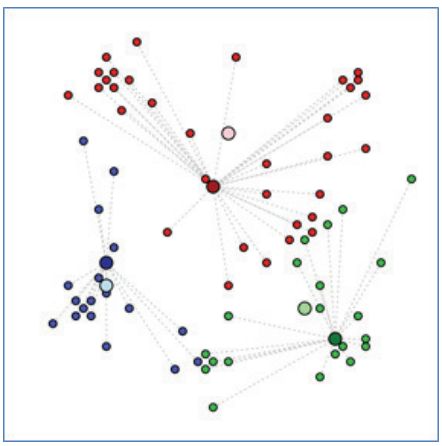


Figura 12

Nesse passo 3, ao se atribuírem as instâncias cada um dos grupos, a posição dos centroides devem ser revisadas, usando a média da posição de cada instância existente em seu *cluster*.

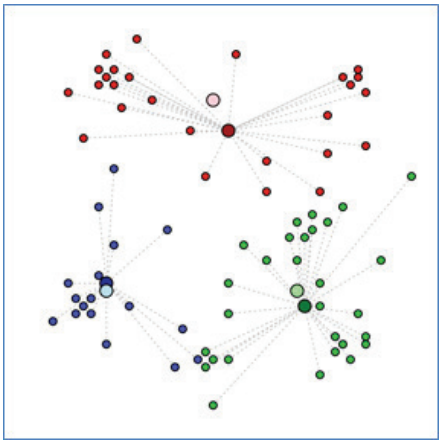


Figura 13

A repetição dos passos 2 e 3 ocorrem até que os centroides fiquem estáveis ou suas variações sejam extremamente pequenas e aceitáveis.

A saída do algoritmo deverá ser os respectivos valores dos centroides e as instâncias utilizadas no modelo classificadas em seus respectivos *clusters*.

Existem diversas ferramentas que implementam o algoritmo *k-means*, por exemplo, o *software Weka*, a plataforma *Mahout*, que pode ser instalada sob o *Hadoop*, a plataforma *Spark*, que também é executada sobre o *Hadoop*, o *software R*, bastante utilizado em análise de *Big Data*, dentre outros softwares para análise de dados. Algumas dessas ferramentas serão elencadas nas leituras obrigatórias ou materiais complementares.

Validação de *Clusters*

Um outro aspecto importante em análise e reconhecimento de padrões é a validação dos modelos propostos pelos algoritmos. Na análise de *clustering*, é sempre importante se conhecer o domínio de aplicação para que se possa fazer a análise do modelo criado e utilizar técnicas de validação, embora não sejam técnicas simples para a implementação algorítmica.

Dada a grande variedade de algoritmos de *clustering*, observa-se também uma grande variedade de técnicas de validação, que levam em consideração medidas internas aos *clusters* e medidas externa, considerando o modelo completo (ZAKI; MEIRA JUNIOR, 2014).

- **Medidas externas:** as medidas de validação externa utilizam critérios que não são inerentes ao conjunto de dados, mas sim ao domínio de aplicação. Isso pode ser na forma de conhecimento prévio ou especializado sobre os *clusters*, por exemplo, as instâncias foram previamente etiquetadas, com informações oriundas de conhecimento de especialistas e se faz uma validação a partir dos erros e acertos do algoritmo, sem levar em consideração medidas específicas. Para esse tipo de técnica, podem-se usar as medidas chamada *F-measure*, que deverão medir a precisão do algoritmo como um todo, técnica comumente utilizada para validação de classificadores ou detecção de *outliers*.
- **Medidas internas:** as medidas internas de validação empregam critérios que são derivados dos dados em si. Por exemplo, podemos usar distâncias *intracluster* e *intercluster* para obter medidas de coesão do *cluster* (por exemplo, quão semelhantes são os pontos no mesmo *Cluster*?) e de separação (por exemplo, quão distantes estão os pontos em diferentes *clusters*?).

Observe que a validação de um modelo de *cluster*, na verdade, faz avaliação se a quantidade de *clusters* ou grupos gerados é adequada para o conjunto de dados utilizados para a geração do modelo.

Vamos nos concentrar em duas medidas internas de validação de *clusters*. Nesse caso, é a medida interna que utiliza a soma dos erros quadrados e o coeficiente de silhueta.

Medida de Soma dos Erros Quadrados

A medida de soma dos erros quadrados irá mostrar o valor da soma total das distâncias entre cada instância e seus respectivos centroides. Nesse caso, utilizando a distância euclidiana como medida. Caso esse valor seja muito alto, significa que o *cluster* em si não é coeso e, possivelmente, poderá ser separado e, caso esse valor seja muito baixo, significa que o *cluster* está muito especializado, ou seja, poderá se juntar ao outro.

Segue a especificação da equação para a soma dos erros quadrados, utilizando a distância euclidiana:

- Distância euclidiana é dada por:

$$d = \sqrt{\sum_{k=1}^{n} \left(p_{ik} - p_{jk} \right)^2}$$

- O SSE, ou a soma dos erros quadrados, será a soma da distância euclidiana ao quadrado de cada instância do *cluster* para seu centroide, dada por:

$$SSE\left(C_i\right) = \sum_{i}^{n} d\left(x, ci\right)^2$$

- Nesse caso, calculando apenas a coesão de um dado *cluster*, mas pode-se também calcular a erro quadrado do modelo completo. Nesse caso, esse valor é dado pelo somatório do SSE de cada *cluster*:

$$SSE = \sum_{i}^{n} SSE\left(C_i\right)$$

Para se validar o modelo proposto, é importante executar essa validação para inúmeros valores de K, ou seja, executar o algoritmo iniciando com K igual a 1 e aumentando gradativamente; para cada execução do algoritmo, calcular o SSE total e se plotar em um gráfico. A minimização dessa soma de erros quadrado ilustrará graficamente a qualidade do modelo gerado. Segue uma imagem que ilustra um modelo hipotético.

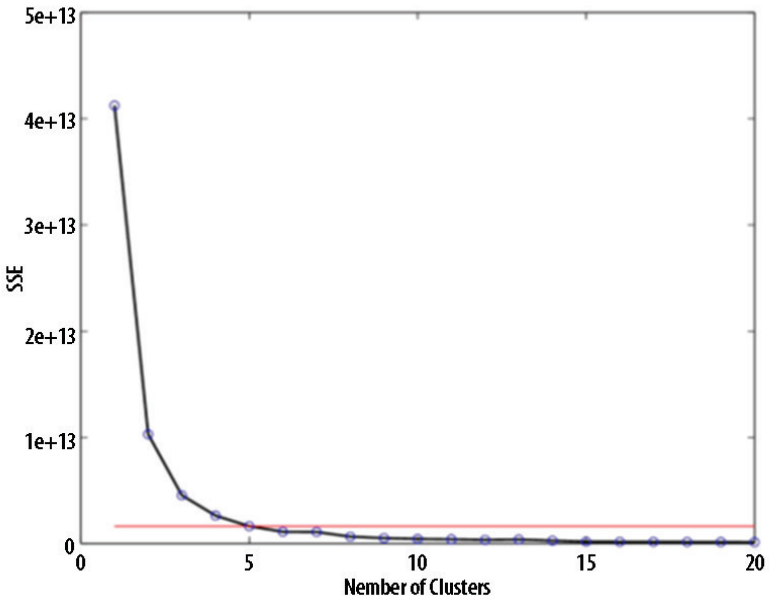


Figura 14 – Decaimento de ESS para a validação do modelo proposto
Fonte: SOUZA, 2015

O ponto ideal do número de *cluster* será no chamado joelho da curva. No gráfico ilustrado pela figura, observa-se o valor de $K = 5$, note que, com $k = 1$ o modelo possui um erro muito grande, e para o $k = 20$ o modelo fica extremamente especializado. Nesse caso, com k tendendo ao número de instância o erro quadrado tende a 0, sendo assim, o meio termo é um número ideal de *clusters* para o modelo.

Material Complementar

Indicações para saber mais sobre os assuntos abordados nesta Unidade:

Sites

Agrupamento via *K-Harmonic Means* para base Ruspini com $k = 4$

Segue o link de uma tese para leitura complementar no qual o autor faz pesquisas sobre os algoritmos de agrupamento.

https://goo.gl/YvcZg2

Leitura

Mineração de Dados

Segue a leitura complementar do livro de Mineração de Dados presente na Minha Biblioteca. Destacamos a leitura do capítulo 4 dedicado aos algoritmos de *clustering*.

https://goo.gl/sYKicd

Mineração de Dados

Segue a leitura complementar do livro de Mineração de Dados presente na Minha Biblioteca. Destacamos a leitura do capítulo 8 dedicado às técnicas de detecção de anomalias.

https://goo.gl/936MqZ

***Outliers*, o que são e como tratá-los em uma análise de dados?**

Segue a leitura complementar que traz um artigo sobre os *outliers*.

https://goo.gl/Sn1GLS

Referências

DOUGHERTY, G. ***Pattern Recognition and Classification***: *An Introduction*. 2013. ed. [S.l.]: Springer, 2012.

DUDA, R. O.; HART, P. E.; STORK, D. G. ***Pattern Classification***. 2. ed. Wiley-Interscience, 2000. ISBN: 0471056693.

SOUZA, A. M. da C. **Uma nova arquitetura para Internet das Coisas com análise e reconhecimento de padrões e processamento com *Big Data***. 2015. Tese (Doutorado em Sistemas Eletrônicos) – Escola Politécnica, Universidade de São Paulo, São Paulo, 2015. Disponível em: <http://www.teses.usp.br/teses/disponiveis/3/3142/tde-20062016-105809/>. Acesso em: 2017-03-07.

THEODORIDIS, S.; KOUTROUMBAS, K. ***Pattern Recognition***. 4. ed. Academic Press: 2008.

ZAKI, M. J.; MEIRA JUNIOR, W. ***Data Mining and Analysis***: *Fundamental Concepts and Algorithms*, Cambridge University Press, May 2014. ISBN: 9780521766333, disponível em <http://www.dataminingbook.info/pmwiki.php/Main/BookPathUploads?action=downloadman&upname=book-20160121.pdf> Acesso em 2017-03-07.


Cruzeiro do Sul
Educacional