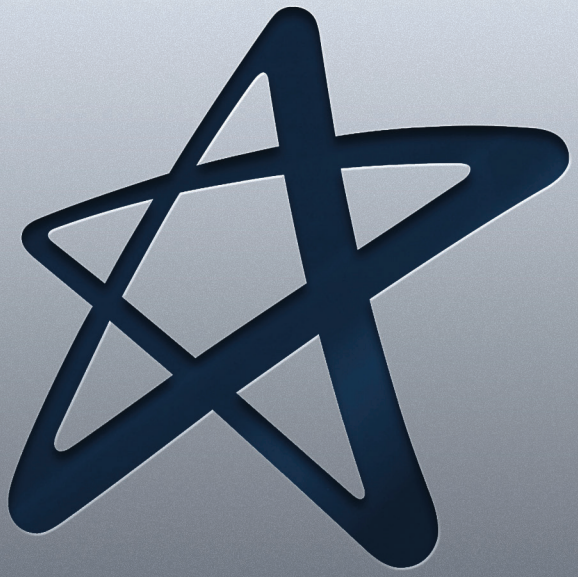
Mineração de Dados



Cruzeiro do Sul Virtual
Educação a distância

Material Teórico

Algoritmos de Regressão e Classificação

Responsável pelo Conteúdo:
Prof. Dr. Alberto Messias

Revisão Textual:
Prof.ª Dr.ª Selma Aparecida Cesarin

UNIDADE
Algoritmos de Regressão e Classificação

- Regressão Linear;
- Algoritmos de Classificação;
- Algoritmo de Classificação *Naïve Bayes;*
- Árvore de Decisões;
- Validação Cruzada e Curva *Roc;*
- Validação Cruzada.



OBJETIVO DE APRENDIZADO

- Apresentar as técnicas de regressão e os algoritmos de classificação, bem como o algoritmo *Naive Bayes*, as árvores de decisão e, por fim, as técnicas de validação dos modelos gerados, como a validação cruzada e a curva ROC para classificadores.

Orientações de estudo

Para que o conteúdo desta Disciplina seja bem aproveitado e haja maior aplicabilidade na sua formação acadêmica e atuação profissional, siga algumas recomendações básicas:



Assim:

- ✓ Organize seus estudos de maneira que passem a fazer parte da sua rotina. Por exemplo, você poderá determinar um dia e horário fixos como seu "momento do estudo";
- ✓ Procure se alimentar e se hidratar quando for estudar; lembre-se de que uma alimentação saudável pode proporcionar melhor aproveitamento do estudo;
- ✓ No material de cada Unidade, há leituras indicadas e, entre elas, artigos científicos, livros, vídeos e *sites* para aprofundar os conhecimentos adquiridos ao longo da Unidade. Além disso, você também encontrará sugestões de conteúdo extra no item **Material Complementar**, que ampliarão sua interpretação e auxiliarão no pleno entendimento dos temas abordados;
- ✓ Após o contato com o conteúdo proposto, participe dos debates mediados em fóruns de discussão, pois irão auxiliar a verificar o quanto você absorveu de conhecimento, além de propiciar o contato com seus colegas e tutores, o que se apresenta como rico espaço de troca de ideias e de aprendizagem.

Regressão Linear

A **predição numérica** ou **regressão** é definida como uma técnica para se prever valores numéricos a partir de uma dada entrada. Por exemplo, uma situação industrial na qual se deseja prever a quantidade de metros cúbicos de água poluída por um determinado componente na saída de água corrente em um processo químico, dado que esse valor está relacionado à temperatura de entrada da água.

Observa-se, nesse caso, que a variável de quantidade é dependente da variável de temperatura. Nesse exemplo, as técnicas de regressão podem ser utilizadas para a predição dos valores (LARSON; FARBER, 2010; NAVIDI, 2014).

Para prever uma variável dependente a partir de outra independente, usando a regressão linear, faz-se necessário determinar a equação da reta de regressão que melhor modela os dados. A reta de regressão e sua equação podem ser usadas na predição do valor de y para um dado valor de x (LARSON; FARBER, 2010).

Uma reta de regressão ou reta de ajuste ótimo é aquela para a qual a soma dos quadrados dos resíduos é mínima.

A equação de uma reta de regressão para uma variável independente x e uma variável dependente y é dada por: $y' = mx + b$, onde, y' é o valor y previsto para um valor x dado.

A inclinação m é dada por:

$$m = \frac{n\sum xy - (\sum x)(\sum y)}{n\sum x^2 - \left(\sum x\right)^2}$$

O intercepto b é dado por:

$$b = \bar{y} - m\bar{x} = \frac{\sum y}{n} - m\frac{\sum x}{n},$$

onde,

$\bar{x}$ e $\bar{y}$ são as médias de valores nos conjuntos de dados x e y.

A reta de regressão passa sempre pelo ponto$(\bar{x};\bar{y})$ (LARSON; FARBER, 2010).

A Figura 1 exemplifica valores de temperatura de entrada de água e quantidade de metros cúbicos de água poluídos.

Tabela 1 – Com exemplos de valores de temperatura de entrada e metros cúbicos de água poluída

Temperatura (/10) X	Vendas da Empresa (metros cúbicos) Y
2,4	225,0
1,6	184,0
2,0	220,0
2,6	240,0
1,4	180,0
1,6	184,0
2,0	186,0
2,2	215,0

Fonte: adaptado de (Navidi, 2014)

Para o exemplo ilustrado pela Tabela, observa-se,

$$n = 8,\ \sum x = 15{,}8,\ \sum y = 1634,\ \sum xy = 3289{,}9 \text{ e } \sum x^2 = 32{,}44.$$

Esses valores podem ser utilizados para calcular a inclinação m, aplicando-se a segunda equação, e o intercepto b da reta de regressão, aplicando-se a terceira equação conforme segue, respectivamente:

$$m = \frac{8(3289{,}8) - (15{,}8)(1634)}{8(32{,}44) - 15{,}8^2} = \frac{501{,}2}{9{,}88} \approx 50{,}7287$$

$$b = \bar{y} - m\bar{x} = \frac{1634}{8} - (50{,}7287)\frac{15{,}8}{8} = 204{,}25 - (50{,}7287)(1{,}975) \approx 104{,}0608$$

Portanto, a equação da reta de regressão para o exemplo citado é dada por:

$$\hat{y} = 50{,}729x + 104{,}061$$

Para esse exemplo, discutido em Larson e Farber (2010), consegue-se prever qualquer valor de metros cúbicos de água poluídos, dado por y, dependente da temperatura de passagem da água, dada por x.

Em outros ambientes, um melhor modelo de previsão para uma variável dependente pode ser obtido com a ajuda de mais de uma variável independente.

Modelos que contêm mais de uma variável independente são modelos de regressão múltipla, que seguem o mesmo raciocínio da regressão linear com uma única variável.

Note que a implementação é relativamente simples, mas também é facilmente encontrada nas ferramentas de BI, mineração de dados ou *Big Data*.

Algoritmos de Classificação

As **Técnicas de Classificação** podem ser utilizadas para classificar objetos num determinado número de categorias ou classes.

Em Dougherty (2012), é citado que, para dividir objetos em classes, é necessário observar as características dos objetos, verificar quais características discriminam melhor as classes e a partir delas iniciar o processo de classificação.

Em Theodoridis e Koutroumbas (2008), e em Dougherty (2012), são encontradas diversas técnicas de classificação, como, por exemplo, classificadores probabilísticos, classificadores baseados na Teoria de Decisão de *Bayes*, classificadores lineares baseados em funções de probabilidade, classificadores baseados em rede neurais, métodos estocásticos e classificadores polinomiais, dentre outros.

Para a criação de classificadores, deve-se, inicialmente, passar por uma etapa de treinamento, na qual é criado um conjunto de treinamento, no qual se conhece a quais classes essas instâncias de treinamento pertencem, para que seja possível, posteriormente, o classificador associar novas instâncias a essas classes inicialmente impostas a ele.

Algoritmo de Classificação *Naïve Bayes*

O **algoritmo *Naïve Bayes*** é um classificador probabilístico baseado na Lei de *Bayes* e noções de suposições de independência condicional.

Em outras palavras, o algoritmo *Naïve Bayes* assume que a presença ou a ausência de uma característica específica ou atributo de uma classe não está relacionada à presença ou à ausência de qualquer outra característica.

Por exemplo, um objeto pode ser classificado numa categoria específica com base em seus atributos, como forma, cor e peso. Uma classificação razoável para um objeto, que é esférico, amarelo e com menos de 60 gramas de peso pode ser uma bola de tênis.

Mesmo que esses recursos dependam um do outro ou da existência dos outros recursos, um classificador bayesiano considera que todas essas propriedades contribuem de forma independente para a probabilidade de o objeto ser uma bola de tênis.

As variáveis de entrada são, geralmente, discretas ou categóricas, mas existem outras variações dos algoritmos que trabalham com variáveis contínuas.

Embora o peso possa ser considerado uma variável contínua, no exemplo da bola de tênis, o peso foi agrupado em intervalos para aumentar o peso de uma variável categórica.

Geralmente, o resultado retorna um índice de probabilidade e associação de classe. A saída da maioria das implementações são pontuações de *LOG* da probabilidade para todas as classes; sendo assim, atribui-se dado objeto à classe que ele tiver o maior índice.

Os classificadores bayseanos são bastante utilizados em classificação de documentos e em detecção de fraudes ou *outliers*.

O algoritmo se baseia na regra de *Bayes*, que utiliza a Teoria de Probabilidade e de Probabilidade Condicional.

Segue a especificação da Regra de *Bayes*:

$$p(C \left| A) = \frac{P(A \cap C)}{P(A)} = \frac{P(A \left| C)P(C)}{P(A)}\right.$$

onde

a probabilidade condicional de C dado que A ocorreu, dada por P (C | A), a probabilidade de A é a mesma que a probabilidade condicional de A, dado C, dado por P (A | C), multiplicada pela probabilidade de C.

Ambos os termos são iguais a P (A ^ C) que é a probabilidade A e C ocorrerem simultaneamente, por fim, dividem-se os três por P (A).

Note que:

- C é a classe específica: C ϵ {C_1, C_2, … C_n}
  - » A é o conjunto de atributos do objeto observado: A = (a_1, a_2, … a_m)
- P(C | A) é a probabilidade de C dado que A é observado, é o que chamamos de probabilidade condicional.

Segue um exemplo prático com as seguintes probabilidades:

P (C) = probabilidade de ter a doença = 0,05

P (¬C) = probabilidade de não ter a doença = .95

P (A | C) = probabilidade de teste positivo, se tiver a doença = .95

P (A | CC) = probabilidade de teste positivo, se não tiver a doença = .1

A fim de testar se o teste é confiável, resolve-se a probabilidade de ter a doença, dado que você tem um resultado de teste positivo, P (C | A).

Usando a regra de *Bayes*, P (C | A) = P (A | C) P (C) / P (A).

Precisamos calcular P (A):

P (A) = probabilidade de teste positivo = P (C) * P (A | C) + P (¬C) * P (A | ¬C) = .05 * .95 + .95 * .1 = 0.1425

Então,

P (C | A) = P (A | C) P (C) / P (A) = (.95 * .05) / 0.1425 = 1/3,

o que significa que a probabilidade de um paciente ter a doença dado ao paciente testado ser positivo é apenas um terço.

O classificador de *Bayes* irá, então, retornar a classe à qual o objeto tiver maior probabilidade de estar.

Para isso, ele calcula usando a regra de *Bayes* para todas as classes. Note que, caso haja mais atributos, o resultado será o produtório da probabilidade de todos os atributos para a determinada classe.

Conforme segue:

$$P(a_1, a_2, ..., a_m | C_i) = P(a_1 | C_1)P(a_2 | C_1)...P(a_m | C_i)...P(a_m | C_i) = \prod_{j=1}^{m} P(a_j | C_i)$$

Sendo assim, para se desenvolver o classificador, é necessário calcular as seguintes estatísticas para o conjunto de dados de treinamento:

- $P(C_i)$ para todas as classes.
- $P(a_j | C_i)$ para todas as possíveis a_j e C_i
- Retornar a classe, Ci, que possua a maior probabilidade de estar.

Há variações do algoritmo *Naive Bayes* para atributos numéricos; nesses casos, usando a média e a variância para cada atributo.

Árvore de Decisões

Uma **árvore de decisão** consiste em nós internos que representam as decisões correspondentes aos hiperplanos ou pontos de divisão entre as classes, e nós de folha que representam regiões ou partições do espaço de dados, que são rotulados com a maioridade da classe.

Uma região é, então, caracterizada pelo subconjunto de pontos de dados que se encontram nela.

O algoritmo é relativamente simples, tendo em vista que os pontos de divisão entre as classes estão previamente definidos.

Segue um exemplo gráfico:

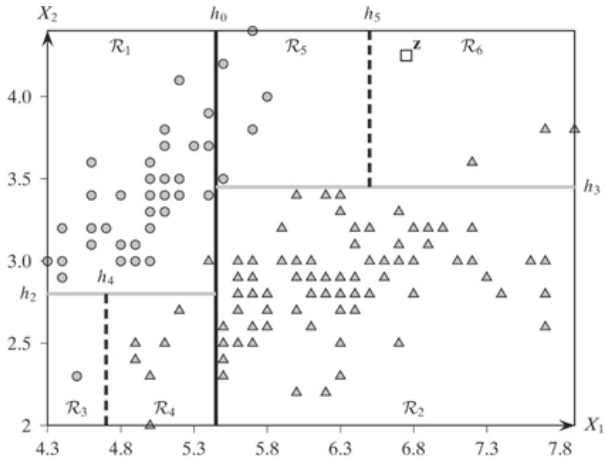


Figura 1 – Exemplo gráfico de hiperplanos que separam as classes
Fonte: Zaki; Meira, 2014

Nesse caso, os pontos de divisão criam hiperplanos que irão dividir as classes.

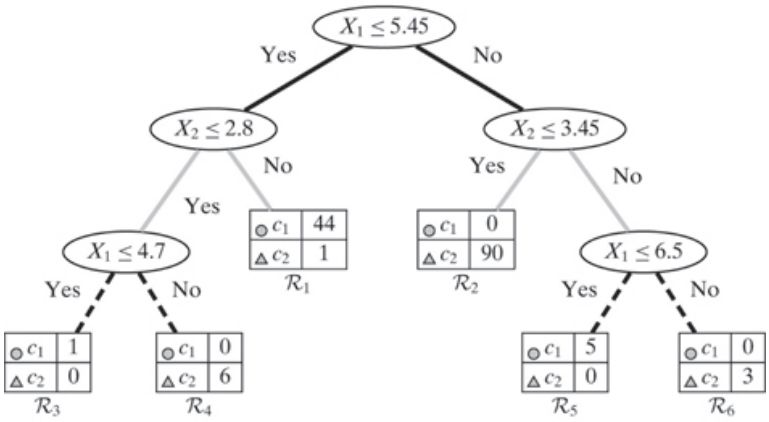


Figura 2 – Exemplo de árvore de decisão com os pontos de divisão
Fonte: Zaki; Meira, 2014

Os mesmos pontos de divisão permitem a criação da árvore de decisão. Sendo assim, a execução do algoritmo, dadas as definições dos pontos de divisão, é relativamente simples.

A árvore em si é um conjunto de regras que encaixa os objetos em classes, dados os seus atributos.

Segue um exemplo do conjunto de regras da árvore ilustrada anteriormente:

R_3 :Se $X_1 \leq 5.45$ e $X_2 \leq 2.8$ e $X_1 \leq 4.7$, a classe é c_1, ou

R_4 : Se $X_1 \leq 5.45$ e $X_2 \leq 2.8$ e $X_1 > 4.7$, a classe é c_2, ou

R_1 : Se $X_1 \leq 5.45$ e $X_2 > 2.8$, a classe é c_1, ou

R_2 : Se $X_1 > 5.45$ e $X_2 \leq 3.45$, a classe é c_2, ou

R_5 : Se $X_1 > 5.45$ e $X_2 > 3.45$ e $X_1 \leq 6.5$, a classe é c_1, ou

R_6 : Se $X_1 > 5.45$ e $X_2 > 3.45$ e $X_1 > 6.5$, a classe é c_2

O aspecto fundamental é como chegar aos pontos de divisão. Para isso, existem algumas métricas e a mais comumente utilizada é a Entropia ou Teoria da Informação.

A Entropia, em geral, mede a quantidade de desordem ou de incerteza em um Sistema.

Em algoritmos de classificação, uma partição de dados possui entropia inferior quando possui baixa desordem, se for relativamente pura, ou seja, se a maioria dos pontos tiverem o mesmo rótulo.

Por outro lado, uma partição possui maior entropia ou mais desordem se os objetos forem misturados, e não há uma classe principal; em outras palavras, há objetos de classes diferentes misturados. A entropia mede, então, o grau de pureza de uma classe.

Sendo assim, o algoritmo vai dividindo os grupos e calculando a pureza, dados os parâmetros iniciais de tamanho de folha e limiar de pureza necessário.

O cálculo da entropia ou ganho de informação para um dado grupo pode ser feito da seguinte maneira:

$$H(D) = -\sum_{i=1}^{k} P(c_i|D)\,\log_2 P(c_i|D),$$

onde,

D é o conjunto a ser medido, $P(c_i | D)$ é a probabilidade da classe ci ocorrer no conjunto D e K é o número total de classes existentes.

Caso o grupo seja puro, significa que todos os objetos são da mesma classe e sua entropia será 0.

Note que esse tipo de cálculo pode ser aplicado a um determinado atributo, de modo a se verificar se ele é relevante para a definição de classe, nesse caso, usando também a entropia como base.

Validação Cruzada e Curva Roc

Os métodos mais comuns para validação de modelo em algoritmos de classificação são a **curva ROC**, que usa métricas de acerto e erro do algoritmo, nesse caso, a ***F-measure*** ou, ainda, a **validação cruzada**.

Vamos falar sobre a *F-measure* que mede, na verdade, a quantidade de acertos e de erros dos algoritmos, conhecida como acurácia.

Essa medida soma os seguintes acertos e erros do algoritmo:

- **Verdadeiro Positivo** (**TP – *True Positive***): trata-se do número de pontos classificados corretamente como positivos;
- **Falso Positivo** (**FP – *False Positive***): número de pontos classificados como positivo; porém, é negativo para a dada classe, nesse caso, um erro;
- **Falso Negativo** (**FN – *False Negative***): número de pontos classificado como negativo para uma dada classe; porém, ele deveria ser positivo, que também se trata de um erro do algoritmo;
- **Verdadeiro Negativo** (**TN – *True Negative***): número de pontos classificados corretamente como negativos, ou seja, de fato não pertencem à classe dada.

Com base nesses somatórios, consegue-se chegar a algumas medidas como:

Taxa de Erro (***Error Rate***) – que é a fração de pontos classificados incorretamente, seja para positivo seja para negativo, dada por:

$$Error\ Rate = \frac{FP + FN}{n}$$

- **Taxa de Acertos ou Acurácia** (***Accuracy***) – que é a fração de pontos classificados corretamente, seja para negativo seja para positivo, dada por:

$$Accuracy = \frac{TP + TN}{n}$$

A partir desses indicadores, pode-se medir a precisão do algoritmo de classificação e, ainda, analisar-se a precisão por meio da curva ROC.

A curva ROC, ou *Receive Operating Characteristic*, possuirá uma área abaixo da curva AUC *(Area Under Curve)*, em que, para um classificador preciso, a área deverá ser 1, e para um classificador ruim ou impreciso, a área será 0, ou seja, classificadores que forem mais próximos de 1 tem melhor desempenho; classificadores aleatórios possuem AUC em 0,5.

Segue um exemplo Gráfico de uma AUC para um classificador dito como bom:

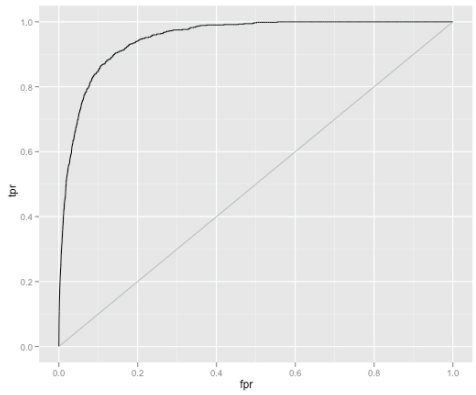


Figura 3 – Exemplo Gráfico de uma AUC para um classificador dito como bom
Fonte: Próprio Autor

Note que a reta entre os pontos (0,0) e (1,1) se trata de um classificador aleatório e o classificador em questão é representado pela curva presente no Gráfico.

Validação Cruzada

A **validação cruzada** é uma técnica relativamente simples, na qual se pode dividir a base de dados total de treinamento em parcela. Por exemplo, validação cruzada de 50%, em que o classificador será treinado com os 50% de dados representativos e validado com os outros 50%. Nesse caso, dado que se sabe o resultado da classificação, pode-se medir a acurácia do classificador.

Dessa maneira, conseguir aferir qual parcela do conjunto total de dados representa melhor o conjunto total e gera um melhor classificador.

Cabe destacar que as implementações desses principais algoritmos de classificação, bem como seus métodos de validação, são encontrados facilmente nas principais ferramentas para análise de Dados, como, por exemplo, o Software R, implementações em *Hadoop*, como *Spark* ou *Mahout*, ou o próprio *software Weka*, que poderá servir para provas de conceito e validações dos modelos antes de se colocar em produção com análise de *Big Data* ou BI propriamente dita.

Material Complementar

Indicações para saber mais sobre os assuntos abordados nesta Unidade:

Sites

Minha Biblioteca

Como leitura complementar, o capítulo 5 do livro de mineração de dados presente na Minha Biblioteca, capítulo dedicado aos algoritmos de classificação.

https://goo.gl/S8NnNn

Science Prog

Segue um *link* que ilustra um exemplo de execução do *Naive Bayes* no *Weka*.

https://goo.gl/X4GVM7

Dev Media

Segue um *link* no qual é possível fazer uma leitura sobre a regressão linear, bem como observar um exemplo prático.

https://goo.gl/cvWhzS

Referências

DOUGHERTY, G. ***Pattern Recognition and Classification:*** *An Introduction*. 2013. ed.[S.l.]: Springer, 2012.

LARSON, R.; FARBER, B. **Estatística aplicada.** 4. ed. São Paulo: Pearson Prentice Hall,2010.

MOHAMMED, J. Zaki; MEIRA JR., Wagner. ***Data Mining and Analysis***: *Fundamental Concepts and Algorithms.* Cambridge University Press. May 2014. Disponível em: <http://www.dataminingbook.info/pmwiki.php/Main/BookPathUploads?action=downloadman&upname=book-20160121.pdf>. Acesso em: 7 mar. 2017.

SOUZA, Alberto Messias da Costa. **Uma nova arquitetura para Internet das Coisas com análise e reconhecimento de padrões e processamento com *Big Data*.** 2015. Tese (Doutorado em Sistemas Eletrônicos) – Escola Politécnica, Universidade de São Paulo, São Paulo, 2015. Disponível em: <http://www.teses.usp.br/teses/disponiveis/3/3142/tde-20062016-105809/>. Acesso em: 7 mar. 2017.

THEODORIDIS, S.; KOUTROUMBAS, K. ***Pattern Recognition***, Fourth Edition. 4th. ed.[S.l.]: Academic Press, 2008.


Cruzeiro do Sul
Educacional