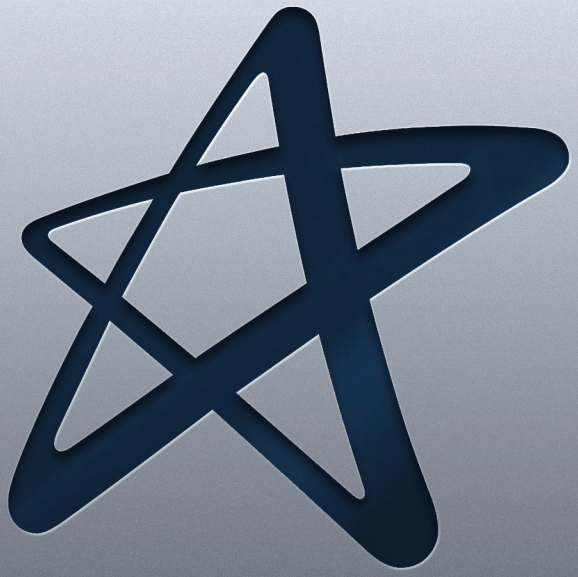
Mineração de Dados



Cruzeiro do Sul Virtual
Educação a distância

Material Teórico

Algoritmos e *Big Data* na Prática com *Apache Mahout*

Responsável pelo Conteúdo:
Prof. Dr. Alberto Messias da Costa Souza

Revisão Textual:
Prof.ª Me. Sandra Regina Fonseca Moreira

UNIDADE

Algoritmos e *Big Data* na Prática com *Apache Mahout*

- Projeto *Mahout*;
- Instalação do *Mahout*.



OBJETIVO DE APRENDIZADO

- Introduzir o projeto *Apache Mahout*, mostrar seu processo de instalação e, posteriormente, mostrar a execução do algoritmo *Kmeans* usando a implementação do *Mahout*, bem como analisar os resultados obtidos.

Orientações de estudo

Para que o conteúdo desta Disciplina seja bem aproveitado e haja maior aplicabilidade na sua formação acadêmica e atuação profissional, siga algumas recomendações básicas:



Assim:

- ✓ Organize seus estudos de maneira que passem a fazer parte da sua rotina. Por exemplo, você poderá determinar um dia e horário fixos como seu "momento do estudo";
- ✓ Procure se alimentar e se hidratar quando for estudar; lembre-se de que uma alimentação saudável pode proporcionar melhor aproveitamento do estudo;
- ✓ No material de cada Unidade, há leituras indicadas e, entre elas, artigos científicos, livros, vídeos e *sites* para aprofundar os conhecimentos adquiridos ao longo da Unidade. Além disso, você também encontrará sugestões de conteúdo extra no item **Material Complementar**, que ampliarão sua interpretação e auxiliarão no pleno entendimento dos temas abordados;
- ✓ Após o contato com o conteúdo proposto, participe dos debates mediados em fóruns de discussão, pois irão auxiliar a verificar o quanto você absorveu de conhecimento, além de propiciar o contato com seus colegas e tutores, o que se apresenta como rico espaço de troca de ideias e de aprendizagem.

Projeto *Mahout*

O projeto *Mahout* é um projeto de código livre da fundação *Apache* que possui uma biblioteca de implementação de algoritmos para aprendizagem de máquina. De acordo com Giacomelli (2013), o objetivo do projeto *Mahout* é ser uma escolha de ferramenta para aprendizado por máquina para processamento de conjuntos de dados extremamente grandes, tanto para execução em *clusters* de instâncias de *Hadoop* ou em uma única máquina. O *Mahout* é uma ferramenta desenvolvida em linguagem de programação *Java* dentro do projeto de computação distribuída *Hadoop*.

O projeto *Mahout* possui implementações de algoritmos de classificação e *clustering*, como o algoritmo *K-means* que possui grande relevância para o curso.

O projeto *Mahout* possui implementações de diversos algoritmos em sua execução direta no *Hadoop* com o *Mapreduce*, algoritmos em *Spark*, além de poder usar *frameworks* H2O e *Flink*.

Usando o *Mapreduce*, há os seguintes algoritmos implementados:

- **Classificação:**
  - *Naive Bayes;*
  - *Hidden Markov Models;*
  - *Logistic Regression;*
  - *Random Forest.*
- ***Clustering:***
  - *k-Means;*
  - *Canopy;*
  - *Fuzzy k-Means;*
  - *Streaming KMeans;*
  - *Spectral Clustering.*
- **Processamento pós-*clustering*:**
  - *Cluster Dumper tool;*
  - *Cluster visualisation.*
- **Redução de dimensionalidade:**
  - Singular *value decomposition;*

- Algoritmo *Lanczos;*
- *Stochastic* SVD;
- PCA (via *Stochastic* SVD);
- QR *Decomposition.*

• **Outras implementações de suporte:**

- *RowSimilarityJob;*
- *Collocations;*
- *Sparse TF-IDF Vectors* em Textos;
- XML *Parsing;*
- *Email Archive Parsing;*
- *Evolutionary Processes.*

Instalação do *Mahout*

A instalação do *framework Mahout* parte do pressuposto de que a plataforma *Hadoop* está instalada e em funcionamento adequado.

Após o *download* do pacote *Mahout*, deve-se descompactar e adicionar um *link* simbólico */usr/local* com o nome *mahout*:

```
wget  http://linorg.usp.br/apache/mahout/0.13.0/apache-mahout-distribution-
-0.13.0.tar.gz

tar xzf apache-mahout-distribution-0.13.0.tar.gz
rm apache-mahout-distribution-0.13.0.tar.gz
mv apache-mahout-distribution-0.13.0 /usr/local
ln -sf /usr/local/apache-mahout-distribution-0.13.0/ /usr/local/mahout
```

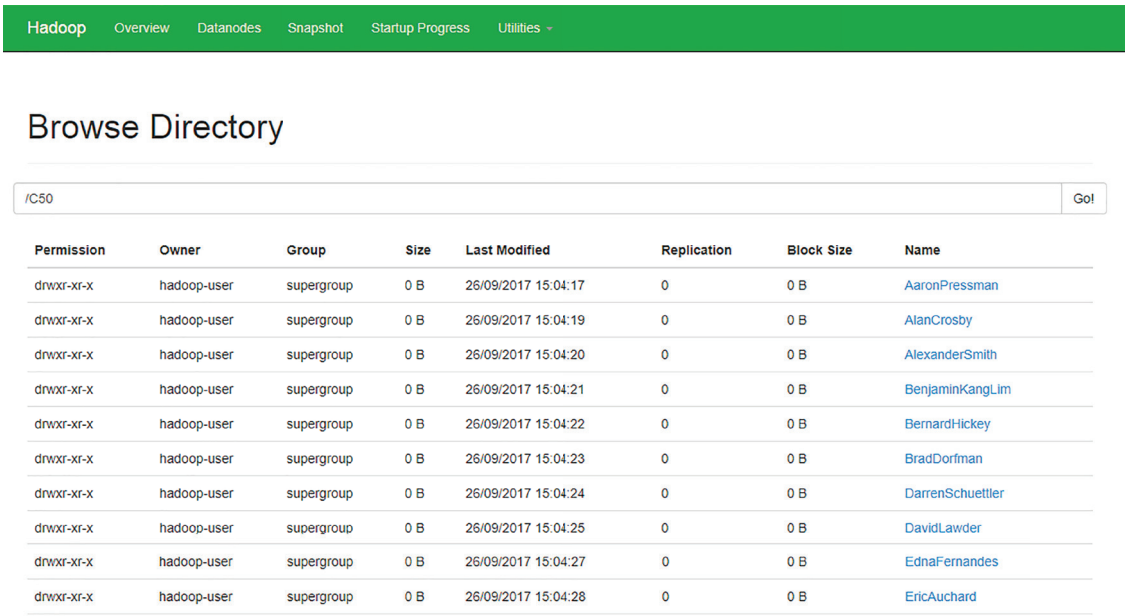
Execução de algoritmo *Kmeans* no *Hadoop*

Vamos utilizar a mesma base usada no exemplo de execução da contagem de palavras em *Hadoop*. Vamos iniciar pela cópia dos textos para o HDFS.

Segue o comando para a cópia dos arquivos com os textos:

```
hadoop fs -copyFromLocal C50 /
```

Segue a Figura que ilustra a correta cópia dos arquivos.



Permission	Owner	Group	Size	Last Modified	Replication	Block Size	Name
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:17	0	0 B	AaronPressman
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:19	0	0 B	AlanCrosby
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:20	0	0 B	AlexanderSmith
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:21	0	0 B	BenjaminKangLim
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:22	0	0 B	BernardHickey
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:23	0	0 B	BradDorfman
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:24	0	0 B	DarrenSchuettler
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:25	0	0 B	DavidLawder
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:27	0	0 B	EdnaFernandes
drwxr-xr-x	hadoop-user	supergroup	0 B	26/09/2017 15:04:28	0	0 B	EricAuchard

Figura 1

Inicialmente deve-se criar arquivos de vetores sequenciais para o processamento dos textos. Para isso, usa-se o comando "*seqdirectory*" presente no *Mahout*.

Segue o comando executado na base:

```
./mahout seqdirectory -i /C50/C50train -o /seqreuters -xm sequential
```

Nesse caso, são passados parâmetros de diretório ou arquivo de entrada, o diretório de saída do comando e o parâmetro que informa para se criar o vetor sequencial.

Saída do comando:



Figura 2

O próximo comando faz efetivamente a análise de textos a partir dos vetores criados, são criados, então, os vetores contendo o TF-IDF calculado para os termos e documentos existentes.

Segue o comando:

```
./mahout seq2sparse -i /seqreuters -o /train-sparse
```

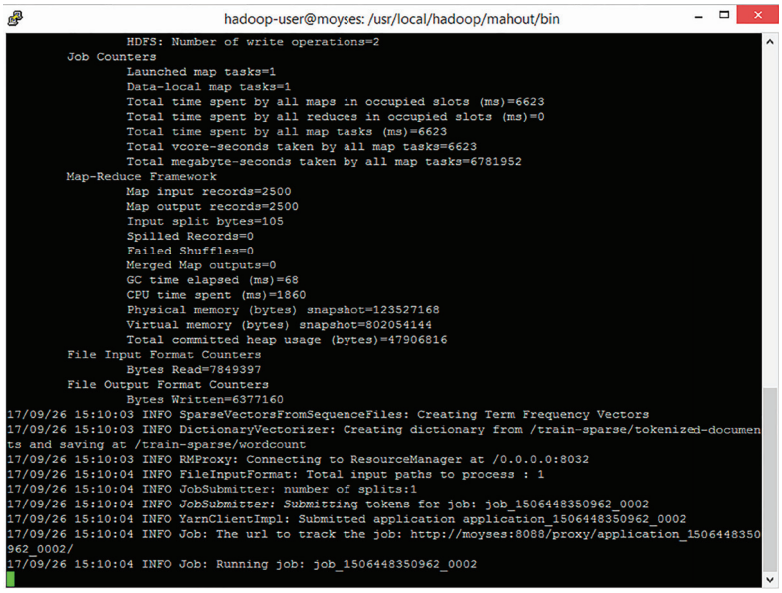


Figura 3

O comando recebe como parâmetro o diretório sequencial de entrada, o diretório para saída e o parâmetro que informa a criação de vetores de análise de texto, por padrão usando o TF-IDF "*seq2sparce*".

O próximo comando executa efetivamente o algoritmo *kmeans*:

```
./mahout kmeans -i /train-sparse/tfidf-vectors/ -c /kmeans-train-clusters -o /train-clusters-final -dm org.apache.mahout.common.distance.EuclideanDistanceMeasure -x 10 -k 10 -ow
```

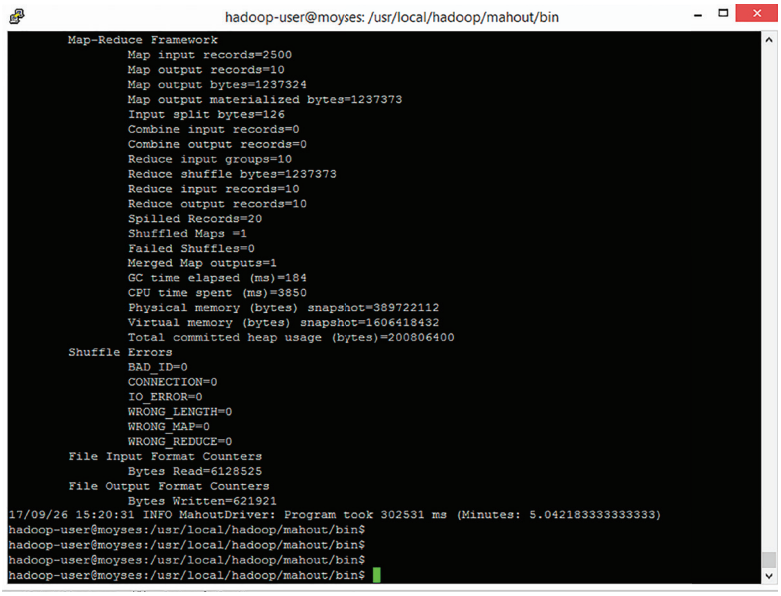


Figura 4

O comando de execução do *kmeas* recebe os seguintes parâmetros:

- **- i:** passa os vetores e valores de TF-IDF para o algoritmo;
- **- c:** indica o diretório de *clusters* iniciais;
- **- o:** indica o diretório de execução do algoritmo e onde ficarão armazenados os *clusters* gerados;
- **- dm:** indica o tipo de métrica de distância a ser utilizada, nesse caso, utilizando a distância euclidiana;
- **- x:** indica o número máximo de iterações do algoritmo, nesse caso, o valor máximo de 10 iterações;
- **- k:** indica o número de *clusters* do modelo a ser gerado pelo algoritmo, nesse caso, 10 *clusters*;
- **- ow:** indica que o algoritmo poderá sobrescrever os diretórios caso os indicados para saída não estejam vazios;

Note que a saída do algoritmo será no formato de vetores, assim, como o formato de entrada, será necessário converter os vetores de saída para texto plano. Para isso, o *mahout* disponibiliza a ferramenta "*clusterdump*" que permite a criação de um arquivo de saída com texto plano e no diretório de trabalho fora do HDFS.

```
./mahout clusterdump -d /train-sparse/dictionary.file-0 -dt sequencefile -i
/train-clusters-final/clusters-10-final -n 10 -b 100 -o ~/saida_clusters.txt
-p /train-clusters-final/clustered-points
```

Seguem os parâmetros passados para o comando "*clusterdump*":

- **-d:** indica o arquivo de dicionário, nesse caso, o dicionário inicialmente criado pelo comando de criação dos valores de TF-IDF;
- **-dt:** indica o tipo de dicionário que foi passado como parâmetro, nesse caso, o tipo era arquivos/vetores sequenciais;
- **-i:** indica o diretório de entrada para o comando, nesse caso, contendo os *clusters* criados pelo algoritmo *kmeans*;
- **-n:** indica o número de *top* termos existentes no *cluster*, nesse caso, o arquivo de saída conterá os 10 principais termos que caracterizam o *cluster*;
- **-b:** indica o texto que caracterizará o centroide, nesse caso, o parâmetro 100 indica os 100 caracteres inicias que caracterizam o centroide;
- **-o:** indica o arquivo de saída do comando, nesse caso, fora do HDFS;
- **-p:** indica os pontos que foram passados como parâmetros para a criação dos vetores e *clusters*.

O arquivo de saída possui as configurações dos *clusters* e seus principais termos. Segue o conteúdo do arquivo:

```
1:{“r”:[{“0”:0.473},{“0.01”:0.269},{“0.02”:0.329},{“0.03”:0.348},{“0.04”:0.
209},{“0.05”:0.498},{“0.06”
Top Terms:
million     =>  2.01768555414109
percent     =>  1.9796222609914702
its         =>  1.9652491679558388
company     =>  1.7706142707622095
billion     =>  1.7352270411921071
year        =>  1.6528963794638385
from        =>  1.6224009523461589
which       =>  1.5927217226762038
market      =>  1.5844123679639655
would       =>  1.553171214777908

2:{“r”:[{“1”:1.072},{“1,000”:2.487},{“1,900”:3.372},{“107”:1.021},{“171”:1.
986},{“20”:1.289},{“21”:1.9
Top Terms:
kwik          =>  19.68147373199463
bowler        =>  14.924392700195312
stores        =>  11.923139572143555
save          =>  11.16239881515503
superstores   =>  10.116906881332397
107           =>  10.109184741973877
save’s        =>  9.3254234790802
chilled       =>  7.99928092956543
graeme        =>  7.725433826446533
fabric        =>  7.725433826446533

3:{“r”:[{“0.01”:0.538},{“0.02”:0.538},{“0.03”:0.569},{“0.04”:0.591},{“0.05”
:0.499},{“0.06”:0.552},{“0.
Top Terms:
computer      =>   5.46894957037533
software      =>   5.239956008686739
microsoft     =>   4.4167699940064375
internet      =>   4.11774596045999
corp          =>   3.0309750865487493
computers     =>   2.993433007072
windows       =>   2.877699588326847
quarter       =>   2.790801902378307
apple         =>   2.7814465102027444
pc            =>   2.690458118214327
```

4:{“r”:[{“0.00”:2.471},{“0.01”:1.14},{“0.09”:1.17},{“0.10”:0.971},{“0.16”:1
.17},{“0.2”:1.115},{“0.20”:

```
Top Terms:
b             =>   6.5324959497194035
shenzhen      =>   6.3067194191185205
shanghai      =>   6.03469366640658
index         =>   5.877770565651558
markets       =>   5.281963432157362
points        =>   5.199001299368368
investors     =>   4.874857696327004
securities    =>   4.628458164833687
exchanges     =>   4.141134030110127
stock         =>   4.080203191654102
```

5:{“r”:[{“0”:3.092},{“1”:1.072},{“1.7”:2.649},{“10”:1.174},{“100,000”:2.24}
,{“13”:1.874},{“1995”:1.615

```
Top Terms:
norilsk         =>   23.49074363708496
norilsk’s       =>   15.450867652893066
nickel          =>   12.47007417678833
uneximbank      =>   10.925413131713867
platinum        =>   8.708802223205566
roubles         =>   8.3026442527771
moscow          =>   8.118297100067139
russian         =>   7.876293182373047
feldman         =>   7.725433826446533
interrosimpex   =>   7.725433826446533
```

6:{“r”:[{“0003”:2.214},{“1.43”:2.514},{“1.6”:3.233},{“1.621”:2.621},{“1.73”
:2.879},{“1.8”:2.199},{“1.9

```
Top Terms:
octavia       =>    14.064229170481363
skoda         =>    13.854314804077148
sedan         =>    8.558053016662598
octavias      =>    8.547192096710205
kalma         =>    7.802151203155518
vw            =>    7.316673119862874
model         =>    6.555060386657715
crowns        =>    6.507203102111816
skoda’s       =>    6.345716953277588
volkswagen    =>    6.334976593653361
```

7:{“r”:[{“1”:1.516},{“1.3”:2.456},{“1.8”:2.333},{“10”:1.174},{“102”:3.17},{“118.75”:3.863},{“13”:1.874

Top Terms:

211 => 14.927149295806885
measure => 12.132993698120117
tech => 11.13357400894165
california => 10.693992614746094
proposition => 9.519742488861084
ballot => 9.508709192276001
lawsuits => 9.39264965057373
doerr => 8.708802223205566
proponents => 7.99928092956543
valley => 7.407749176025391

8:{“r”:[{“0”:2.69},{“0.1”:1.202},{“0.7”:1.086},{“1”:0.957},{“1.2”:2.101},{“1.75”:0.948},{“10”:1.5},{“1

Top Terms:

cocoa => 12.384515571594239
exporters => 8.50833672114781
ivory => 8.21403864451817
tonnes => 6.71575323513576
crop => 6.522159004211426
abidjan => 6.3893278803144185
caistab => 5.51087145124163
coast => 5.5066701071602955
coast’s => 4.897656372615269
97 => 4.866566862378802

9:{“r”:[{“0”:0.624},{“0.01”:0.237},{“0.02”:0.237},{“0.1”:0.486},{“0.10”:0.202},{“0.2”:0.328},{“0.3”:0.

Top Terms:

china => 2.694108472310831
chinese => 2.158722143216715
hong => 2.1480606425991082
kong => 1.9270160045971756
he => 1.8345288953052552
beijing => 1.8224368677171905
his => 1.6468639969146102
has => 1.627261827174179
china’s => 1.6272221035669168
would => 1.5738226572219431

```
10:{“r”:[{“1,500”:2.89},{“2,800”:3.719},{“30,000”:2.844},{“743”:2.518},{“ab
out”:0.586},{“although”:1.45
Top Terms:
hoffa          =>    26.19202709197998
ballots        =>    24.79529571533203
teamsters      =>    17.274595260620117
carey          =>    15.327719688415527
o’mara         =>    13.380844116210938
quindel        =>    13.380844116210938
carey’s        =>    12.153128623962402
election       =>    11.104988098144531
counted        =>    11.062716484069824
votes          =>    11.028792381286621
```

Ao se analisar os *clusters* gerados, observa-se mais claramente nos *clusters* 3 e 9, que possuem um tema em comum. Por exemplo, no *cluster* 3, os dez termos estão relacionados à computação, enquanto que no *cluster* 9, percebe-se claramente o assunto de China e cidades, portanto, certamente seria um agrupamento por assuntos nas postagens de *blogs* analisadas.

A saída do comando exibe o raio de atuação do centroide, com a variável específica e seu valor de raio associado. Para a ordenação dos termos exibida, a saída traz o valor de cada um dos termos para o *cluster* gerado.

Os diversos algoritmos implementados em *Mahout* poderão ser implantados em projetos reais e dependerão de integrações ou implementações específicas, dado o modelo de negócio ou tecnologias utilizadas.



Importante!

O projeto *Mahout* possui integrações e implementações em linguagem escala e a possibilidade de execução dos algoritmos usando a estrutura do projeto *Spark*, outra poderosa ferramenta para *Big Data* e que utiliza a estrutura do projeto *hadoop*.

Material Complementar

Indicações para saber mais sobre os assuntos abordados nesta Unidade:

Sites

Aprendizado de Máquina: Recomendação de Restaurantes com o *Apache Mahout* - Pragmatismo.io

Segue o *link* de um exemplo de execução de algoritmos em *Mahout* para sistemas de recomendação.

https://goo.gl/FNb5Ym

Introdução ao *Apache Mahout*

Segue o *link* do portal da IBM que traz um exemplo e introdução ao projeto *Mahout*.

https://goo.gl/MrxUue

***Apache Mahout* - Alexandre Volpi**

Segue outro *link* que traz um artigo sobre o *Mahout*.

https://goo.gl/9q3mvw

Apache Mahout parte três - Alexandre Volpi

Segue um exemplo de execução de um sistema de recomendação passo a passo com *Mahout*.

https://goo.gl/dfFeUn

Referências

SEAN Owen, Robin Anil, Ted Dunning, and Ellen Friedman. ***Mahout in Action***. Greenwich, CT, USA: Manning Publications Co., 2011.

SOUZA, Alberto Messias da Costa. **Uma nova arquitetura para *Internet* das Coisas com análise e reconhecimento de padrões e processamento com *Big Data***. 2015. Tese (Doutorado em Sistemas Eletrônicos) - Escola Politécnica, Universidade de São Paulo, São Paulo, 2015. Disponível em: <http://www.teses.usp.br/teses/disponiveis/3/3142/tde-20062016-105809/>. Acesso em: 2017-03-07.

THEODORIDIS, S.; KOUTROUMBAS, K. ***Pattern Recognition***. 4th. ed. [S.l.]: Academic Press, 2008.


Cruzeiro do Sul
Educacional